

Anh 1

main.pdf

 Kiểm tra trung lập 13

 Thông kê sinh học

 Khoa Lâm học

Thông tin chi tiết về tài liệu

ID bài nộp

trn:oid:::1:3645324921

Ngày nộp

22:20 GMT+7 10 thg 9, 2026

Ngày tải xuống

07:12 GMT+7 11 thg 9, 2026

Tên tệp

main.pdf

Kích cỡ tệp

3.6 MB

123 Trang

29.518 Từ

116.369 Ký tự

29% Tính tương đồng nói chung

Tổng cộng của tất cả các kết quả trùng khớp, bao gồm cả các nguồn trùng lặp, cho mỗi c...

Nguồn hàng đầu

22%  Nguồn Internet

16%  Ấn bản

17%  Bài tập được nộp (bài của học sinh)

Nguồn hàng đầu

- 22%  Nguồn Internet
- 16%  Ấn bản
- 17%  Bài tập được nộp (bài của học sinh)

Nguồn hàng đầu

Các nguồn có số lượng kết quả trùng khớp cao nhất trong bài nộp. Các nguồn chồng chéo sẽ không được hiển thị.

1	Bài của học viên	
Ton Duc Thang University		2%
2	Bài của học viên	
Ho Chi Minh City Open University		2%
3	Xuất bản	
Ton Duc Thang University		2%
4	Internet	
www.ctu.edu.vn		1%
5	Bài của học viên	
Van Lang University		1%
6	Bài của học viên	
National Economics University		1%
7	Bài của học viên	
Nha Trang University		<1%
8	Internet	
arxiv.org		<1%
9	Internet	
ictu.edu.vn		<1%
10	Internet	
tailieu.vn		<1%
11	Bài của học viên	
Post and Telecommunications Institute of Technology		<1%

12	Internet	vcl.huflit.edu.vn	<1%
13	Internet	www.thuvientailieu.vn	<1%
14	Bài của học viên	Vietnam Maritime University	<1%
15	Bài của học viên	University of Economics & Law	<1%
16	Bài của học viên	Foreign Trade University	<1%
17	Bài của học viên	Ho Chi Minh City University of Transport	<1%
18	Internet	www.slideshare.net	<1%
19	Internet	talkbank.org	<1%
20	Internet	gwdu.ptit.edu.vn	<1%
21	Internet	text.123docz.net	<1%
22	Internet	tmt.quarto.pub	<1%
23	Internet	lib.uet.vnu.edu.vn	<1%
24	Bài của học viên	University of Finance – Marketing	<1%
25	Internet	gust.edu.vn	<1%

26	Xuất bản	Vietnam National University of Forestry	<1%
27	Bài của học viên	Thai Nguyen University of Education	<1%
28	Xuất bản	Phenikaa University	<1%
29	Bài của học viên	International University - VNUHCM	<1%
30	Internet	www.zbook.vn	<1%
31	Internet	www.ijert.org	<1%
32	Internet	repositoriotec.tec.ac.cr	<1%
33	Xuất bản	Hanoi University	<1%
34	Internet	hvtc.edu.vn	<1%
35	Xuất bản	Duc Thang Phan, Huong Thanh Le. "Utilize Pre-Trained PhoBERT to Compute Text ...	<1%
36	Bài của học viên	Hung Vuong University	<1%
37	Internet	text.xemtailieu.net	<1%
38	Internet	www.neurosymbolic-ai-journal.com	<1%
39	Internet	123docz.net	<1%

40	Internet	luanvan.net.vn	<1%
41	Xuất bản	Thị Huỳnh Như Văn, Thị Hương Mai Thân, Bích Gia Hân Ôn, Phước Lộc Trần. "Phâ...	<1%
42	Internet	portal.ptit.edu.vn	<1%
43	Internet	qlkh.humg.edu.vn	<1%
44	Xuất bản	Poonam Nandal, Tapas Kumar, Meeta Singh, Mamta Dahiya. "Progressive Compu...	<1%
45	Internet	jst-haui.vn	<1%
46	Bài của học viên	Hoa Sen University	<1%
47	Internet	thuvienso.dut.udn.vn	<1%
48	Bài của học viên	University of Warwick	<1%
49	Bài của học viên	The Olympia School	<1%
50	Bài của học viên	Vietnam Commercial University	<1%
51	Internet	journalprivacyconfidentiality.org	<1%
52	Bài của học viên	Thai Nguyen University	<1%
53	Internet	hal.archives-ouvertes.fr	<1%

54	Bài của học viên	Ho Chi Minh University of Technology and Education	<1%
55	Xuất bản	"Intelligent Data Engineering and Automated Learning – IDEAL 2025", Springer Sc...	<1%
56	Internet	jstic.ptit.edu.vn	<1%
57	Internet	tapchigiaothong.qltns.mediacd.vn	<1%
58	Internet	tldr.lib.ntu.edu.tw	<1%
59	Internet	irlab.science.uva.nl	<1%
60	Internet	www.researchgate.net	<1%
61	Internet	www.tailieudaihoc.com	<1%
62	Xuất bản	Hanoi Pedagogical University 2	<1%
63	Internet	fliphtml5.com	<1%
64	Internet	fr.slideshare.net	<1%
65	Bài của học viên	Fulbright University Vietnam	<1%
66	Xuất bản	Tolga Berber. "A boolean information retrieval system for mammography reports...	<1%
67	Bài của học viên	Vietnam Aviation Academy	<1%

68	Internet	d197for5662m48.cloudfront.net	<1%
69	Internet	data.ute.udn.vn	<1%
70	Internet	github.com	<1%
71	Internet	vietnam.unfpa.org	<1%
72	Internet	anchor.fm	<1%
73	Internet	apps.dtic.mil	<1%
74	Internet	mdpi-res.com	<1%
75	Xuất bản	Nguyễn Tiến Hà, Nguyễn Thị Minh Huyền, Nguyễn Minh Hải. "Xây dựng kho ngữ l..."	<1%
76	Internet	www.mdpi.com	<1%
77	Internet	core.ac.uk	<1%
78	Internet	www.bbc.com	<1%
79	Xuất bản	Nguyễn Đức Dư, Phạm Đình Phong, Phạm Đình Vũ, Nguyễn Đức Thảo. "Một phươ..."	<1%
80	Xuất bản	Tâm Nguyễn Đức, Chinh Mai Tiến, Kỳ Phạm Văn. "Đánh giá độ tin cậy an toàn chổ..."	<1%
81	Xuất bản	Tô Khánh Toàn, Võ Hải Đăng, Trần Thị Cẩm Tú, Trương Quốc Định, Huỳnh Xuân Hi...	<1%

82	Internet	downloads.hindawi.com	<1%
83	Internet	www.diva-portal.org	<1%
84	Bài của học viên	HCMC University of Technology	<1%
85	Xuất bản	Lã Hoàng Quý, Toàn Định Phạm. "Phân đoạn ảnh cộng hưởng từ u não sử dụng t...	<1%
86	Bài của học viên	Universidade de Brasília, UnB	<1%
87	Internet	hcmulaw.edu.vn	<1%
88	Internet	ijcsmc.com	<1%
89	Internet	www.timtailieu.vn	<1%
90	Bài của học viên	University of Bolton	<1%
91	Internet	www.coursehero.com	<1%
92	Xuất bản	Hà Mạnh Hùng, Trương Việt Hùng, Đinh Văn Thuật, Vũ Quang Việt. "Phương phá...	<1%
93	Bài của học viên	Technological University Dublin	<1%
94	Internet	inba.info	<1%
95	Internet	clef2024.clef-initiative.eu	<1%

96	Internet	doc.edu.vn	<1%
97	Internet	nhandan.org.vn	<1%
98	Internet	thanhvien.vn	<1%
99	Internet	thuvienluanvan.net	<1%
100	Internet	123doc.org	<1%
101	Bài của học viên	University of Hong Kong	<1%
102	Internet	ictmag.ictvietnam.vn	<1%
103	Internet	jst.tnu.edu.vn	<1%
104	Internet	snapshot.canon-asia.com	<1%
105	Internet	trituenhantao.io	<1%
106	Internet	vdoc.pub	<1%
107	Internet	www.uet.vnu.edu.vn	<1%
108	Xuất bản	Mạnh Hùng Đỗ. "Nghiên cứu đánh giá ảnh hưởng các tham số của biến đổi fourie..."	<1%
109	Internet	hdujs.edu.vn	<1%

110	Xuất bản	"Experimental IR Meets Multilinguality, Multimodality, and Interaction", Springer...	<1%
111	Xuất bản	Bùi Trung Kiên, Đặng Hoàng Long, Từ Minh Phương. "TĂNG CƯỜNG PHÁT HIỆN Đ...	<1%
112	Bài của học viên	Foreign Trade University - Ho Chi Minh Campus	<1%
113	Internet	coe.ctu.edu.vn	<1%
114	Internet	dokumen.pub	<1%
115	Internet	lp3m.asia.ac.id	<1%
116	Internet	truongtohnhat.vn	<1%
117	Bài của học viên	Escuela Superior Politécnica del Litoral	<1%
118	Bài của học viên	Imperial College of Science, Technology and Medicine	<1%
119	Internet	cmsnews.tapchixaydung.vn	<1%
120	Internet	ir.lib.uth.gr	<1%
121	Bài của học viên	Banking University of Ho Chi Minh City	<1%
122	Bài của học viên	College Faculty Members	<1%
123	Bài của học viên	Hanoi Metropolitan University	<1%

124	Bài của học viên	Yersin University of Da Lat	<1%
125	Internet	hpmu.edu.vn	<1%
126	Internet	repository.library.ualberta.ca	<1%
127	Internet	thonghutbephottaivinhphuc.com	<1%
128	Internet	vi.cenlamontessori.org	<1%
129	Internet	www.arxiv-vanity.com	<1%
130	Internet	zhuanzhi.ai	<1%
131	Xuất bản	Huỳnh Hữu Nghĩa, Hồ Quốc Bảo. "RÚT TRÍCH VÀ CHUẨN HÓA KHÁI NIỆM Y TẾ TRỀ...	<1%
132	Internet	ar5iv.labs.arxiv.org	<1%
133	Internet	bde.vn	<1%
134	Internet	daln.gov.vn	<1%
135	Internet	doan.edu.vn	<1%
136	Internet	ejurnal.stmik-budidarma.ac.id	<1%
137	Internet	honors.libraries.psu.edu	<1%

138	Internet	thuviensonla.com.vn	<1%
139	Internet	vpslabs.net	<1%
140	Internet	36win.com.co	<1%
141	Xuất bản	Bhagya Sri Uddandam, Chirag Girish Mokashi, Jose Rodrigo Arizpe Figueroa, Krish...	<1%
142	Xuất bản	Harris Papadopoulos. "Reliable Probabilistic Prediction for Medical Decision Supp...	<1%
143	Xuất bản	Phạm Thế Phi, Đỗ Thanh Nghị. "ỨNG DỤNG KỸ THUẬT ĐỊNH DANH TỪ DỮ LIỆU VI...	<1%
144	Internet	bigdatauni.com	<1%
145	Internet	cgspace.cgiar.org	<1%
146	Internet	cs191w.stanford.edu	<1%
147	Internet	dataaspirant.com	<1%
148	Internet	dl.ueb.vnu.edu.vn	<1%
149	Internet	excelonline.work	<1%
150	Internet	fpt.ai	<1%
151	Internet	itigic.com	<1%

152	Internet	netlibrary.aau.at	<1%
153	Internet	proceeding.vap.ac.vn	<1%
154	Internet	publikationen.bibliothek.kit.edu	<1%
155	Internet	repository.itpln.ac.id	<1%
156	Internet	sdh.hcmus.edu.vn	<1%
157	Internet	tailieuso.udn.vn	<1%
158	Internet	talkcodetome.com	<1%
159	Internet	thuvien.due.udn.vn:8080	<1%
160	Internet	tiensu.github.io	<1%
161	Internet	timtailieu.vn	<1%
162	Internet	www.tailieumienphi.vn	<1%
163	Internet	21stcenturyschizoidband.com	<1%
164	Xuất bản	Hanoi National University of Education	<1%
165	Xuất bản	Hoàng Nguyễn Văn. "DETECTING INUNDATED RICE PADDY FIELDS IN AN GIANG P...	<1%

166	Xuất bản	Nguyễn Chí Thanh, Võ Thị Huyền Trang, Lê Minh Hưng, Hoàng Lê Uyên Thực. "KẾ...	<1%
167	Xuất bản	Nguyễn Thị Hải Như. "Ứng dụng mạng trí tuệ nhân tạo tìm cốt liệu tương đương ...	<1%
168	Internet	aclanthology.org	<1%
169	Internet	beatdautu.com	<1%
170	Internet	documents.mx	<1%
171	Internet	dulieu.tailieuhoctap.vn	<1%
172	Internet	forum.ueh.vn	<1%
173	Internet	gialoc.com.vn	<1%
174	Internet	gs.ctu.edu.vn	<1%
175	Internet	ichi.pro	<1%
176	Internet	kse2025.kse-conferences.org	<1%
177	Internet	luanan.net	<1%
178	Internet	luanvan.co	<1%
179	Internet	midtransangiang.blogspot.com	<1%

180	Internet	o7planning.org	<1%
181	Internet	phannguyenquoctu.blogspot.com	<1%
182	Internet	sanytuong.vn	<1%
183	Internet	tai-lieu.com	<1%
184	Internet	text-id.123dok.com	<1%
185	Internet	thuvienphapluat.vn	<1%
186	Internet	vahanamok.blogspot.com	<1%
187	Internet	viasm.edu.vn	<1%
188	Internet	worldhealthy.emyspot.com	<1%
189	Internet	www.allsciencesacademy.com	<1%
190	Internet	www.nguoi-viet.com	<1%
191	Internet	www.sdh.vimaru.edu.vn	<1%
192	Internet	www.triethoc.edu.vn	<1%
193	Xuất bản	Đào Vũ Hiệp, Mạc Đình Hiếu, Tống Việt Hùng, Vũ Văn Phán, Hà Quốc Trung. "IVA-...	<1%

194	Xuất bản	Hà Mạnh Hùng. "Ứng dụng thuật toán "rừng ngẫu nhiên" cho phân tích hồi qui k...	<1%
195	Xuất bản	Trần Ngọc Phúc. "PHÂN LOẠI NỘI DUNG TÀI LIỆU WEB TIẾNG VIỆT", Vietnam Jour...	<1%
196	Internet	academic.oupdev.silverchair.com	<1%
197	Internet	audio.myna.vn	<1%
198	Internet	cloudgo.vn	<1%
199	Internet	data.uet.vnu.edu.vn:8080	<1%
200	Internet	diaoctienphong.vn	<1%
201	Internet	dichvuthammy.vn	<1%
202	Internet	dost.hochiminhcity.gov.vn	<1%
203	Internet	hackmd.io	<1%
204	Internet	hdl.vn	<1%
205	Internet	hoctiengtrung.com	<1%
206	Internet	hzzgjt.com	<1%
207	Internet	ioop.org.vn	<1%

208	Internet	itvovantien.blogspot.com	<1%
209	Internet	jmst.mod.gov.vn	<1%
210	Internet	jst-ud.vn	<1%
211	Internet	lamkinhdesigner.com	<1%
212	Internet	lastenkulttuuri.fi	<1%
213	Internet	oilgas.vn	<1%
214	Internet	phonglanbk.blogspot.com	<1%
215	Internet	pkhht.dlu.edu.vn	<1%
216	Internet	pyhealth.readthedocs.io	<1%
217	Internet	thuvienso.bvu.edu.vn	<1%
218	Internet	toc.123doc.org	<1%
219	Internet	ttgdtvlaocai.vn	<1%
220	Internet	ueb.edu.vn	<1%
221	Internet	umontreal.scholaris.ca	<1%

222	Internet	vi.quanlynhanuoc.vn	<1%
223	Internet	vie.legatechnics.com	<1%
224	Internet	webbenhxahoi.com	<1%
225	Internet	www.cmmeetup.com	<1%
226	Internet	www.everyvietstudent.com	<1%
227	Internet	www.ida.liu.se	<1%
228	Internet	www.timmachhoc.vn	<1%
229	Internet	www.uit.edu.vn	<1%
230	Xuất bản	Huỳnh Quyết Thắng, Phùng Đình Vũ, Tống Văn Vinh. "Dự đoán xu thế chỉ số chứn...	<1%
231	Xuất bản	Phan Phương Lan, Huỳnh Hữu Hưng, Huỳnh Xuân Hiệp. "HỆ TƯ VẤN DỰA TRÊN Đ...	<1%
232	Xuất bản	VNUA	<1%
233	Xuất bản	Duc-Vu Nguyen, Ngan Luu-Thuy Nguyen. "Is word segmentation necessary for Vi...	<1%
234	Xuất bản	Huỳnh Thanh Tú, Võ Bách Khôi, Hồ Anh Dũng, Vũ Đức Lung. "PHÂN TÍCH CẢM XÚ...	<1%
235	Xuất bản	Nguyễn Quang Phúc. "Gom cụm kết quả tìm kiếm video với hướng tiếp cận kết h...	<1%

236	Xuất bản	Thanh Phong Huỳnh, Ngọc Thái Anh Huỳnh. "Ứng dụng thiết bị di động nhận dạng..."	<1%
237	Xuất bản	Trần Hoàng Phát, Phạm Mạnh Cường, Trần Đình Toàn, Hoàng Tùng, Lê Minh Hưn...	<1%
238	Xuất bản	Trần Văn Quang, Trần Đình Toàn, Lê Mậu Long, Lê Minh Hưng. "PHÂN LOẠI HẠCH..."	<1%
239	Xuất bản	Võ Minh Thiện, Lê Minh Hưng, Trần Kim Tâm, Trần Văn Lãng. "XỬ LÝ MẤT CÂN BẮ..."	<1%

BỘ GIÁO DỤC VÀ ĐÀO TẠO
TRƯỜNG ĐẠI HỌC MỞ THÀNH PHỐ HỒ CHÍ MINH



NGUYỄN HOÀNG ANH

PHÁT HIỆN TIN GIẢ TIẾNG VIỆT SỬ DỤNG HỌC
MÁY VÀ HỌC SÂU

ĐỒ ÁN NGÀNH
NGÀNH TRÍ TUỆ NHÂN TẠO

TP. HỒ CHÍ MINH, NĂM 2026

BỘ GIÁO DỤC VÀ ĐÀO TẠO
TRƯỜNG ĐẠI HỌC MỎ THÀNH PHỐ HỒ CHÍ MINH



NGUYỄN HOÀNG ANH

PHÁT HIỆN TIN GIẢ TIẾNG VIỆT SỬ DỤNG HỌC
MÁY VÀ HỌC SÂU

Mã số sinh viên: 2351010009

ĐỒ ÁN NGÀNH
NGÀNH TRÍ TUỆ NHÂN TẠO

Giảng viên hướng dẫn: TS. LÊ QUANG MINH

TP. HỒ CHÍ MINH, NĂM 2026

Đầu tiên, em xin bày tỏ lòng biết ơn sâu sắc đến **TS. LÊ QUANG MINH** – giảng viên hướng dẫn của đồ án – người đã tận tình chỉ bảo, định hướng nghiên cứu, góp ý chi tiết và động viên em xuyên suốt quá trình thực hiện đồ án ngành.

Em cũng xin trân trọng cảm ơn quý thầy cô trong Đào tạo Đặc biệt và Công nghệ Thông tin – Trường Đại học Mở đã trang bị cho em nền tảng kiến thức vững chắc về ngành **TRÍ TUỆ NHÂN TẠO** cùng các hành trang cần thiết trong suốt những năm học vừa qua.

Em cũng xin cảm ơn gia đình và bạn bè – những người luôn ở bên cạnh, lắng nghe và động viên em trong suốt thời gian thực hiện đồ án. Do thời gian và kiến thức còn hạn chế, đồ án khó tránh khỏi những hạn chế và điểm chưa hoàn thiện. Em kính mong nhận được những ý kiến đóng góp từ quý thầy cô để có thể tiếp tục cải thiện kiến thức, kỹ năng cũng như nâng cao chất lượng các nghiên cứu trong tương lai.

Thành phố Hồ Chí Minh, tháng 9 năm 2026

Sinh viên thực hiện

NGUYỄN HOÀNG ANH

TÓM TẮT ĐỒ ÁN NGÀNH

Hiện nay, các nền tảng số đang góp phần thúc đẩy tốc độ lan truyền thông tin với quy mô ngày càng rộng., vấn nạn tin giả ngày càng trở nên nghiêm trọng và gây ra nhiều hệ lụy đối với xã hội, kinh tế cũng như chính trị. Trước thực trạng đó, các hệ thống phát hiện tin giả tự động đã nhận được sự quan tâm đáng kể từ cộng đồng nghiên cứu và các tổ chức truyền thông. Nhiều phương pháp đã được đề xuất, từ các mô hình học máy truyền thống dựa trên đặc trưng văn bản cho đến các mô hình học sâu có khả năng khai thác ngữ nghĩa và ngữ cảnh ở mức độ phức tạp hơn.

Đề tài này phát triển và đánh giá bốn mô hình phát hiện tin giả tiếng Việt, đại diện cho các mức độ phức tạp khác nhau – từ học máy truyền thống đến mô hình ngôn ngữ tiên huấn luyện. Bốn phương pháp được so sánh bao gồm: Hồi quy Logistic (LR) và Máy vectơ hỗ trợ (SVM) sử dụng đặc trưng TF-IDF, mạng LSTM hai chiều (BiLSTM) với cơ chế chú ý, và mô hình ngôn ngữ PhoBERT được tinh chỉnh theo tác vụ. Thực nghiệm được tiến hành trên bộ dữ liệu gồm 13.958 mẫu sau khi làm sạch, được chia theo tỉ lệ 70/15/15 (huấn luyện/kiểm định/kiểm tra).

Kết quả cho thấy PhoBERT đạt F1-Score cao nhất (89,88%) và ROC-AUC = 0,9495, vượt trội so với LR, SVM và BiLSTM. Kiểm định McNemar với hiệu chỉnh Holm–Bonferroni xác nhận sự khác biệt có ý nghĩa thống kê ($p < 0,001$) khi so sánh PhoBERT với các mô hình còn lại. Nghiên cứu ablation chỉ ra rằng

tiền huấn luyện trên ngữ liệu tiếng Việt là nhân tố quyết định chính, trong khi phân đoạn từ và kích thước từ điển đóng vai trò thứ yếu đối với các mô hình học máy truyền thống.

Mục lục

Tóm tắt đồ án ngành	IV
Mục lục	IX
Danh mục viết tắt	XI
Danh mục hình vẽ	XIII
Danh mục bảng biểu	XV
1 Tổng quan về đề tài	1
1.1 Đặt vấn đề	1
1.2 Mục tiêu nghiên cứu	1
1.3 Phạm vi nghiên cứu	2
1.4 Cấu trúc của báo cáo	2
2 Cơ sở lý thuyết	3
2.1 Một số khái niệm cơ bản	3
2.1.1 Văn bản và biểu diễn văn bản	3
2.1.2 Đặc trưng văn bản và tiền xử lý	4
2.1.3 Bài toán phân loại văn bản	5
2.2 Xử lý ngôn ngữ tự nhiên tiếng Việt	6

37	2.2.1	Đặc điểm ngôn ngữ tiếng Việt	6
	2.2.2	Phân đoạn từ (Word Segmentation)	7
	2.2.3	Biểu diễn văn bản số	7
99	2.2.4	Quá trình hình thành, phát triển và các nghiên cứu liên quan	8
2	2.3	Học máy	9
	2.3.1	Định nghĩa	9
	2.3.2	Một số thuật toán học máy tiêu biểu	10
	2.3.2.1	Logistic Regression (LR)	10
184	2.3.2.2	Support Vector Machine (SVM)	10
	2.3.3	Biểu diễn đặc trưng cơ bản	12
77	2.3.3.1	TF-IDF (Term Frequency – Inverse Document Frequency)	12
	2.4	Học sâu	14
	2.4.1	Định nghĩa	14
49	2.4.2	Mạng nơ-ron nhân tạo (Artificial Neural Network)	15
	2.4.2.1	Một số thành phần cần chú ý	17
139	2.4.3	Recurrent Neural Networks (RNN)	19
	2.4.4	Long Short-Term Memory (LSTM)	19
	2.4.5	Mạng LSTM hai chiều (Bidirectional LSTM)	21
	2.4.6	Cơ chế chú ý (Attention Mechanism)	22
	2.5	Biểu diễn phân tán và mã hóa con (Distributed & Subword Representations)	23
	2.5.1	Word2Vec và GloVe	24
	2.5.2	FastText và thông tin subword	25
	2.5.3	Mã hóa con (Subword Tokenization)	25
	2.6	Mô hình Transformer và phương thức Self-Attention	26
221	2.6.1	Cơ chế Scaled Dot-Product Attention	27
	2.6.2	Multi-Head Attention và Positional Encoding	27

2.6.3	Encoder vs Decoder	29
2.7	PhoBERT và mô hình ngôn ngữ tiền huấn luyện	30
2.7.1	Tiền huấn luyện (Pre-Training) và tinh chỉnh (Fine-Tuning)	30
2.7.2	PhoBERT cho tiếng Việt	31
2.7.3	Một số công trình liên quan về phát hiện tin giả tiếng Việt	32
2.8	Đánh giá mô hình và phân tích hiệu chuẩn	32
2.8.1	Các độ đo hiệu năng phân loại	32
2.8.2	Kiểm định thống kê	33
2.8.3	Hiệu chuẩn xác suất (Probability Calibration)	34
2.9	Kết luận chương	35
3	Bộ dữ liệu và tiền xử lý	37
3.1	Thu thập và mô tả bộ dữ liệu	37
3.1.1	Nguồn dữ liệu	37
3.1.2	Phân phối nhãn	38
3.2	Tiền xử lý văn bản	39
3.2.1	Làm sạch và lọc dữ liệu	39
3.2.2	Phân đoạn từ bằng VnCoreNLP	40
3.3	Chia tập dữ liệu	41
3.3.1	Chia phân tầng	41
3.3.2	Kiểm tra rò rỉ dữ liệu	44
3.4	Kết luận chương	45
4	Xác định tin giả	46
4.1	Phương pháp đề xuất	46
4.2	Lý do lựa chọn các nhóm mô hình	47
4.3	Tổng quan kiến trúc hệ thống	49
4.4	Trích xuất đặc trưng	50
4.4.1	TF-IDF cho mô hình học máy truyền thống	50

4.4.1.1	Lý do lựa chọn TF-IDF	50
4.4.1.2	Cấu hình TF-IDF	51
4.4.2	Word Embedding cho BiLSTM	51
4.4.3	Tokenization PhoBERT (BPE)	52
4.5	Các mô hình phân loại	53
4.5.1	Các mô hình học máy truyền thống	53
4.5.1.1	Hồi quy Logistic	53
4.5.1.2	Máy vectơ hỗ trợ	53
4.5.2	Các mô hình học sâu	54
4.5.2.1	Mạng BiLSTM	54
4.5.2.2	Tinh chỉnh PhoBERT	54
4.6	Chiến lược xử lý mất cân bằng nhãn	55
4.7	Các phân tích mở rộng được thiết kế cho chương thực nghiệm	56
4.7.1	Phân tích khả năng giải thích (Explainability)	56
4.7.2	Hiệu chỉnh xác suất sau huấn luyện (Post-Hoc Calibration)	57
4.7.3	Phân tích các trường hợp khó (Hard Cases)	58
4.7.4	Knowledge Distillation	58
4.8	Kết luận chương	59
5	Kết quả thực nghiệm	60
5.1	Môi trường thực nghiệm	60
5.2	So sánh hiệu năng các mô hình	61
5.2.1	Kết quả tổng thể	61
5.2.2	Hiệu năng theo từng lớp	62
5.2.3	Ma trận nhầm lẫn	63
5.2.4	Đường cong ROC và Precision-Recall	64
5.2.5	Phân tích hiệu chuẩn xác suất (Calibration Analysis)	64
5.3	Kiểm định thống kê	67
5.3.1	Kiểm định McNemar	67

5.3.2	Khoảng tin cậy Bootstrap	69
5.3.3	Kiểm tra chéo (Cross-Validation)	71
5.4	Nghiên cứu triệt bỏ (Ablation Study)	72
5.5	Phân tích lỗi	76
5.5.1	Thống kê lỗi tổng quan	76
5.5.1.1	So sánh FP và FN	76
5.5.1.2	Phân phối lỗi theo độ dài văn bản	78
5.5.1.3	Hàm ý cải tiến mô hình	79
5.5.2	Phân tích khả năng giải thích	80
5.5.2.1	Phân tích khả năng giải thích cấp token (Token-Level Explainability)	81
5.5.2.2	Hiệu chỉnh xác suất sau huấn luyện (Post-Hoc Calibration)	85
5.5.2.3	Phân tích chuyên sâu các trường hợp khó (Hard Cases Deep Analysis)	87
5.5.2.4	Knowledge Distillation – Mô hình sinh viên nhỏ, chất lượng tiệm cận giáo viên	90
5.6	Kết luận chương	91
	Kết luận	93
	Phụ lục	100

DANH MỤC VIẾT TẮT

117	AUC	Area Under the ROC Curve
	BERT	Bidirectional Encoder Representations from Transformers
	BPE	Byte Pair Encoding
	CI	Confidence Interval
	CV	Cross-Validation
	ECE	Expected Calibration Error
	F1	F1-Score
154	FFN	Feed-Forward Network
	FN	False Negative
	FP	False Positive
	GPU	Graphics Processing Unit
	IDF	Inverse Document Frequency
	KD	Knowledge Distillation
	LR	Logistic Regression
	MCE	Maximum Calibration Error
	NLP	Natural Language Processing
	PhoBERT	Pre-trained language model for Vietnamese (VinAI)
120	ReLU	Rectified Linear Unit
	RNN	Recurrent Neural Network
	ROC	Receiver Operating Characteristic
	TF	Term Frequency
	TN	True Negative
	TP	True Positive

Danh mục hình vẽ

2	2.1	Minh họa phương pháp biểu diễn văn bản bằng TF-IDF ¹	4
2	2.2	Các bước tiền xử lý văn bản trước khi đưa vào mô hình học máy. ¹	5
	2.3	Minh họa bài toán phân loại văn bản ¹	6
	2.4	Minh họa thuật toán nhị phân SVM ¹	12
	2.5	Ví dụ minh họa cách tính TF-IDF trên hai tài liệu ¹	14
	2.6	Minh họa mạng nơ-ron nhân tạo ¹	16
	2.7	Minh họa kiến trúc nhiều lớp của mạng nơ-ron nhân tạo ¹	17
	2.8	Minh họa cấu trúc mạng LSTM ¹	20
	2.9	Minh họa cấu trúc mạng LSTM hai chiều ¹	21
	2.10	Minh họa kiến trúc Transformer encoder ¹	28
	3.1	Phân phối nhãn theo từng tập dữ liệu và tổng quan toàn bộ 15.789 mẫu	38
45	3.2	Phân phối nhãn trong các tập dữ liệu huấn luyện, kiểm định và kiểm tra	43
10	5.1	So sánh các chỉ số hiệu năng (Accuracy, F1-Score, ROC-AUC) của bốn mô hình trên tập kiểm tra	61
	5.2	Precision, Recall và F1-Score theo từng lớp (<i>thật / giả</i>) cho bốn mô hình	62
28	5.3	Ma trận lỗi của bốn mô hình khi thực hiện dự đoán trên tập kiểm tra (2.094 mẫu)	63

5.4 Đường cong ROC và Precision-Recall của bốn mô hình trên tập kiểm tra	64
5.5 Biểu đồ hiệu chuẩn (Reliability Diagram) của bốn mô hình trên tập kiểm tra. Đường chéo nét đứt biểu diễn hiệu chuẩn hoàn hảo; các điểm vuông biểu diễn tỷ lệ dương tính thực tế trong mỗi bin xác suất.	66
5.6 So sánh số lượng False Positive (FP) và False Negative (FN) trong quá trình phân loại	76
5.7 Phân phối lỗi phân loại theo độ dài văn bản	78
5.8 Top 15 đặc trưng TF-IDF có hệ số LR cao nhất (dương = chỉ điểm <i>giả</i> , âm = chỉ điểm <i>thật</i>)	80
5.9 Phân loại lỗi theo độ dài văn bản và mức độ tin cậy dự đoán . . .	81
5.10 Token attribution bằng SHAP cho Logistic Regression và SVM trên cùng một mẫu kiểm tra.	84
5.11 Jaccard overlap của top-10 token quan trọng giữa các phương pháp attribution, trung bình trên 20 mẫu kiểm tra.	85
5.12 Biểu đồ hiệu chuẩn của bốn mô hình trước và sau khi áp dụng post-hoc calibration.	87
5.13 Phân bố của 85 mẫu khó theo chủ đề, độ dài, lý do thất bại và độ tự tin của từng mô hình.	89

Danh mục bảng biểu

3.1	Thống kê tập dữ liệu	43
5.1	Siêu tham số các mô hình	60
5.2	Độ phức tạp và thời gian huấn luyện	61
5.3	So sánh hiệu suất các mô hình	61
5.4	Chỉ số hiệu suất theo lớp	62
5.5	Chỉ số hiệu chuẩn xác suất của bốn mô hình trên tập kiểm tra	66
5.6	Kết quả kiểm định McNemar (Sau hiệu chỉnh Holm-Bonferroni)	69
5.7	Khoảng tin cậy 95% Bootstrap [1] cho F1-Score (10.000 lần lấy mẫu lại)	70
5.8	Kết quả kiểm tra chéo 5-fold (3 seeds)	71
5.9	Kết quả Ablation Study trên tập kiểm tra	74
5.10	Phân tích lỗi trên tập kiểm tra	79
5.11	Faithfulness of token-level explanations	85
5.12	So sánh hiệu chuẩn sau post-hoc calibration	87
5.13	Các mẫu khó được phân tích chi tiết	90
5.14	So sánh teacher và student sau Knowledge Distillation	91
5.15	Số mẫu theo lớp của từng tập	100
5.16	Cấu hình TF-IDF, LR, SVM	102
5.17	Cấu hình BiLSTM và PhoBERT	102
5.18	Metric tổng hợp trên tập test	103
5.19	Precision/Recall/F1 theo lớp	104
5.20	Confusion matrix trên tập test	104

5.21 Khoảng tin cậy Bootstrap 95% cho F1-score	104
5.22 So sánh giáo viên – sinh viên	105
5.23 Faithfulness của sáu phương pháp attribution	105
5.24 Cross-validation 5-fold	106
5.25 Phân bố hard cases theo lý do	106

6

Chương

1

TỔNG QUAN VỀ ĐỀ TÀI

1.1 Đặt vấn đề

Sự bùng nổ của mạng xã hội như Facebook, TikTok, Zalo cùng các nền tảng tin tức trực tuyến tại Việt Nam đã tạo môi trường thuận lợi cho việc lan truyền thông tin nhanh chóng. Đồng thời, điều này cũng làm cho tin giả dễ dàng phát tán trước khi được kiểm chứng.

Việc kiểm tra thủ công từng bài viết đòi hỏi nhiều nhân lực và thời gian, không khả thi ở quy mô lớn. Vì vậy, việc xây dựng các hệ thống phát hiện tin giả tự động bằng học máy và học sâu trở nên cấp thiết.

1.2 Mục tiêu nghiên cứu

- Xây dựng và so sánh bốn mô hình phân loại tin tức tiếng Việt: LR, SVM, BiLSTM và PhoBERT.
- Đánh giá ảnh hưởng của phân đoạn từ tiếng Việt đối với hiệu năng mô hình.
- Thực hiện đánh giá toàn diện bao gồm kiểm định thống kê, kiểm tra chéo và phân tích giải thích.
- Xác định phương pháp phù hợp nhất cho bài toán phát hiện tin giả tiếng

Việt.

1.3 Phạm vi nghiên cứu

Nghiên cứu tập trung vào phân loại nhị phân văn bản tiếng Việt (tin thật/tin giả) dựa trên tiêu đề và nội dung bài viết. Bộ dữ liệu được thu thập từ các bài đăng công khai trên mạng xã hội cùng nhiều bài viết trên các nền tảng trực tuyến.

1.4 Cấu trúc của báo cáo

Nội dung báo cáo được triển khai qua năm chương, tiếp nối bằng phần kết luận.:

- **Chương 1** (chương hiện tại) trình bày tổng quan đề tài, mục tiêu, phạm vi và bố cục báo cáo.
- **Chương 2** trình bày cơ sở lý thuyết về xử lý ngôn ngữ tự nhiên tiếng Việt, các phương pháp học máy và kiến trúc mô hình học sâu được sử dụng.
- **Chương 3** mô tả bộ dữ liệu, quy trình tiền xử lý và cách chia tập dữ liệu.
- **Chương 4** trình bày chi tiết các phương pháp đề xuất, kiến trúc mô hình và quy trình huấn luyện.
- **Chương 5** trình bày kết quả thực nghiệm, phân tích lỗi, kiểm định thống kê và nghiên cứu ablation.
- **Kết luận** tổng kết các đóng góp của đề án, hạn chế và hướng phát triển trong tương lai.

Chương 2

CƠ SỞ LÝ THUYẾT


Chương này bắt đầu với một số khái niệm cơ bản trong lĩnh vực xử lý ngôn ngữ tự nhiên như văn bản, đặc trưng văn bản, biểu diễn từ và vector hóa dữ liệu. Sau đó, trình bày định nghĩa và một số thuật toán tiêu biểu được sử dụng trong bài toán phát hiện tin giả như Logistic Regression và Support Vector Machine. Cuối cùng là mô tả về học sâu và cấu trúc của các mô hình mạng nơ-ron được áp dụng trong đề tài, bao gồm BiLSTM và PhoBERT cùng với các thành phần chính của chúng.

2.1 Một số khái niệm cơ bản

2.1.1 Văn bản và biểu diễn văn bản

Trong lĩnh vực xử lý ngôn ngữ tự nhiên, văn bản là dữ liệu đầu vào chính của hệ thống. Văn bản bao gồm các câu được cấu thành từ các từ và ký tự. Tuy nhiên, để các mô hình học máy có thể xử lý, văn bản cần được chuyển đổi sang dạng số thông qua các phương pháp biểu diễn như bag-of-words hoặc TF-IDF. Các phương pháp này giúp chuyển mỗi tài liệu thành một vector đặc trưng trong không gian nhiều chiều.

Test preprocessing pipeline




Hình 2.1: Minh họa phương pháp biểu diễn văn bản bằng TF-IDF¹

2.1.2 Đặc trưng văn bản và tiền xử lý

Đặc trưng văn bản là các thuộc tính được trích xuất từ dữ liệu văn bản nhằm phục vụ cho quá trình huấn luyện mô hình, dữ liệu cần được tiền xử lý nhằm đưa văn bản về dạng phù hợp. Các bước thường thực hiện gồm chuẩn hóa nội dung và loại bỏ những ký tự đặc biệt không cần thiết, tách từ và loại bỏ từ dừng. Đối với tiếng Việt, bước tách từ đóng vai trò quan trọng do đặc điểm ngôn ngữ có từ ghép và đa nghĩa.

¹nguồn ảnh: <https://www.linkedin.com/pulse/creating-tf-idf-model-from-scratch-python-noor-saeed>




Hình 2.2: Các bước tiền xử lý văn bản trước khi đưa vào mô hình học máy.²

2.1.3 Bài toán phân loại văn bản

Bài toán phát hiện tin giả được xem là một bài toán phân loại nhị phân, trong đó mỗi văn bản được gán nhãn là “tin thật” hoặc “tin giả”. Mục tiêu của mô hình là học được hàm ánh xạ từ không gian đặc trưng của văn bản sang tập nhãn tương ứng.

²nguồn ảnh: <https://www.couchbase.com/blog/data-preprocessing-in-machine-learning/>



Hình 2.3: Minh họa bài toán phân loại văn bản³

2.2 Xử lý ngôn ngữ tự nhiên tiếng Việt

2.2.1 Đặc điểm ngôn ngữ tiếng Việt

Tiếng Việt là ngôn ngữ đơn lập, không biến hình, với các đặc điểm khác biệt so với tiếng Anh và nhiều ngôn ngữ châu Âu:

- Không có khoảng cách giữa các âm tiết: ranh giới từ và âm tiết trong tiếng Việt không trùng nhau. Ví dụ, “thành phố” là một từ nhưng được viết thành hai âm tiết riêng biệt.
- Từ ghép và từ láy: nhiều khái niệm được biểu đạt bằng tổ hợp nhiều âm tiết, ví dụ từ ghép “học_sinh”, “kinh_tế”, hay từ láy “lung_linh”.

³nguồn ảnh: https://maelfabien.github.io/machinelearning/NLP_5/

- Thanh điệu: tiếng Việt có 6 thanh điệu, ảnh hưởng quan trọng đến ngữ nghĩa nhưng không ảnh hưởng đến cấu trúc hình thái học.
- Ngôn ngữ cô lập: quan hệ ngữ pháp được biểu đạt qua trật tự từ và các hư từ, không qua biến đổi hình thái.

Những đặc điểm này đòi hỏi bước tiền xử lý đặc thù – đặc biệt là *phân đoạn từ* – trước khi áp dụng các mô hình học máy.

2.2.2 Phân đoạn từ (Word Segmentation)

Phân đoạn từ là bước xác định ranh giới các từ trong câu tiếng Việt. Hầu hết các mô hình NLP (đặc biệt là PhoBERT) được huấn luyện trên dữ liệu đã qua phân đoạn. Việc phân đoạn nhất quán giữa dữ liệu huấn luyện và dữ liệu suy diễn đóng vai trò quan trọng trong việc duy trì tính tương thích với từ vựng và embedding của mô hình ngôn ngữ tiền huấn luyện.

Ví dụ:

Trước: “thành phố hồ chí minh là trung tâm kinh tế lớn nhất Việt nam.”

Sau: “thành_phố hồ_chí_minh là trung_tâm kinh_tế lớn nhất Việt_nam.”

2.2.3 Biểu diễn văn bản số

Các mô hình học máy cần chuyển đổi văn bản thô sang dạng số. Nghiên cứu này sử dụng ba phương pháp:

1. TF-IDF: Vectơ đặc trưng dựa trên tần suất từ, phù hợp cho LR và SVM.
2. Word Embedding: Vectơ dày đặc học được [2], khởi tạo từ FastText tiếng Việt [3], phù hợp cho BiLSTM.

3. Subword Tokenization (BPE): Tách từ thành các đơn vị con, dùng cho PhoBERT.

2.2.4 Quá trình hình thành, phát triển và các nghiên cứu liên quan

Xử lý ngôn ngữ tự nhiên tiếng Việt (Vietnamese NLP) có lịch sử phát triển gắn liền với sự phức tạp đặc thù của ngôn ngữ này. Khác với tiếng Anh, nơi ranh giới từ được xác định rõ ràng bởi khoảng trắng, tiếng Việt yêu cầu bước phân đoạn từ trước khi áp dụng hầu hết các kỹ thuật NLP hiện đại. Thách thức cơ bản này đã thúc đẩy nhiều nghiên cứu trong và ngoài nước tập trung vào việc phát triển các công cụ và tài nguyên cho tiếng Việt.

Ở những giai đoạn đầu của quá trình nghiên cứu, đặc biệt trước năm 2010, phân đoạn từ là một trong những bài toán được quan tâm chủ yếu trong lĩnh vực NLP tiếng Việt. Thuật toán CRF (Conditional Random Fields) được sử dụng rộng rãi như phương pháp chuẩn cho bài toán này. Từ năm 2015 trở đi, các phương pháp học sâu dần thay thế CRF trong hầu hết các tác vụ NLP tiếng Việt, bao gồm phân đoạn từ, gán nhãn từ loại và phân tích cú pháp. Đáng chú ý, RDRSegmenter [4] – công cụ phân đoạn từ được sử dụng rộng rãi cho tiếng Việt – sử dụng mạng nơ-ron hồi quy kết hợp với quy tắc suy luận ngược (Backward Inference), đạt độ chính xác trên 98% trên tập dữ liệu VLSP 2013.

Về bài toán phát hiện tin giả nói chung, các nghiên cứu quốc tế đã chỉ ra rằng đây là một vấn đề đa chiều, liên quan đến ngữ nghĩa, phong cách ngôn ngữ, ngữ cảnh lan truyền và tính xác thực của nguồn tin [5]. Các hướng tiếp cận chính bao gồm: (i) dựa trên đặc trưng thủ công (Stylometric, Lexicon-Based) kết hợp với mô hình học máy (Machine Learning — ML) truyền thống; (ii) dựa trên học sâu (BiLSTM, CNN); và (iii) dựa trên mô hình ngôn ngữ tiên huấn luyện (BERT, RoBERTa, PhoBERT) [6]. Các nghiên cứu gần đây như CheckThat! Lab [7] cũng nhấn mạnh tầm quan trọng của việc kiểm tra tính đáng tin cậy

(Check-Worthiness) của thông tin – một tác vụ gần gũi với phát hiện tin giả. Các công trình cụ thể về phát hiện tin giả tiếng Việt được tổng hợp ở Mục 2.7 khi giới thiệu PhoBERT.

Bốn mô hình so sánh trong nghiên cứu được lựa chọn để đại diện cho các mức độ phức tạp khác nhau: LR và SVM (đặc trưng thủ công), BiLSTM (học sâu tuần tự) và PhoBERT (mô hình ngôn ngữ tiền huấn luyện).

2.3 Học máy

2.3.1 Định nghĩa

Học máy (Machine Learning — ML) thuộc lĩnh vực trí tuệ nhân tạo, tập trung vào việc xây dựng các phương pháp giúp máy tính rút ra quy luật từ dữ liệu để thực hiện nhiệm vụ mà không phải xác định thủ công toàn bộ các bước xử lý. Trong phạm vi bài toán phát hiện tin giả, đề án sử dụng phương pháp học có giám sát (Supervised Learning). Với cách tiếp cận này, mô hình được huấn luyện trên tập dữ liệu đã gán nhãn gồm hai lớp tin thật và tin giả, từ đó học được mối quan hệ giữa dữ liệu đầu vào và nhãn tương ứng để phân loại các mẫu dữ liệu chưa biết.

Bên cạnh học có giám sát, học máy còn bao gồm các hướng tiếp cận như học không giám sát (Unsupervised Learning), học bán giám sát (Semi-Supervised Learning) và học tăng cường (Reinforcement Learning). Tuy nhiên, các phương pháp này không thuộc phạm vi nghiên cứu của đề án nên chỉ được đề cập ở mức khái quát.

2.3.2 Một số thuật toán học máy tiêu biểu

2.3.2.1 Logistic Regression (LR)

Logistic Regression (LR) [8] thuộc nhóm các phương pháp học có giám sát, thường được lựa chọn cho những bài toán phân loại gồm hai lớp. Thay vì dự đoán trực tiếp nhãn, LR ước lượng khả năng một mẫu dữ liệu thuộc về lớp dương thông qua hàm sigmoid. Giá trị này được xác định dựa trên tổng có trọng số của các đặc trưng đầu vào cùng với hệ số chệch. Với vector đặc trưng $\mathbf{x} \in \mathbb{R}^d$ và vector trọng số $\mathbf{w} \in \mathbb{R}^d$, xác suất mẫu thuộc lớp $y = 1$ được biểu diễn như sau:

$$P(y = 1 | \mathbf{x}) = \sigma(\mathbf{w}^\top \mathbf{x} + b) = \frac{1}{1 + \exp(-(\mathbf{w}^\top \mathbf{x} + b))}$$

Trong quá trình tối ưu tham số, mô hình sử dụng hàm mất mát *Binary Cross-Entropy* (hay *Log-Loss*) để đánh giá sai lệch giữa xác suất dự đoán và nhãn thực tế:

$$\mathcal{L}(\mathbf{w}) = -\frac{1}{n} \sum_{i=1}^n \left[y_i \log \hat{y}_i + (1 - y_i) \log(1 - \hat{y}_i) \right]$$

trong đó $\hat{y}_i = \sigma(\mathbf{w}^\top \mathbf{x}_i + b)$. Hàm sigmoid đưa giá trị đầu ra về khoảng $(0, 1)$, qua đó cho phép diễn giải kết quả dưới dạng xác suất. Một ưu điểm đáng chú ý của Logistic Regression là tính dễ diễn giải, bởi các hệ số trong vector $\mathbf{w}$ cho biết mức độ ảnh hưởng của từng đặc trưng đến kết quả phân loại. Bên cạnh đó, mô hình có chi phí tính toán tương đối thấp, giúp quá trình huấn luyện và suy diễn diễn ra nhanh chóng.

2.3.2.2 Support Vector Machine (SVM)

Support Vector Machine (SVM) [9] thuộc nhóm các phương pháp học có giám sát, được sử dụng rộng rãi cho các bài toán phân loại. Mục tiêu của SVM là xác định một siêu phẳng (Hyperplane) có khả năng phân chia các lớp dữ liệu


sao cho khoảng cách từ siêu phẳng đến những điểm dữ liệu gần nhất được tối đa hóa. Siêu phẳng này được biểu diễn dưới dạng $\mathbf{w}^\top \mathbf{x} + b = 0$, trong đó $\mathbf{w}$ là vector trọng số và b là hệ số chệch. Xét tập dữ liệu huấn luyện $\mathcal{D} = \{(\mathbf{x}_i, y_i)\}_{i=1}^n$, với $y_i \in \{-1, +1\}$, bài toán tối ưu hóa của SVM được xây dựng như sau:

$$\min_{\mathbf{w}, b} \frac{1}{2} \|\mathbf{w}\|^2 \quad \text{s.t.} \quad y_i(\mathbf{w}^\top \mathbf{x}_i + b) \geq 1, \forall i$$

Đây là trường hợp *hard-margin SVM*, chỉ áp dụng khi dữ liệu tuyến tính phân tách được. Trong thực tế, dữ liệu thường không tuyến tính phân tách hoàn toàn; do đó, SVM sử dụng *soft-margin* với biến slack $\xi_i \geq 0$ cho phép một số điểm vi phạm biên:

$$\min_{\mathbf{w}, b, \xi} \frac{1}{2} \|\mathbf{w}\|^2 + C \sum_{i=1}^n \xi_i \quad \text{s.t.} \quad y_i(\mathbf{w}^\top \mathbf{x}_i + b) \geq 1 - \xi_i, \xi_i \geq 0, \forall i$$

Trong đó, tham số $C > 0$ điều chỉnh sự đánh đổi giữa việc tối đa hóa biên phân tách (margin) và mức phạt đối với các điểm dữ liệu vi phạm biên. Các điểm dữ liệu có $\alpha_i > 0$ trong nghiệm của bài toán đối ngẫu được gọi là *support vectors* (vector hỗ trợ); đây là những điểm dữ liệu đóng vai trò quyết định vị trí của siêu phẳng phân tách. Nhờ cơ chế kernel, SVM có thể ánh xạ dữ liệu sang một không gian đặc trưng có số chiều cao hơn mà không cần biểu diễn tường minh dữ liệu trong không gian này, qua đó cho phép mô hình xử lý hiệu quả các bài toán phân loại có ranh giới quyết định phi tuyến [9]. Kernel RBF (Radial Basis Function) là lựa chọn phổ biến nhất, cho phép mô hình hóa các ranh giới phân lớp phi tuyến trong không gian đặc trưng có số chiều cao.



Hình 2.4: Minh họa thuật toán nhị phân SVM⁴

2.3.3 Biểu diễn đặc trưng cơ bản

2.3.3.1 TF-IDF (Term Frequency – Inverse Document Frequency)

TF-IDF (Term Frequency – Inverse Document Frequency) [10] được sử dụng để chuyển đổi văn bản thành dạng biểu diễn số, qua đó cung cấp đầu vào phù hợp cho các mô hình xử lý và phân loại văn bản. Giá trị của mỗi từ được xác định dựa trên hai yếu tố chính: mức độ xuất hiện của từ trong tài liệu đang xét và tần suất từ đó xuất hiện trên toàn bộ tập dữ liệu. Nhờ kết hợp hai yếu tố này, những từ xuất hiện thường xuyên trong một tài liệu nhưng ít phổ biến ở các tài liệu khác sẽ nhận được trọng số cao hơn, trong khi các từ xuất hiện rộng rãi trong nhiều tài liệu sẽ có mức độ đóng góp thấp hơn.

⁴nguồn ảnh: https://statusneo.com/wp-content/uploads/2023/08/SVM_3-1.png

Term frequency (TF) biểu diễn số lần một từ t xuất hiện trong tài liệu d . Để tránh thiên lệch do độ dài tài liệu, TF thường được chuẩn hóa theo tổng số từ trong tài liệu:

$$TF(T, D) = \frac{f_{t,d}}{\sum_{t' \in d} f_{t',d}}$$

Trong đó $f_{t,d}$ là số lần xuất hiện của từ t trong tài liệu d .

Inverse document frequency (IDF) được sử dụng nhằm giảm trọng số của các từ xuất hiện phổ biến trong nhiều tài liệu và tăng trọng số cho các từ mang tính phân biệt cao. IDF được tính như sau:

$$IDF(T) = \log \left(\frac{N}{df_t} \right)$$

Trong đó N là tổng số tài liệu trong tập dữ liệu và df_t là số tài liệu chứa từ t .

Giá trị TF-IDF của một từ t trong tài liệu d được xác định bằng tích của hai thành phần trên:

$$TF-IDF(T, D) = TF(T, D) \times IDF(T)$$

Kết quả thu được là một trọng số thực phản ánh mức độ quan trọng tương đối của từ trong tài liệu. Sau khi tính toán cho toàn bộ từ vựng, mỗi tài liệu được biểu diễn dưới dạng một vector đặc trưng có kích thước bằng số lượng từ trong từ điển. Các vector này thường có tính thưa (Sparse) và được sử dụng làm đầu vào cho các mô hình học máy truyền thống như Logistic Regression và Support Vector Machine trong các bài toán phân loại văn bản, bao gồm phát hiện tin giả.

Để minh họa cụ thể cách tính toán TF-IDF trên một tập tài liệu nhỏ, Hình 2.5 trình bày ví dụ với hai tài liệu giả định.

TF-IDF Calculation Example							
Words	Count		Term Frequency (TF)		Inverse Document Frequency (IDF)	TF * IDF	
	Document 1	Document 2	Document 1	Document 2		Document 1	Document 2
read	1	1	0.17	0.17	0	0	0
svm	1	0	0.17	0	0.3	0.05	0
algorithm	1	1	0.17	0.17	0	0	0
article	1	1	0.17	0.17	0	0	0
dataaspirant	1	1	0.17	0.17	0	0	0
blog	1	1	0.17	0.17	0	0	0
randomforest	0	1	0	0.17	0.3	0	0.05

Hình 2.5: Ví dụ minh họa cách tính TF-IDF trên hai tài liệu⁵

Từ ví dụ trên các từ xuất hiện trong nhiều tài liệu sẽ có giá trị IDF thấp và do đó trọng số TF-IDF nhỏ, trong khi các từ mang tính đặc trưng cho từng tài liệu sẽ có trọng số cao hơn.

2.4 Học sâu

2.4.1 Định nghĩa

Học sâu (Deep Learning) phát triển từ nền tảng của học máy, trong đó mạng nơ-ron được xây dựng với nhiều tầng xử lý để hình thành các biểu diễn ngày càng phức tạp từ dữ liệu. Một điểm đáng chú ý của phương pháp này là quá trình tìm kiếm đặc trưng có thể được thực hiện trực tiếp trong quá trình huấn luyện, thay vì phụ thuộc hoàn toàn vào các đặc trưng được thiết kế thủ công như trong nhiều phương pháp học máy truyền thống.

Quá trình xử lý của một mô hình học sâu có thể được xem như chuỗi các phép biến đổi liên tiếp. Dữ liệu từ đầu vào lần lượt đi qua các tầng của mạng theo chiều thuận (Feedforward), trong đó mỗi tầng kết hợp phép biến đổi tuyến tính với hàm kích hoạt để tạo nên biểu diễn mới cho dữ liệu. Khi mô hình được huấn luyện, sai số từ kết quả đầu ra được truyền ngược qua mạng bằng thuật toán lan truyền ngược (Backpropagation). Dựa trên sai số này, các tham số của mô hình được cập nhật nhằm làm giảm giá trị hàm mất mát.


⁵ nguồn ảnh: <https://dataaspirant.com/tf-idf-term-frequency-inverse-document-frequency/>

Khả năng xây dựng biểu diễn theo nhiều cấp độ giúp học sâu phù hợp với những dữ liệu có cấu trúc phức tạp và được ứng dụng rộng rãi trong thị giác máy tính, xử lý ngôn ngữ tự nhiên cũng như nhận dạng tiếng nói. Đối với bài toán phát hiện tin giả, việc sử dụng BiLSTM và PhoBERT giúp mô hình khai thác tốt hơn đặc điểm ngữ cảnh của văn bản và mối quan hệ giữa các thành phần ngôn ngữ, từ đó hỗ trợ quá trình phân loại nội dung.

2.4.2 Mạng nơ-ron nhân tạo (Artificial Neural Network)

Dựa trên cơ chế hoạt động của các neuron trong hệ thần kinh sinh học, các nhà nghiên cứu đã xây dựng mô hình mạng nơ-ron nhân tạo nhằm mô phỏng quá trình xử lý thông tin của não người. Trong cơ thể, neuron được xem là đơn vị cấu trúc cơ bản của hệ thần kinh. Mỗi neuron bao gồm thân tế bào chứa nhân, các sợi nhánh (Dendrite) có chức năng tiếp nhận tín hiệu từ các neuron khác và sợi trục (Axon) dùng để truyền tín hiệu đi.


Mạng nơ-ron nhân tạo (Artificial Neural Network, ANN) lấy cảm hứng từ nguyên lý hoạt động của não bộ sinh học. Mỗi neuron nhân tạo nhận nhiều tín hiệu đầu vào, tính tổng có trọng số, rồi đưa qua một hàm kích hoạt (Activation Function) để tạo ra tín hiệu đầu ra. Cơ chế này được mô hình hóa dưới dạng hàm toán học, cho phép mạng học các quan hệ phức tạp trong dữ liệu.



Hình 2.6: Minh họa mạng nơ-ron nhân tạo⁶

Mạng nơ-ron nhân tạo được xây dựng từ các neuron nhân tạo và tổ chức thành nhiều tầng xử lý. Trong một mạng điển hình, dữ liệu được truyền qua các tầng theo thứ tự từ lớp đầu vào đến các lớp ẩn (Hidden Layer) và cuối cùng là lớp đầu ra. Mỗi lớp ẩn có thể chứa số lượng neuron khác nhau; các neuron giữa hai lớp liên kế được kết nối để truyền thông tin, trong khi các neuron thuộc cùng một lớp không kết nối trực tiếp với nhau. Theo cách quy ước này, số lớp của mạng được xác định bằng tổng số lớp đầu vào và các lớp ẩn, còn lớp đầu ra không được tính vào số lớp của mạng.

⁶nguồn ảnh: <http://www.wpclipart.com/medical/anatomy/cells/neuron/neuron.png.html>



Hình 2.7: Minh họa kiến trúc nhiều lớp của mạng nơ-ron nhân tạo⁷

Khi mô hình được huấn luyện, các tham số của mạng được cập nhật dựa trên sai lệch giữa kết quả dự đoán và nhãn thực tế. Dữ liệu được đưa lần lượt qua các tầng của mạng để hình thành đầu ra, sau đó sai số thu được được sử dụng trong quá trình lan truyền ngược (Backpropagation) nhằm xác định hướng điều chỉnh các tham số. Hàm mất mát (Loss Function) đóng vai trò lượng hóa mức độ sai lệch này và là cơ sở để tối ưu mô hình. Các bước tính toán và cập nhật tham số được thực hiện lặp lại qua nhiều vòng huấn luyện cho đến khi mô hình đạt trạng thái phù hợp với dữ liệu.

Tùy thuộc vào dạng dữ liệu và nhiệm vụ cần giải quyết, mạng nơ-ron có thể được phát triển theo nhiều kiến trúc khác nhau. Trong lĩnh vực xử lý văn bản, mạng nơ-ron hồi tiếp (RNN) và các kiến trúc dựa trên Transformer là những hướng tiếp cận được sử dụng phổ biến.

2.4.2.1 Một số thành phần cần chú ý

Hàm kích hoạt (Activation Function) được sử dụng để biến đổi đầu ra của mỗi neuron trước khi thông tin được truyền sang tầng tiếp theo. Sau khi các đặc

⁷nguồn ảnh: www.researchgate.net/figure/A-general-model-of-a-deep-neural...

trung đầu vào được kết hợp với các trọng số và hệ số chệch, hàm kích hoạt sẽ xử lý giá trị thu được để tạo ra biểu diễn đầu ra của neuron. Việc đưa các phép biến đổi phi tuyến vào mạng giúp mô hình có thể biểu diễn những quan hệ phức tạp mà các phép biến đổi tuyến tính đơn thuần khó mô tả.

Một số hàm kích hoạt thường gặp trong mạng nơ-ron gồm Sigmoid, Tanh và ReLU. Tùy vào mục đích sử dụng, mỗi hàm có đặc điểm đầu ra khác nhau. Trong bài toán phân loại nhị phân, Sigmoid thường được lựa chọn ở tầng cuối để chuyển giá trị đầu ra về khoảng $(0, 1)$, từ đó có thể sử dụng như xác suất của một lớp. Với bài toán có nhiều lớp, Softmax có thể được sử dụng để chuyển các giá trị đầu ra thành phân phối xác suất trên các lớp.

Để đánh giá mức độ chính xác của mô hình trong quá trình huấn luyện, hàm mất mát (Loss Function) được sử dụng nhằm đo lường sai số giữa giá trị dự đoán và nhãn thực tế. Trong các bài toán phân loại văn bản, hàm mất mát phổ biến là cross-entropy, do khả năng phản ánh tốt sự khác biệt giữa phân phối xác suất dự đoán và phân phối thực tế. Giá trị của hàm mất mát càng nhỏ thì mô hình càng đưa ra dự đoán gần với nhãn đúng.

Việc tối ưu một mạng nơ-ron được thực hiện bằng cách điều chỉnh dần các tham số của mô hình dựa trên sai lệch giữa kết quả dự đoán và nhãn thực tế. Ở mỗi vòng huấn luyện, dữ liệu được đưa vào mạng để tính toán đầu ra. Giá trị đầu ra này được so sánh với mục tiêu thông qua hàm mất mát, từ đó xác định mức độ sai lệch của mô hình.

Sau khi tính được sai số, thuật toán lan truyền ngược (Backpropagation) được sử dụng để xác định gradient của hàm mất mát đối với các tham số trong mạng. Các gradient này sau đó được sử dụng bởi phương pháp tối ưu như Gradient Descent để điều chỉnh trọng số và hệ số chệch theo hướng làm giảm sai số. Chu trình trên được lặp lại qua nhiều vòng cho đến khi mô hình đạt được kết quả phù hợp.

Đối với các mạng có nhiều tầng, quá trình tối ưu có thể gặp một số vấn đề

như gradient biến mất hoặc gradient bùng nổ. Những hiện tượng này làm cho việc cập nhật tham số trở nên kém hiệu quả và có thể ảnh hưởng đến khả năng hội tụ của mô hình. Các kiến trúc như LSTM được thiết kế với cơ chế đặc biệt nhằm duy trì thông tin qua nhiều bước thời gian, trong khi Transformer sử dụng cơ chế Attention để xử lý mối quan hệ giữa các thành phần trong chuỗi. Nhờ đó, các kiến trúc này có khả năng khai thác thông tin ngữ cảnh hiệu quả trong những bài toán xử lý ngôn ngữ tự nhiên, chẳng hạn như phát hiện tin giả.


2.4.3 Recurrent Neural Networks (RNN)

Mạng nơ-ron hồi quy (Recurrent Neural Networks — RNN) xử lý dữ liệu tuần tự bằng cách duy trì trạng thái ẩn giữa các bước thời gian, cho phép mô hình nắm bắt mối liên hệ giữa các phần tử trong chuỗi. Khác với mạng truyền thẳng xử lý từng đầu vào độc lập, RNN có vòng lặp bên trong truyền tải thông tin qua từng bước.

Hạn chế cố hữu của RNN truyền thống là hiện tượng *vanishing* hoặc *exploding gradient* khi chuỗi đủ dài, làm mô hình khó học các phụ thuộc xa — vốn phổ biến trong văn bản. Để khắc phục, kiến trúc LSTM đã được đề xuất nhằm tăng cường khả năng ghi nhớ dài hạn.

2.4.4 Long Short-Term Memory (LSTM)

LSTM (Long Short-Term Memory) [11] được thiết kế nhằm cải thiện khả năng xử lý thông tin trong các chuỗi có độ dài lớn. Kiến trúc này duy trì một trạng thái bộ nhớ riêng (Memory Cell), đồng thời sử dụng ba cổng gồm cổng quên, cổng đầu vào và cổng đầu ra để điều tiết thông tin đi vào, được lưu giữ hoặc đưa ra khỏi bộ nhớ. Nhờ cơ chế kiểm soát này, mô hình có thể duy trì những thông tin cần thiết qua nhiều bước trong chuỗi thay vì phụ thuộc hoàn toàn vào trạng thái ở bước gần nhất.



Hình 2.8: Minh họa cấu trúc mạng LSTM⁸

Khả năng duy trì thông tin trong thời gian dài giúp LSTM phù hợp với những dữ liệu mà ý nghĩa của một phần tử có thể phụ thuộc vào các thành phần xuất hiện trước đó. Đặc tính này đã khiến LSTM được ứng dụng trong nhiều nhiệm vụ xử lý dữ liệu tuần tự, chẳng hạn như xử lý ngôn ngữ tự nhiên, dịch máy, nhận dạng giọng nói và dự báo chuỗi thời gian.

Một ưu điểm quan trọng của kiến trúc LSTM là cơ chế cập nhật trạng thái giúp giảm tác động của hiện tượng suy giảm gradient khi mạng xử lý các chuỗi dài. Nhờ vậy, LSTM có thể học được mối quan hệ giữa những thông tin cách xa nhau trong chuỗi. Đối với bài toán phân loại văn bản, đặc tính này cho phép mô hình khai thác ngữ cảnh xuyên suốt nội dung và hỗ trợ nhận diện các đặc điểm liên quan đến tin giả.


Trong LSTM, ba cổng kiểm soát luồng thông tin theo các cách khác nhau: cổng quên xác định thông tin cần loại bỏ khỏi bộ nhớ, cổng vào quyết định thông tin mới cần cập nhật, và cổng ra chọn phần thông tin từ bộ nhớ để tạo trạng thái ẩn hiện tại. Sự kết hợp này cho phép LSTM học và ghi nhớ các phụ thuộc dài hạn hiệu quả hơn RNN truyền thống.

⁸nguồn ảnh: towardsdatascience.com/an-introduction-to-long-short-term-me...

LSTM tiêu chuẩn chỉ khai thác ngữ cảnh theo một chiều (từ trái sang phải). Trong khi đó, ngữ nghĩa của một từ thường chịu ảnh hưởng của cả các từ đứng trước lẫn phía sau. Để tận dụng ngữ cảnh hai chiều, kiến trúc bidirectional LSTM đã được đề xuất — nền tảng của mô hình BiLSTM.

2.4.5 Mạng LSTM hai chiều (Bidirectional LSTM)

BiLSTM sử dụng hai hướng xử lý độc lập để khai thác thông tin trong chuỗi. Nhánh thứ nhất tiếp nhận dữ liệu theo thứ tự từ đầu đến cuối, trong khi nhánh còn lại thực hiện quá trình xử lý theo hướng ngược lại. Ở mỗi vị trí trong chuỗi, thông tin thu được từ hai nhánh được tổng hợp, thường thông qua phép nối (Concatenation), tạo thành một biểu diễn chứa thông tin từ cả hai phía của vị trí đang xét. Nhờ đó, mô hình có thể xem xét đồng thời ngữ cảnh xuất hiện trước và sau một từ khi thực hiện phân loại. Trong phạm vi đề tài, đặc tính này hỗ trợ BiLSTM khai thác đầy đủ hơn thông tin ngữ cảnh của văn bản và phân biệt hai nhóm tin “thật” và “giả”.



Hình 2.9: Minh họa cấu trúc mạng LSTM hai chiều⁹

⁹ nguồn ảnh: <https://www.geeksforgeeks.org/nlp/bidirectional-lstm-in-nlp/>

2.4.6 Cơ chế chú ý (Attention Mechanism)

Cơ chế chú ý (Attention Mechanism) [12] được đề xuất nhằm khắc phục hạn chế của các mô hình xử lý chuỗi khi phải nén toàn bộ thông tin của một câu vào một vector duy nhất. Thay vì xem mọi phần tử trong chuỗi có mức độ quan trọng như nhau, cơ chế chú ý cho phép mô hình tự động học trọng số cho từng bước thời gian, từ đó tập trung nhiều hơn vào những thành phần mang thông tin quan trọng đối với nhiệm vụ dự đoán.

Giả sử $\{h_1, h_2, \dots, h_T\}$ là các trạng thái ẩn thu được từ mô hình LSTM hoặc BiLSTM. Tại mỗi bước thời gian t , một điểm số e_t được tính để đo mức độ liên quan của trạng thái ẩn h_t đối với đầu ra cuối cùng:

$$e_t = \mathbf{v}^\top \tanh(\mathbf{W}_a \overleftrightarrow{\mathbf{h}}_t) \quad (2.1)$$

Các điểm số này sau đó được chuẩn hóa thông qua hàm softmax để tạo thành trọng số chú ý α_t :

$$\alpha_t = \frac{\exp(e_t)}{\sum_{k=1}^T \exp(e_k)} \quad (2.2)$$

Cuối cùng, vector ngữ cảnh $\mathbf{c}$ được tính bằng tổng có trọng số của các trạng thái ẩn:

$$\mathbf{c} = \sum_{t=1}^T \alpha_t \overleftrightarrow{\mathbf{h}}_t \quad (2.3)$$

Trong đó, α_t phản ánh mức độ đóng góp của từng từ hoặc từng bước thời gian vào biểu diễn cuối cùng của câu. Những từ quan trọng sẽ nhận được trọng số lớn hơn, trong khi các từ ít liên quan sẽ có trọng số nhỏ hơn. Nhờ đó, mô hình có khả năng tập trung vào các thành phần mang tính quyết định trong văn bản thay vì xử lý toàn bộ chuỗi một cách đồng đều.

Đối với nhiệm vụ phát hiện tin giả, cơ chế chú ý cho phép mô hình tập trung nhiều hơn vào những thành phần có vai trò quan trọng trong việc xác định đặc điểm của một bài viết. Các thông tin như cách diễn đạt, những chi tiết khác thường hoặc các nội dung mang tính gây tranh cãi có thể được mô hình gán mức độ quan tâm khác nhau. Nhờ đó, quá trình phân loại có thể tận dụng tốt hơn các đặc điểm quan trọng của văn bản để phân biệt tin “thật” và tin “giả”.

Một trường hợp đặc biệt của cơ chế này là tự chú ý (Self-Attention), được sử dụng làm thành phần trung tâm trong kiến trúc Transformer và được trình bày cụ thể tại Mục 2.6. Với self-attention, thông tin của một phần tử trong chuỗi được xác định dựa trên mối tương quan của nó với các phần tử còn lại, thay vì chỉ phụ thuộc vào những vị trí lân cận. Cách tiếp cận này giúp tạo ra biểu diễn có khả năng bao quát ngữ cảnh của toàn bộ chuỗi. Để có cơ sở cho việc tìm hiểu Transformer, Mục 2.5 trước đó trình bày các phương pháp biểu diễn phân tán và mã hóa con, là những kỹ thuật được sử dụng trong quá trình biểu diễn đầu vào cho các mô hình như PhoBERT.

2.5 Biểu diễn phân tán và mã hóa con (Distributed & Subword Representations)

Các phương pháp biểu diễn đặc trưng truyền thống như bag-of-words hay TF-IDF (trình bày ở Mục 2.3.3.1) mặc dù đơn giản và hiệu quả với các mô hình tuyến tính, lại mang hai hạn chế cố hữu: (i) *curse of dimensionality* — số chiều vector tăng theo kích thước từ vựng, tạo ra các vector thưa (Sparse) có hàng chục nghìn chiều; và (ii) *orthogonality* — hai từ khác nhau luôn có vector trực giao, không phản ánh được mối quan hệ ngữ nghĩa giữa chúng. Để khắc phục, các phương pháp biểu diễn phân tán (Distributed Representations) đã được đề xuất, trong đó mỗi từ được ánh xạ vào một không gian vector dày đặc có số chiều cố định (thường 50–300), sao cho các từ có ngữ nghĩa tương tự nằm gần

nhau trong không gian.

2.5.1 Word2Vec và GloVe

Word2Vec [2] học biểu diễn vector cho từ thông qua mối quan hệ giữa từ đó với các từ xuất hiện xung quanh trong tập văn bản. Hai cách huấn luyện thường được sử dụng là *continuous bag-of-words* (CBOW) và *skip-gram*. Với CBOW, các từ trong ngữ cảnh được dùng làm cơ sở để suy ra từ mục tiêu, trong khi skip-gram thực hiện theo hướng ngược lại, tức sử dụng từ mục tiêu để dự đoán những từ xuất hiện xung quanh. Kết quả của quá trình huấn luyện là một không gian vector có kích thước d , trong đó mỗi từ trong từ vựng gồm V từ được gán một vector biểu diễn tương ứng, có thể xem dưới dạng ma trận $\mathbf{E} \in \mathbb{R}^{V \times d}$.

Một đặc điểm đáng chú ý của không gian biểu diễn Word2Vec là khoảng cách và hướng giữa các vector có thể phản ánh một số mối quan hệ về mặt ngữ nghĩa. Chẳng hạn, các phép toán trên vector có thể biểu diễn quan hệ tương tự như:

$$\text{vua} - \text{nam} + \text{nữ} \approx \text{hoàng hậu}$$

Tuy nhiên, cách biểu diễn này gán mỗi từ với một vector duy nhất, nên chưa thể phân biệt các ý nghĩa khác nhau của cùng một từ khi nó xuất hiện trong những ngữ cảnh khác nhau. Đây là một hạn chế của Word2Vec đối với những trường hợp từ có nhiều nghĩa (*word-sense ambiguity*).

GloVe [13] tiếp cận bài toán biểu diễn từ theo hướng khai thác đồng thời thông tin về sự xuất hiện của các từ trong toàn bộ tập văn bản. Thay vì chỉ học từ những quan hệ ngữ cảnh cục bộ, phương pháp này sử dụng ma trận đồng xuất hiện (Co-Occurrence Matrix) để đưa thống kê của toàn bộ tập dữ liệu vào quá trình tối ưu. Mối quan hệ giữa từ mục tiêu i và từ ngữ cảnh j được mô hình hóa thông qua biểu thức:

$$\log \hat{P}(i | j) = \mathbf{u}_i^\top \mathbf{v}_j + b_i + b_j$$

trong đó $\hat{P}(i | j)$ biểu thị xác suất quan sát từ i khi xét đến ngữ cảnh của từ j . Việc kết hợp thông tin đồng xuất hiện ở quy mô toàn tập dữ liệu giúp GloVe xây dựng không gian biểu diễn dựa trên các quan hệ thống kê giữa các từ, từ đó hỗ trợ tốt cho những tác vụ yêu cầu đánh giá mức độ tương đồng về ngữ nghĩa.

2.5.2 FastText và thông tin subword

Cả word2vec và GloVe đều có nhược điểm chung: từ hiếm và từ ngoài từ vựng (OOV — Out-Of-Vocabulary) không thể có embedding vì không xuất hiện trong tập huấn luyện. Đối với tiếng Việt — một ngôn ngữ có tính tổng hợp (Agglutinative) và đa dạng biến thể ngữ pháp — vấn đề này đặc biệt nghiêm trọng vì cùng một gốc từ có thể sinh ra hàng chục hình thái khác nhau.

FastText [3] giải quyết vấn đề này bằng cách biểu diễn mỗi từ như là *túi các n-gram ký tự* (Character N-Grams). Cụ thể, với một từ w và tập các n-gram $\mathcal{G}_w \subseteq \{3, 4, \dots, 6\}$, embedding của w được tính:

$$\mathbf{e}_w = \sum_{g \in \mathcal{G}_w} \mathbf{z}_g$$

trong đó $\mathbf{z}_g$ là vector embedding của n-gram g . Nhờ vậy, ngay cả khi một từ chưa từng xuất hiện trong tập huấn luyện, mô hình vẫn có thể tính được embedding của nó từ các n-gram con, giúp tăng độ bao phủ từ vựng và giảm hiện tượng OOV cho các từ ghép ít gặp.

2.5.3 Mã hóa con (Subword Tokenization)

Trong khi FastText dùng n-gram ký tự ở cấp độ từ, các mô hình Transformer hiện đại như BERT [14] và PhoBERT [15] sử dụng BPE (Byte Pair Encoding) [16]

— một thuật toán mã hóa con phổ biến nhất hiện nay. Ý tưởng chính của BPE:

1. Khởi tạo từ vựng bằng tất cả các ký tự xuất hiện trong kho ngữ liệu.
2. Lặp lại K lần: đếm cặp ký hiệu liền kề xuất hiện nhiều nhất, hợp nhất chúng thành một ký hiệu mới và thêm vào từ vựng.
3. Sau K lần hợp nhất, từ vựng gồm $K + |\Sigma|$ token, trong đó $|\Sigma|$ là số ký tự gốc.

Kết quả là một từ vựng cân bằng giữa kích thước và tính bao phủ: các từ phổ biến xuất hiện nguyên vẹn (1 Token), còn các từ hiếm được tách thành vài đơn vị con (Subword) có nghĩa. Ví dụ, từ tiếng Việt khó có thể được biểu diễn bằng $kh + ó$ thay vì một token duy nhất. Điều này giải quyết triệt để bài toán OOV và giảm kích thước từ vựng từ hàng trăm nghìn (từ vựng cấp từ) xuống chỉ vài chục nghìn (từ vựng cấp Subword).

PhoBERT sử dụng BPE được huấn luyện trên kho ngữ liệu tiếng Việt khoảng 20GB [15], cho từ vựng khoảng 64,000 subword. Kết hợp với RDRSegmenter (Mục 2.2.2), PhoBERT có thể biểu diễn hiệu quả cả những từ ghép và từ hán-việt dài mà không cần mở rộng từ vựng.

2.6 Mô hình Transformer và phương thức Self-Attention

Transformer là kiến trúc được xây dựng xoay quanh cơ chế tự chú ý (Self-Attention) [17]. Thay vì phụ thuộc vào quá trình xử lý tuần tự như RNN hay LSTM, kiến trúc này khai thác mối quan hệ giữa các phần tử trong toàn bộ chuỗi để tạo ra biểu diễn đầu vào. Nhờ không phải lần lượt xử lý từng bước thời gian, Transformer có thể thực hiện các phép tính trên nhiều vị trí trong chuỗi cùng lúc, qua đó tận dụng tốt khả năng tính toán song song của GPU và rút

ngắn thời gian huấn luyện [18]. Đặc điểm này cũng giúp mô hình thuận lợi hơn trong việc khai thác các mối quan hệ giữa những thành phần nằm cách xa nhau trong văn bản.

2.6.1 Cơ chế Scaled Dot-Product Attention

Thành phần cốt lõi của Transformer là cơ chế *scaled dot-product attention*. Cho một chuỗi đầu vào, ba ma trận $\mathbf{Q}$ (Query), $\mathbf{K}$ (Key) và $\mathbf{V}$ (Value) được tạo bằng các phép chiếu tuyến tính từ các vector embedding đầu vào. Đầu ra attention được tính:

$$\text{Attention}(\mathbf{Q}, \mathbf{K}, \mathbf{V}) = \text{softmax}\left(\frac{\mathbf{Q}\mathbf{K}^\top}{\sqrt{d_k}}\right) \mathbf{V} \quad (2.4)$$

trong đó d_k là số chiều của vector key. Hệ số chia $\sqrt{d_k}$ có vai trò ổn định gradient khi d_k lớn, tránh hiện tượng softmax rơi vào vùng bão hòa (Saturation) [17]. Trong *self-attention*, ba ma trận $\mathbf{Q}, \mathbf{K}, \mathbf{V}$ đều được chiếu từ cùng một chuỗi đầu vào, cho phép mỗi vị trí tương tác với tất cả các vị trí khác trong cùng một lớp.

2.6.2 Multi-Head Attention và Positional Encoding

Để mô hình có thể đồng thời học nhiều loại quan hệ ngữ nghĩa khác nhau, Transformer sử dụng multi-head attention: thay vì thực hiện một attention duy nhất trên vector d -chiều, đầu vào được chiếu song song h lần vào h không gian con $d_k = d/h$ chiều, attention được tính độc lập trên mỗi không gian, sau đó các đầu ra được nối lại:

$$\text{multihead}(\mathbf{Q}, \mathbf{K}, \mathbf{V}) = \text{concat}(\text{head}_1, \dots, \text{head}_h) \mathbf{W}^O \quad (2.5)$$

trong đó $\text{head}_i = \text{Attention}(\mathbf{Q}\mathbf{W}_i^Q, \mathbf{K}\mathbf{W}_i^K, \mathbf{V}\mathbf{W}_i^V)$.


Vì Self-attention là phép toán bất biến với hoán vị (Permutation-Invariant),

Transformer bổ sung positional encoding để đưa thông tin thứ tự vào chuỗi. Bài báo gốc [17] đề xuất:

$$pe_{(pos, 2i)} = \sin\left(\frac{pos}{10000^{2i/d}}\right) \quad (2.6)$$

$$pe_{(pos, 2i+1)} = \cos\left(\frac{pos}{10000^{2i/d}}\right) \quad (2.7)$$

các hàm lượng giác này cho phép mô hình dễ dàng học quan hệ vị trí tương đối và tổng quát hóa cho các độ dài chuỗi dài hơn độ dài huấn luyện.



Hình 2.10: Minh họa kiến trúc Transformer encoder¹⁰

¹⁰ nguồn ảnh: https://d2l.ai/chapter_attention-mechanisms-and-transformers/transformer.html

https://d2l.ai/chapter_attention-mechanisms-and-transformers/transformer.html

Hình 2.10 minh họa cấu trúc của một khối encoder trong Transformer. Mỗi khối encoder bao gồm hai thành phần chính. Thứ nhất là cơ chế multi-head self-attention, cho phép mỗi từ trong câu tương tác trực tiếp với tất cả các từ khác để tính toán mức độ liên quan. Nhờ đó, mô hình có thể nắm bắt được các quan hệ ngữ nghĩa dài hạn trong văn bản mà không bị giới hạn bởi khoảng cách vị trí. Kết quả của lớp attention được đưa qua bước cộng và chuẩn hóa (add & norm) nhằm ổn định quá trình huấn luyện.

Thứ hai là mạng truyền thẳng theo từng vị trí (Positionwise Feed-Forward Network – FFN), thực hiện các phép biến đổi phi tuyến trên từng vector đầu ra của lớp attention. FFN thường có hai lớp tuyến tính với hàm kích hoạt gelu ở giữa:

$$\text{FFN}(\mathbf{x}) = \mathbf{W}_2 \cdot \text{gelu}(\mathbf{W}_1 \mathbf{x} + \mathbf{b}_1) + \mathbf{b}_2$$

với kích thước lớp ẩn thường gấp 4 lần d . Sau đó, một bước add & norm tiếp theo được áp dụng. Các khối encoder này được xếp chồng L lần (thường $L = 12$ cho BERT-base và $L = 24$ cho BERT-large [14]) nhằm tăng khả năng biểu diễn của mô hình.

2.6.3 Encoder vs Decoder

Kiến trúc Transformer ban đầu bao gồm hai thành phần chính là encoder và decoder [17]:

- Encoder ánh xạ chuỗi đầu vào thành chuỗi biểu diễn ngữ cảnh, sử dụng self-attention hai chiều (mỗi vị trí nhìn thấy tất cả các vị trí khác). Phù hợp cho các tác vụ thuộc nhóm *understanding* như phân loại văn bản, gán nhãn token, trích xuất quan hệ.
- Decoder sử dụng *masked self-attention* (mỗi vị trí chỉ nhìn thấy các vị trí trước đó) kết hợp với *cross-attention* đến đầu ra encoder, phù hợp cho các tác vụ sinh văn bản (Generation) như dịch máy, tóm tắt.

Trong các mô hình ngôn ngữ tiền huấn luyện như BERT [14] và PhoBERT [15], chỉ phần encoder được sử dụng để xây dựng biểu diễn ngữ cảnh cho văn bản. Do đó, trong phạm vi các mô hình so sánh, trọng tâm được đặt vào kiến trúc Transformer encoder.

2.7 PhoBERT và mô hình ngôn ngữ tiền huấn luyện

2.7.1 Tiền huấn luyện (Pre-Training) và tinh chỉnh (Fine-Tuning)

Một trong những đóng góp quan trọng nhất của BERT [14] là xây dựng một framework huấn luyện hai giai đoạn cho phép tận dụng lượng lớn dữ liệu không nhãn:

1. Tiền huấn luyện (Pre-Training): mô hình Transformer encoder được huấn luyện trên kho ngữ liệu lớn với hai nhiệm vụ tự giám sát (Self-Supervised):
 - *Masked Language Modeling* (MLM): một tỷ lệ (thường 15%) token đầu vào bị che ngẫu nhiên, mô hình phải dự đoán lại các token bị che dựa trên ngữ cảnh hai chiều.
 - *Next Sentence Prediction* (NSP): mô hình dự đoán hai câu có liên tiếp trong văn bản gốc hay không, giúp học quan hệ giữa các câu.

Quá trình này rất tốn kém — BERT-base mất khoảng 4 ngày trên 64 GPU TPU [14] — nhưng chỉ thực hiện một lần cho mỗi ngôn ngữ.

2. Tinh chỉnh (Fine-Tuning): sau tiền huấn luyện, chỉ cần thêm một lớp phân loại nhỏ (thường là một lớp tuyến tính) lên trên encoder và huấn luyện tiếp trên dữ liệu có nhãn của tác vụ cụ thể (phát hiện tin giả, phân tích

cảm xúc, trả lời câu hỏi, v.v.). Do phần lớn trọng số đã được khởi tạo tốt, fine-tuning thường chỉ cần 3–10 epoch trên dữ liệu tác vụ [19].

Hai giai đoạn này giải quyết được nghịch lý kinh điển của NLP: *dữ liệu không* *nhân thì rất nhiều nhưng dữ liệu có nhân thì rất đắt*. Các mô hình như BERT, PhoBERT, RoBERTa [20] đều tuân theo paradigm này.

2.7.2 PhoBERT cho tiếng Việt

PhoBERT [15] là mô hình ngôn ngữ tiền huấn luyện đầu tiên được thiết kế đặc thù cho tiếng Việt, dựa trên kiến trúc RoBERTa [20]. So với BERT gốc, RoBERTa có bốn cải tiến quan trọng mà PhoBERT kế thừa:

- Bỏ tác vụ NSP, chỉ giữ MLM;
- Huấn luyện trên dữ liệu lớn hơn nhiều lần (160GB so với 13GB của BERT);
- Sử dụng dynamic masking thay vì static masking;
- Sinh chuỗi dài hơn (lên tới 512 token).

PhoBERT được huấn luyện trên khoảng 20GB văn bản tiếng Việt thu thập từ Wikipedia và các trang báo điện tử. Mô hình này có hai biến thể:

- PhoBERT-base: 12 lớp encoder, $d = 768$, 12 head attention, $\sim 135\text{M}$ tham số.
- PhoBERT-large: 24 lớp encoder, $d = 1024$, 16 head attention, $\sim 370\text{M}$ tham số.

Cả hai biến thể đều sử dụng RDRSegmenter (Mục 2.2.2) để phân đoạn từ trước khi áp dụng BPE, đảm bảo từ vựng và embedding phù hợp với đặc thù tiếng Việt. Biến thể PhoBERT-base thường được lựa chọn trong các nghiên cứu thực nghiệm do cân bằng giữa hiệu năng và tài nguyên tính toán.

2.7.3 Một số công trình liên quan về phát hiện tin giả tiếng Việt

Trước khi PhoBERT xuất hiện, các nghiên cứu về phát hiện tin giả tiếng Việt chủ yếu dựa trên đặc trưng thủ công kết hợp với các mô hình học máy truyền thống [21]. Kể từ khi PhoBERT được công bố, một số nghiên cứu đã chỉ ra rằng fine-tuning PhoBERT mang lại kết quả vượt trội cho tác vụ phát hiện tin giả tiếng Việt. Cụ thể, Luu và cộng sự [22] xây dựng hệ thống *ViFakeDect* dựa trên *PhoBERT-base*, đạt F1-macro khoảng 88% trên tập dữ liệu thu thập thủ công. Tran và cộng sự [23] đề xuất pipeline kết hợp PhoBERT với đặc trưng phong cách ngôn ngữ (Stylometric Features) cho bài toán tin giả tiếng Việt, cho thấy đặc trưng phong cách bổ sung thông tin có giá trị cho PhoBERT. Các nghiên cứu quốc tế tổng quát hơn [5–7] cũng chỉ ra rằng phương pháp dựa trên Transformer đang là hướng tiếp cận chủ đạo cho fake news detection.

2.8 Đánh giá mô hình và phân tích hiệu chuẩn

Chương này trình bày các phương pháp đánh giá mô hình phân loại và phân tích hiệu chuẩn xác suất — những công cụ được sử dụng xuyên suốt các chương thực nghiệm sau.

2.8.1 Các độ đo hiệu năng phân loại

Cho một bài toán phân loại nhị phân với hai lớp *thật* (Negative) và *giả* (Positive), ma trận nhầm lẫn gồm bốn giá trị: *TP* (Tin giả được dự đoán đúng là giả), *TN* (Tin thật được dự đoán đúng là thật), *FP* (Tin thật bị dự đoán nhầm là giả) và *FN* (Tin giả bị dự đoán nhầm là thật). Từ ma trận này, các độ

đo quan trọng gồm:

$$\text{accuracy} = \frac{TP + TN}{TP + TN + FP + FN} \quad (2.8)$$

$$\text{precision} = \frac{TP}{TP + FP} \quad (2.9)$$

$$\text{recall} = \frac{TP}{TP + FN} \quad (2.10)$$

$$F_1 = 2 \cdot \frac{\text{precision} \cdot \text{recall}}{\text{precision} + \text{recall}} \quad (2.11)$$

Trong đó, F_1 nói trên là F_1 cho lớp *Positive* (lớp *giả*). Đối với bài toán có phân phối nhãn chệch lệch, F_1 -macro được định nghĩa là trung bình cộng của F_1 hai lớp:

$$F_1\text{-macro} = \frac{F_1^{(0)} + F_1^{(1)}}{2},$$

với $F_1^{(0)}$ và $F_1^{(1)}$ lần lượt là F_1 của lớp *Negative* (lớp *thật*) và lớp *Positive* (lớp *giả*). Độ đo này có trọng số bằng nhau cho hai lớp nên phản ánh đồng đều hiệu năng trên cả hai lớp.

Trong bài toán phát hiện tin giả có phân phối nhãn chệch lệch (ví dụ 56% thật, 44% giả như trong tập dữ liệu được sử dụng), Accuracy có thể gây hiểu lầm vì mô hình luôn dự đoán lớp đa số cũng đạt kết quả cao. Vì vậy, F_1 -macro — trung bình F_1 của hai lớp có trọng số bằng nhau, theo công thức ở trên — được sử dụng làm độ đo chính. F_1 -macro phản ánh đồng đều hiệu năng trên cả hai lớp và ít bị ảnh hưởng bởi mất cân bằng nhãn.

Bên cạnh đó, diện tích dưới đường cong ROC (ROC-AUC) đo lường khả năng phân biệt tổng thể giữa hai lớp ở mọi ngưỡng quyết định.

2.8.2 Kiểm định thống kê

Để xác nhận sự khác biệt hiệu năng giữa các mô hình có ý nghĩa thống kê, báo cáo sử dụng ba phương pháp bổ sung cho nhau:

- Kiểm định McNemar [24]: Kiểm định tính nhị phân cho hai mô hình trên cùng tập kiểm tra gồm 2.094 mẫu, sử dụng phân phối χ^2 bậc 1 để so sánh số lượng mẫu mà hai mô hình dự đoán khác nhau. Phù hợp với các mô hình học sâu chi phí huấn luyện cao vì không cần k-fold.
- Khoảng tin cậy bootstrap [1]: Lặp lại B lần (thường $B = 1000$), mỗi lần lấy mẫu hoàn lại kích thước n từ tập kiểm tra, tính F_1 trên mẫu bootstrap, rồi dựng khoảng tin cậy 95% theo phương pháp percentile. Cho biết độ ổn định ước lượng.
- Kiểm tra chéo (Cross-Validation) [25]: Chia dữ liệu thành k fold, huấn luyện trên $k - 1$ fold và đánh giá trên fold còn lại. Khi so sánh nhiều mô hình, kiểm định Holm [26] được áp dụng để hiệu chỉnh p-value đa so sánh.

2.8.3 Hiệu chuẩn xác suất (Probability Calibration)

Một mô hình phân loại tốt không chỉ cần dự đoán đúng nhãn mà còn cần ước lượng xác suất đầu ra phản ánh đúng xác suất thực sự. Một mô hình được gọi là *hiệu chuẩn tốt* (Well-Calibrated) nếu với mọi xác suất dự đoán p , tỷ lệ nhãn đúng trong số các dự đoán có xác suất gần p cũng xấp xỉ p . Ví dụ, trong số các dự đoán có $p = 0,8$, khoảng 80% nên đúng [27].

Trong bài toán phát hiện tin giả, hiệu chuẩn đặc biệt quan trọng vì hệ thống thường được sử dụng như một công cụ hỗ trợ quyết định (Decision Support): biên tập viên cần biết mô hình *tin bao nhiêu* vào dự đoán của nó, chứ không chỉ dự đoán đúng/sai. Các độ đo hiệu chuẩn phổ biến gồm:

- Expected Calibration Error (ECE) [28]: Chia khoảng $[0, 1]$ thành B bin đều nhau, tính trung bình có trọng số của hiệu giữa độ chính xác trong mỗi bin và độ tự tin trung bình của bin đó:

$$\text{ECE} = \sum_{b=1}^B \frac{|B_b|}{n} |\text{acc}(B_b) - \text{conf}(B_b)|$$

- Maximum Calibration Error (MCE): Giá trị lớn nhất của hiệu $|\text{acc}(B_b) - \text{conf}(B_b)|$ trên các bin — phản ánh sai lệch tệ nhất.

- Brier Score: Trung bình bình phương sai lệch giữa xác suất dự đoán và nhãn nhị phân:

$$\text{Brier} = \frac{1}{N} \sum_{i=1}^N (p_i - y_i)^2$$

trong đó $p_i \in [0, 1]$ là xác suất dự đoán và $y_i \in \{0, 1\}$ là nhãn thực. Giá trị càng nhỏ càng tốt.

Các độ đo trên và kỹ thuật hiệu chỉnh sau huấn luyện (Platt scaling, Temperature scaling, Isotonic regression) [27] sẽ được sử dụng trong các chương thực nghiệm (phương pháp được trình bày ở Mục 4.7) để đánh giá chất lượng xác suất đầu ra của bốn mô hình so sánh.

2.9 Kết luận chương

Chương này đã trình bày nền tảng lý thuyết xuyên suốt tám mục cho bốn mô hình so sánh trong nghiên cứu. Mục 2.1 giới thiệu khái niệm văn bản, đặc trưng và bài toán phân loại nhị phân. Mục 2.2 trình bày đặc điểm ngôn ngữ tiếng Việt cùng các phương pháp biểu diễn số được sử dụng trong nghiên cứu. Mục 2.3 mô tả các thuật toán học máy kinh điển (Logistic Regression và Support Vector Machine) và phương pháp trích xuất đặc trưng TF-IDF. Mục 2.4 trình bày học sâu, mạng nơ-ron nhân tạo, RNN/LSTM và cơ chế chú ý — tiền đề cho các kiến trúc Transformer hiện đại. Mục 2.5 đi sâu vào biểu diễn phân tán (Word2Vec, GloVe, FastText) và mã hóa con (BPE). Mục 2.6 phân tích chi tiết kiến trúc Transformer và cơ chế self-attention. Mục 2.7 trình bày PhoBERT và paradigm tiền huấn luyện — tinh chỉnh, đồng thời tổng quan các công trình liên quan về phát hiện tin giả tiếng Việt. Cuối cùng, Mục 2.8 giới thiệu các độ đo đánh giá, kiểm định thống kê và phân tích hiệu chuẩn xác suất — các công cụ sẽ được

sử dụng xuyên suốt các chương thực nghiệm. Từ LR tuyến tính đến SVM phi tuyến, từ BiLSTM tuần tự đến Transformer song song, mỗi mô hình phản ánh một giai đoạn phát triển của NLP. Chương tiếp theo mô tả bộ dữ liệu và quy trình tiền xử lý.

Chương 3

BỘ DỮ LIỆU VÀ TIỀN XỬ LÝ

3.1 Thu thập và mô tả bộ dữ liệu

3.1.1 Nguồn dữ liệu


Bộ dữ liệu bao gồm các bài viết tiếng Việt được thu thập từ hai nguồn chính: các bài đăng công khai trên facebook và một số bài báo cũ trong thời gian diễn ra COVID-19. Mỗi bản ghi chứa tối thiểu hai trường chính:

- **text**: Nội dung văn bản của bài viết.
- **label**: Nhãn phân loại (0 = thật, 1 = Giả).

Sau khi thực hiện bước phân đoạn từ (word segmentation), dữ liệu được lưu lại và được sử dụng làm đầu vào cho quá trình làm sạch và chia tập.

Tổng số bản ghi ban đầu của bộ dữ liệu là 15.789 mẫu.

3.1.2 Phân phối nhân



Hình 3.1: Phân phối nhân theo từng tập dữ liệu và tổng quan toàn bộ 15.789 mẫu

Hình 3.1 minh họa phân phối nhân tổng thể của toàn bộ tập dữ liệu. Có thể thấy, tỷ lệ tin thật và tin giả khá cân bằng, giúp đảm bảo mô hình không bị thiên lệch về một phía trong quá trình huấn luyện và đánh giá. Sự cân bằng này là yếu tố quan trọng để kết quả thực nghiệm phản ánh đúng hiệu quả của các phương pháp phân loại, đặc biệt trong bối cảnh dữ liệu thực tế thường có sự chênh lệch giữa các lớp.

3.2 Tiền xử lý văn bản

3.2.1 Làm sạch và lọc dữ liệu

Trước khi thực hiện bước chia tập huấn luyện, dữ liệu được tiến hành làm sạch nhằm loại bỏ nhiễu và hạn chế nguy cơ rò rỉ thông tin. Quy trình làm sạch bao gồm các bước sau:

1. Loại bỏ văn bản trùng lặp: Các bản ghi có nội dung text giống hệt nhau được loại bỏ, chỉ giữ lại lần xuất hiện đầu tiên.
2. Loại bỏ văn bản rỗng hoặc giá trị thiếu: Các bản ghi có trường text bị thiếu (Nan) hoặc chuỗi rỗng sau khi loại bỏ khoảng trắng được loại khỏi tập dữ liệu.
3. Loại bỏ văn bản quá ngắn: Những văn bản có ít hơn 10 từ bị loại bỏ do không cung cấp đủ thông tin ngữ nghĩa cho bài toán phân loại. Ngưỡng này được cấu hình thông qua tham số `min_word_count = 10`.
4. Đặt lại chỉ mục (Index Reset): Sau khi hoàn tất các bước trên, dữ liệu được đánh lại chỉ mục nhằm đảm bảo tính nhất quán và thuận tiện cho quá trình xử lý tiếp theo.

Sau quá trình làm sạch:

- Số mẫu ban đầu: 15.789
- Số mẫu bị loại bỏ: 1.831
- Số mẫu còn lại: 13.958

Quy trình làm sạch này giúp giảm nhiễu dữ liệu và đảm bảo rằng quá trình huấn luyện cũng như đánh giá mô hình không bị ảnh hưởng bởi các bản ghi trùng lặp hoặc không hợp lệ.

3.2.2 Phân đoạn từ bằng VnCoreNLP

Khác với nhiều ngôn ngữ mà ranh giới từ có thể được xác định tương đối trực tiếp từ khoảng trắng, tiếng Việt có sự khác biệt giữa đơn vị âm tiết và đơn vị từ. Một từ có thể được tạo thành từ nhiều âm tiết, chẳng hạn “Việt Nam”, trong khi các âm tiết của từ vẫn được viết cách nhau bằng khoảng trắng. Vì vậy, nếu sử dụng trực tiếp từng âm tiết như một từ riêng biệt, thông tin về cấu trúc và ý nghĩa của các đơn vị từ có thể không được biểu diễn đầy đủ. Phân đoạn từ do đó được thực hiện trước các bước biểu diễn dữ liệu nhằm xác định các đơn vị từ phù hợp với đặc trưng của tiếng Việt.

Đối với dữ liệu trong nghiên cứu, việc phân đoạn được thực hiện thông qua thư viện `py_vncorenlp` với bộ tách từ `RDRSegmenter` của VnCoreNLP [4, 29]. Lựa chọn này giúp quá trình chuẩn bị dữ liệu phù hợp với cách thức xử lý văn bản được sử dụng khi xây dựng PhoBERT. Việc thống nhất phương pháp phân đoạn giữa dữ liệu đầu vào và mô hình tiền huấn luyện giúp hạn chế sự khác biệt trong cách xác định đơn vị từ, qua đó đảm bảo tính tương thích khi đưa văn bản vào mô hình và hỗ trợ khả năng tổng quát hóa.

Quy trình phân đoạn được triển khai theo các bước sau:

- Tự động tải và lưu trữ mô hình `vncorenlp` tại thư mục cục bộ (`.vncorenlp`) nếu chưa tồn tại.

- Thực hiện phân đoạn đối với cả hai trường `title` và `text`.
- Chuẩn hóa văn bản trước khi phân đoạn, bao gồm:
 - Loại bỏ dấu gạch dưới phát sinh từ các lần phân đoạn trước (nếu có).
 - Chuẩn hóa khoảng trắng nhằm đảm bảo tính đồng nhất định dạng.

3 Kết quả sau khi phân đoạn được biểu diễn bằng cách nối các âm tiết thuộc cùng một từ thông qua dấu gạch dưới. Chẳng hạn, với câu “em bé đang ăn bánh ngọt”, kết quả xử lý có thể được minh họa như sau:

trước: “em bé đang ăn bánh ngọt”

sau: “em bé đang ăn bánh_ngọt”

183 Trong trường hợp này, các từ đơn vẫn được giữ nguyên, còn những từ được
151 cấu thành từ nhiều âm tiết sẽ được liên kết bằng dấu gạch dưới. Cách biểu diễn
này giúp xác định rõ đơn vị từ sau khi phân đoạn và tạo đầu vào phù hợp cho
các bước xử lý tiếp theo. Đặc biệt, việc thống nhất cách phân đoạn với dữ liệu
được sử dụng trong quá trình tiền huấn luyện giúp văn bản đầu vào tương thích
tốt hơn với cơ chế *subword tokenization* của PhoBERT, qua đó hạn chế sai lệch
trong quá trình biểu diễn và cải thiện tính ổn định khi huấn luyện cũng như suy
diễn.

96 3.3 Chia tập dữ liệu

3.3.1 Chia phân tầng

4 Dữ liệu sau bước phân đoạn được tiếp tục xử lý qua công đoạn làm sạch,
16 sau đó mới được phân chia thành ba tập phục vụ các mục đích khác nhau, gồm
Train, Validation và Test. Trong đó, tập Train được sử dụng để huấn luyện mô

4 hình, Validation hỗ trợ quá trình đánh giá và điều chỉnh, còn Test được giữ lại để đánh giá khả năng tổng quát hóa sau cùng.

13 Việc chia tập được thực hiện theo chiến lược phân tầng (*stratified split*) nhằm duy trì phân phối nhãn đồng đều trong cả ba tập. Cấu hình chia tập như sau:

- Train: 70%
- Validation: 15%
- Test: 15%
- `random_state = 42`

6 Quy trình chia được thực hiện theo hai bước. Đầu tiên, 15% dữ liệu được tách ra làm tập kiểm tra (Test Set). sau đó, từ 85% dữ liệu còn lại, tiếp tục tách một phần tương ứng 15% tổng dữ liệu ban đầu (xấp xỉ 17,6% của phần còn lại) để tạo tập kiểm định (Validation Set).


Tham số `stratify = label` đảm bảo rằng phân phối nhãn được bảo toàn giữa các tập:

$$P_{\text{train}}(Y) \approx P_{\text{val}}(Y) \approx P_{\text{test}}(Y)$$

12 Nhờ đó, sai lệch phân phối nhãn giữa các tập được hạn chế, giúp quá trình đánh giá mô hình phản ánh chính xác hơn khả năng tổng quát hóa.

Kết quả chia tập cuối cùng:

- Train: 9.770 mẫu
- Validation: 2.094 mẫu
- Test: 2.094 mẫu



Hình 3.2: Phân phối nhãn trong các tập dữ liệu huấn luyện, kiểm định và kiểm tra

Bảng 3.1 mô tả thống kê chi tiết sau khi chia tập:

Bảng 3.1: Thống kê tập dữ liệu

tập	tổng	<i>tin thật</i>	<i>tin giả</i>	độ dài tb
huấn luyện	9.770	5.434(55,6%)	4.336(44,4%)	90,1
xác thực	2.094	1.165(55,6%)	929(44,4%)	91,7
kiểm tra	2.094	1.165(55,6%)	929(44,4%)	96,5

Bảng 3.1 trình bày số lượng mẫu, phân phối nhãn và độ dài trung bình của văn bản trong từng tập dữ liệu. Có thể thấy rằng tin thật chiếm 55,6% và tin giả chiếm 44,4% ở cả ba tập (huấn luyện, kiểm định và kiểm tra), cho thấy chiến lược chia dữ liệu theo phương pháp phân tầng (*stratified split*) đã bảo toàn phân phối nhãn ban đầu giữa ba tập.

Độ dài trung bình của văn bản trong tập kiểm định và kiểm tra (91,7 từ đối với tập kiểm định và 96,5 từ đối với tập kiểm tra) cao hơn nhẹ so với tập huấn luyện (90,1 từ), phản ánh sự đa dạng về cấu trúc văn bản trong toàn bộ dữ liệu.

Mặc dù tồn tại sự mất cân bằng lớp ở mức vừa phải, tỷ lệ này không quá nghiêm trọng và được xử lý thông qua cơ chế trọng số lớp (*class weighting*) trong quá trình huấn luyện nhằm giảm thiểu sai lệch dự đoán.

3.3.2 Kiểm tra rò rỉ dữ liệu

Toàn bộ nội dung văn bản trong từng tập (Train, Validation, Test) được chuyển đổi thành các tập hợp (*set*) dựa trên giá trị của trường `text`. Sau đó, đề tài này thực hiện phép giao giữa từng cặp tập dữ liệu nhằm phát hiện các bản ghi trùng lặp:

- Train và Validation
- Train và Test
- Validation và Test

Kết quả cho thấy:

$$\text{train} \cap \text{Validation} = \emptyset$$

$$\text{train} \cap \text{test} = \emptyset$$

$$\text{Validation} \cap \text{test} = \emptyset$$

Không phát hiện văn bản trùng lặp giữa bất kỳ cặp tập dữ liệu nào.

Việc kiểm tra rò rỉ dữ liệu đặc biệt quan trọng trong các bài toán phân loại văn bản, bởi sự xuất hiện của các mẫu trùng lặp giữa tập huấn luyện và tập kiểm tra có thể dẫn đến đánh giá thiên lệch (*biased evaluation*). Khi đó, mô hình có thể đạt hiệu năng cao một cách giả tạo do đã “ghi nhớ” nội dung từ tập huấn luyện, thay vì thực sự học được các đặc trưng có khả năng tổng quát hóa. Do đó, việc đảm bảo tính độc lập giữa các tập dữ liệu là điều kiện tiên quyết để đánh giá chính xác năng lực của mô hình.

3.4 Kết luận chương

Chương này đã trình bày toàn bộ quy trình chuẩn bị dữ liệu cho bài toán phát hiện tin giả tiếng Việt, bao gồm phân đoạn từ, làm sạch và chia tập theo chiến lược phân tầng. Dữ liệu được phân đoạn bằng RDRSegmenter nhằm đảm bảo tính tương thích với mô hình PhoBERT, sau đó được loại bỏ các văn bản trùng lặp, rỗng hoặc quá ngắn nhằm giảm nhiễu và nâng cao chất lượng đầu vào.

Tập dữ liệu sau làm sạch được chia theo tỷ lệ 70%-15%-15% cho các tập huấn luyện, kiểm định và kiểm tra với `random_state = 42`. Đồng thời, hệ thống tiến hành kiểm tra nghiêm ngặt rò rỉ dữ liệu giữa các tập để đảm bảo không tồn tại giao nhau về nội dung văn bản.

Quy trình này đảm bảo tính nhất quán, khách quan và khả năng tái lập (*reproducibility*), tạo nền tảng vững chắc cho quá trình huấn luyện và đánh giá mô hình ở chương tiếp theo.

Chương 4

XÁC ĐỊNH TIN GIẢ

Chương này trình bày cơ sở và định hướng phương pháp cho bài toán phát hiện tin giả bằng tiếng Việt. Trước hết, nội dung tập trung làm rõ bài toán nghiên cứu và cách tiếp cận được lựa chọn. Tiếp theo, các phương pháp và mô hình được sử dụng trong đề tài sẽ được giới thiệu, từ những kỹ thuật học máy truyền thống đến các kiến trúc học sâu và mô hình ngôn ngữ tiên huấn luyện. Phần cuối chương khái quát nguyên lý hoạt động của những phương pháp này, tạo nền tảng cho các nội dung thực nghiệm được trình bày ở những chương sau.

4.1 Phương pháp đề xuất

Phát hiện tin giả tiếng Việt đặt ra một bài toán đáng quan tâm trong xử lý ngôn ngữ tự nhiên, đặc biệt khi lượng nội dung được chia sẻ trên môi trường trực tuyến ngày càng lớn. Những thông tin không chính xác nếu được lan truyền rộng rãi có thể tác động đến cách tiếp nhận thông tin của người dùng cũng như gây ra nhiều hệ quả đối với xã hội. Điều này tạo động lực cho việc xây dựng và đánh giá các phương pháp có khả năng tự động nhận diện nội dung sai lệch.

Một hướng tiếp cận phổ biến là chuyển văn bản sang dạng biểu diễn phù hợp trước khi đưa vào mô hình phân loại. Các phương pháp như *bag-of-words*, TF-IDF và *word embedding* cung cấp những cách khác nhau để mã hóa đặc trưng

của văn bản. Song song với đó, sự phát triển của học sâu đã mở ra các phương pháp có khả năng khai thác thông tin ngữ cảnh trực tiếp từ dữ liệu. Trong nhóm này, các mạng nơ-ron hồi tiếp và mô hình ngôn ngữ dựa trên Transformer đã được áp dụng rộng rãi cho nhiều nhiệm vụ xử lý ngôn ngữ và cho thấy tiềm năng trong việc phân loại văn bản.

Dựa trên những hướng tiếp cận trên, đề tài xây dựng một quy trình thực nghiệm nhằm đánh giá và đối chiếu khả năng phát hiện tin giả của các nhóm mô hình khác nhau. Nhóm phương pháp truyền thống sử dụng đặc trưng được trích xuất từ văn bản kết hợp với Logistic Regression và SVM, trong khi nhóm học sâu được đại diện bởi BiLSTM và PhoBERT. Việc đặt các phương pháp này trong cùng một quy trình đánh giá cho phép phân tích sự khác biệt về hiệu năng giữa cách tiếp cận dựa trên đặc trưng thủ công và các mô hình có khả năng học biểu diễn từ dữ liệu.

4.2 Lý do lựa chọn các nhóm mô hình

Trong bài toán phân loại văn bản, đặc biệt là phát hiện tin giả, việc lựa chọn mô hình cần cân bằng giữa ba yếu tố chính:

- Khả năng diễn giải của mô hình
- Chi phí tính toán
- Năng lực biểu diễn ngữ nghĩa

Dựa trên các tiêu chí này, nghiên cứu so sánh hai nhóm phương pháp chính:

1. Nhóm học máy truyền thống, bao gồm:

- Logistic Regression
- Support Vector Machine

Đầu vào của các mô hình này là đặc trưng TF-IDF [10]. Hai mô hình có nền tảng lý thuyết vững chắc, hoạt động ổn định trên dữ liệu văn bản có đặc trưng chiều cao và thưa, đồng thời thuận lợi cho việc phân tích đóng góp của đặc trưng và kiểm soát hiện tượng quá khớp [9]. Vì vậy, chúng được sử dụng như các *strong baselines* nhằm đánh giá mức cải thiện thực sự của các phương pháp phức tạp hơn.

2. Nhóm học sâu, bao gồm:

- BiLSTM
- PhoBERT

BiLSTM tận dụng hai hướng xử lý của mạng LSTM để khai thác thông tin từ cả hai phía của chuỗi. Khi được bổ sung cơ chế *attention*, mô hình có khả năng gán mức độ quan trọng khác nhau cho các thành phần trong văn bản, qua đó hỗ trợ lựa chọn những thông tin hữu ích cho quá trình phân loại [11, 12].

Đối với PhoBERT, đây là mô hình ngôn ngữ được huấn luyện trước trên dữ liệu tiếng Việt và phát triển dựa trên kiến trúc Transformer/RoBERTa [15, 17, 20]. Nhờ sử dụng biểu diễn ngữ cảnh được học từ quá trình tiền huấn luyện, PhoBERT có khả năng nắm bắt thông tin ngữ nghĩa của văn bản ở nhiều mức độ khác nhau. Đặc điểm này giúp mô hình phù hợp với các nhiệm vụ phân loại và xử lý văn bản tiếng Việt.

Việc đánh giá hai nhóm phương pháp trong cùng một thiết lập thực nghiệm tạo cơ sở để phân tích ba vấn đề trọng tâm của nghiên cứu:

1. Khả năng đạt được kết quả cạnh tranh của các mô hình phân loại truyền thống khi sử dụng những đặc trưng văn bản phù hợp.
2. Mức độ cải thiện khi chuyển từ đặc trưng TF-IDF sang biểu diễn ngữ cảnh được học bởi các mô hình học sâu.

3. Hiệu quả mà mô hình PhoBERT mang lại khi tận dụng tri thức ngôn ngữ tiếng Việt đã được học trước trong bài toán phát hiện tin giả trên dữ liệu thực tế.

4.3 Tổng quan kiến trúc hệ thống

Quy trình xử lý của hệ thống được tổ chức thành ba bước liên tiếp, từ chuẩn bị dữ liệu đến huấn luyện và đánh giá mô hình:

1. Tiền xử lý dữ liệu: Trước khi đưa vào các mô hình, văn bản được chuẩn hóa và loại bỏ những thành phần không cần thiết, đồng thời thực hiện phân đoạn từ tiếng Việt. Dữ liệu sau đó được phân chia thành ba phần gồm tập huấn luyện, tập kiểm định và tập kiểm tra theo tỷ lệ đã xác định. Cách tổ chức này giúp tách biệt dữ liệu dùng cho huấn luyện với dữ liệu phục vụ đánh giá.
2. Biểu diễn dữ liệu: Cách chuyển đổi văn bản sang dạng đầu vào phụ thuộc vào kiến trúc của từng mô hình. Logistic Regression và SVM sử dụng vector TF-IDF, trong khi BiLSTM tiếp nhận các biểu diễn từ được xây dựng bằng FastText. Đối với PhoBERT, văn bản được mã hóa bằng phương pháp BPE (*byte-pair encoding*), sau đó được đưa vào mô hình để khai thác các biểu diễn ngữ cảnh được học từ quá trình tiền huấn luyện.
3. Huấn luyện và đánh giá: Logistic Regression, SVM, BiLSTM và PhoBERT được huấn luyện riêng biệt trong cùng điều kiện dữ liệu để tạo cơ sở cho việc đối chiếu. Hiệu quả phân loại của từng mô hình được xem xét thông qua các thước đo *accuracy*, *F1-score* và *ROC-AUC*. Kết quả cuối cùng được sử dụng để phân tích sự khác biệt về hiệu năng giữa các phương pháp.

4.4 Trích xuất đặc trưng

4.4.1 TF-IDF cho mô hình học máy truyền thống

4.4.1.1 Lý do lựa chọn TF-IDF

TF-IDF là một cách biểu diễn văn bản dựa trên thông tin về mức độ xuất hiện của từ trong từng tài liệu và trên toàn bộ tập dữ liệu. Kết quả thu được là các vector thưa (*sparse vectors*), trong đó mỗi thành phần tương ứng với một đặc trưng từ vựng và mang một trọng số nhất định. Cách biểu diễn này đặc biệt phù hợp với các bộ phân loại tuyến tính như Logistic Regression và Support Vector Machine (SVM), do các mô hình này có thể khai thác trực tiếp những đặc trưng có tính phân biệt trong không gian vector.

So với các phương pháp biểu diễn có khả năng mô hình hóa ngữ cảnh như *word embedding* hoặc các mô hình ngôn ngữ tiên huấn luyện, TF-IDF không cung cấp thông tin ngữ nghĩa ở mức sâu. Tuy nhiên, phương pháp này vẫn có giá trị trong các bài toán phân loại văn bản nhờ khả năng làm nổi bật những đặc trưng từ vựng mang tính đặc trưng cho từng lớp. Vì vậy, TF-IDF thường được sử dụng làm cơ sở đối chứng để đánh giá mức độ cải thiện của các phương pháp biểu diễn phức tạp hơn.

Đối với phát hiện tin giả, nhiều đặc điểm trong cách sử dụng ngôn ngữ có thể mang thông tin hữu ích cho quá trình phân loại, chẳng hạn các cụm từ thường xuất hiện trong tiêu đề, cách diễn đạt nhằm thu hút sự chú ý hoặc những từ khóa có tính đặc trưng. Việc sử dụng các đặc trưng n-gram cùng TF-IDF cho phép mô hình khai thác những tín hiệu này thay vì chỉ xét từng từ riêng lẻ. Trong nghiên cứu này, biểu diễn TF-IDF được kết hợp với Logistic Regression và SVM để xây dựng nhóm mô hình đối chứng, qua đó làm cơ sở so sánh với BiLSTM và PhoBERT.

4.4.1.2 Cấu hình TF-IDF

Để đảm bảo hiệu quả biểu diễn đặc trưng cho các mô hình học máy truyền thống, cấu hình TF-IDF được lựa chọn dựa trên kết quả *ablation study* (Mục 5.4) nhằm tối ưu hóa hiệu năng phân loại. Cụ thể, các siêu tham số được xác định như sau:

- Kích thước từ điển: Số lượng đặc trưng được giới hạn ở 40.000 từ/ngữ phổ biến nhất, giúp giảm nhiễu và kiểm soát độ phức tạp của mô hình.
- N-gram: Sử dụng kết hợp đơn từ (Unigram) và bigram (N-Gram = (1,2)) nhằm khai thác cả thông tin ngữ nghĩa đơn lẻ và các cụm từ liên tiếp, từ đó tăng khả năng nhận diện các mẫu ngữ cảnh đặc trưng của tin giả.
- Tần số tài liệu: Các từ xuất hiện quá ít ($\text{min_df}=5$) hoặc quá phổ biến ($\text{max_df}=0.95$) đều bị loại bỏ, đảm bảo chỉ giữ lại các đặc trưng có giá trị phân biệt cao.
- TF sublinear: Áp dụng phép biến đổi $\text{TF} = 1 + \log f_{t,d}$ nhằm giảm ảnh hưởng của các từ xuất hiện nhiều lần trong cùng một văn bản, giúp mô hình tập trung vào sự hiện diện của từ hơn là tần suất tuyệt đối.

Việc lựa chọn các tham số này được thực hiện một cách hệ thống nhằm cân bằng giữa khả năng biểu diễn đặc trưng và nguy cơ quá khớp, đồng thời đảm bảo tính tổng quát hóa của mô hình trên các tập dữ liệu kiểm định và kiểm tra.

4.4.2 Word Embedding cho BiLSTM

Để phục vụ cho mô hình BiLSTM, biểu diễn văn bản được thực hiện thông qua kỹ thuật word embedding kết hợp giữa embedding tiền huấn luyện và học từ dữ liệu. Từ điển được xây dựng dựa trên toàn bộ tập train, loại bỏ các từ xuất hiện dưới 2 lần nhằm giảm nhiễu và kiểm soát kích thước không gian từ vựng, kết quả thu được 23.166 từ.

Hai token đặc biệt được bổ sung: <pad> (Index 0) dùng để đệm các chuỗi ngắn và <unk> (Index 1) đại diện cho các từ ngoài từ điển. Mỗi văn bản sau tiền xử lý được chuyển đổi thành một chuỗi số nguyên với độ dài tối đa 128, đảm bảo tính nhất quán về kích thước đầu vào cho mô hình tuần tự.

Các vector embedding có chiều 300 được khởi tạo từ bộ embedding tiền huấn luyện FastText [3] phiên bản tiếng Việt (cc.vi.300.bin). FastText sử dụng thông tin n-gram ký tự để xây dựng biểu diễn từ, cho phép xử lý hiệu quả các từ ngoài từ điển bằng cách tổng hợp vector của các n-gram thành phần. Ma trận embedding tiền huấn luyện được nạp vào lớp embedding của mô hình và tiếp tục được tinh chỉnh trong quá trình huấn luyện thông qua lan truyền ngược, cho phép mô hình điều chỉnh biểu diễn ngữ nghĩa phù hợp với nhiệm vụ phân loại tin giả. Việc kết hợp embedding tiền huấn luyện với fine-tuning giúp tận dụng tri thức ngôn ngữ học được từ ngữ liệu lớn (Common Crawl), đồng thời thích ứng tốt với đặc thù dữ liệu tiếng Việt trong miền bài toán.

4.4.3 Tokenization PhoBERT (BPE)

Quá trình mã hóa đầu vào cho PhoBERT sử dụng thuật toán byte-pair encoding (BPE) [16] với từ điển gồm 64.000 subword, cho phép mô hình xử lý hiệu quả các từ ngoài từ điển và hiện tượng đa hình trong tiếng Việt. Mỗi văn bản được tiền xử lý như sau:

- Thêm token đặc biệt [cls] ở đầu và [sep] ở cuối chuỗi để đánh dấu ranh giới văn bản.
- Chuỗi token được cắt hoặc đệm về độ dài cố định 256 nhằm đảm bảo tính nhất quán đầu vào.
- Sinh attention_mask để phân biệt token thực (1) và token đệm (0), hỗ trợ quá trình attention trong mô hình.

Chiến lược này giúp PhoBERT tận dụng tối đa thông tin ngữ cảnh và đảm bảo khả năng tổng quát hóa trên dữ liệu tiếng Việt đa dạng.

4.5 Các mô hình phân loại

4.5.1 Các mô hình học máy truyền thống

4.5.1.1 Hồi quy Logistic

Mô hình hồi quy Logistic sử dụng điều chuẩn L2 nhằm hạn chế quá khớp và áp dụng cơ chế cân bằng lớp (`class_weight='balanced'`) để xử lý mất cân bằng nhãn. Các siêu tham số được lựa chọn thông qua gridsearchcv 5-fold, đảm bảo tính khách quan và tổng quát hóa:

- Lưới tìm kiếm: $C \in \{0,5; 1; 5; 10; 20; 50\}$, $\text{solver} \in \{\text{liblinear}, \text{saga}\}$
- Cấu hình tối ưu: $C = 10$, $\text{solver} = \text{saga}$, $\text{max_iter} = 3000$

Việc lựa chọn này giúp mô hình đạt hiệu năng tốt nhất trên tập kiểm định mà không bị phụ thuộc vào phân phối nhãn.

4.5.1.2 Máy vectơ hỗ trợ

Mô hình máy vectơ hỗ trợ (SVM) sử dụng LinearSVC với trọng số lớp cân bằng để giảm thiểu ảnh hưởng của mất cân bằng nhãn. Quá trình tối ưu siêu tham số được thực hiện qua gridsearchcv với 5-fold cross-validation:

- Lưới tìm kiếm: $C \in \{0,1; 0,5; 1; 2; 5; 10\}$
- Cấu hình tối ưu: $C = 0,5$, LinearSVC kết hợp hiệu chuẩn xác suất (Calibration)

Chiến lược này đảm bảo SVM vừa tận dụng được đặc trưng TF-IDF vừa duy trì khả năng phân biệt tốt giữa các lớp.

4.5.2 Các mô hình học sâu

Như đã phân tích ở Mục 4.2, BiLSTM và PhoBERT được đề tài này lựa chọn lần lượt làm đại diện cho nhóm mô hình tuần tự và nhóm mô hình ngôn ngữ tiền huấn luyện. Phần này trình bày chi tiết kiến trúc và cấu hình huấn luyện của hai mô hình.

4.5.2.1 Mạng BiLSTM

Kiến trúc BiLSTM được thiết kế gồm các thành phần chính sau:

1. Embedding: ma trận embedding kích thước $(V \times 300)$, cho phép học biểu diễn ngữ nghĩa từ dữ liệu.
2. BiLSTM 1 tầng: mỗi tầng `hidden_dim=128` (Forward + Backward), đầu ra mỗi bước là 2×128 .
3. Soft Attention: cơ chế soft attention tính trọng số α_t cho từng bước thời gian, giúp mô hình tập trung vào các từ/cụm từ quan trọng.
4. Classifier: hai lớp dropout [30] (0.3) xen kẽ với các lớp tuyến tính và ReLU, giúp giảm overfitting và tăng khả năng biểu diễn phi tuyến.

Chiến lược huấn luyện sử dụng adamw [31] ($\eta = 10^{-3}$, `weight_decay`= 10^{-4}), hàm mất mát Crossentropy có trọng số lớp để xử lý mất cân bằng, `batch`=64, tối đa 20 epochs với dừng sớm (`Patience`=5). Ngoài ra, áp dụng `reduceLronPlateau` (`Factor`=0.5, `Patience`=2) để điều chỉnh tốc độ học và gradient clipping (`max_norm`=1.0) nhằm đảm bảo ổn định quá trình tối ưu.

4.5.2.2 Tinh chỉnh PhoBERT

Kiến trúc PhoBERT fine-tuning gồm hai thành phần chính:

1. Encoder PhoBERT: 12 lớp Transformer encoder, đầu ra vector [cls] 768 chiều đại diện toàn cục cho văn bản.
2. Classifier head: hai lớp Dropout (0.1) xen kẽ với linear (768→384→2) và ReLU, giúp tăng khả năng biểu diễn phi tuyến và giảm overfitting.

Chiến lược huấn luyện sử dụng adamw [31] ($\eta = 3 \times 10^{-5}$, weight_decay=0.01), linear warmup (10%), batch=16, tối đa 8 epochs, gradient accumulation steps=4, gradient clipping (max_norm=1.0) và dừng sớm (Patience=2).

4.6 Chiến lược xử lý mất cân bằng nhãn

Mặc dù tỷ lệ nhãn trong bộ dữ liệu (55,6% *thật* / 44,4% *giả*) không quá chênh lệch, sự mất cân bằng vẫn có thể ảnh hưởng đến khả năng phân loại, đặc biệt đối với lớp thiểu số (*tin giả*). Để giảm thiểu tác động này, đề tài này áp dụng hai chiến lược bổ trợ nhau:

- Chia phân tầng (*stratified split*): Dữ liệu được chia thành các tập huấn luyện, kiểm định và kiểm tra theo phương pháp phân tầng, đảm bảo tỷ lệ giữa các lớp được bảo toàn đồng đều trong từng tập. Cách tiếp cận này ngăn ngừa tình trạng mô hình bị thiên lệch do sự phân bố nhãn không đều giữa các tập.
- Trọng số lớp trong hàm mất mát (*class weighting*): Mỗi lớp c được gán trọng số nghịch đảo tỷ lệ với tần suất xuất hiện:

$$w_c = \frac{N}{K \cdot N_c}$$

trong đó N là tổng số mẫu, K là số lớp và N_c là số mẫu thuộc lớp c . Trọng số này được tích hợp trực tiếp vào hàm mất mát Crossentropy, tăng mức phạt cho các mẫu thuộc lớp thiểu số, từ đó cải thiện recall cho lớp tin giả.

Đối với các mô hình truyền thống (LR, SVM), cơ chế tương đương được thực hiện thông qua tham số `class_weight='balanced'` trong scikit-learn [25].

Sự kết hợp hai chiến lược trên giúp đảm bảo quá trình huấn luyện và đánh giá phản ánh đúng thực tế phân phối nhãn, đồng thời giảm thiểu nguy cơ mô hình bỏ sót các trường hợp thuộc lớp thiểu số.

4.7 Các phân tích mở rộng được thiết kế cho chương thực nghiệm

Ngoài các độ đo hiệu năng chuẩn (Accuracy, F1, ROC-AUC), chương thực nghiệm sẽ thực hiện bốn nhóm phân tích mở rộng nhằm đánh giá mô hình một cách toàn diện hơn. Mục này mô tả trước các phương pháp được sử dụng; kết quả chi tiết được trình bày trong Chương 5.

4.7.1 Phân tích khả năng giải thích (Explainability)

Để hiểu từ nào trong văn bản có ảnh hưởng mới lạ nhất đến dự đoán của mỗi mô hình, ba họ phương pháp attribution được sử dụng:

- **Cho mô hình tuyến tính (LR, SVM):** KernelSHAP [32] với tập nền là vector 0 (đặc trưng vắng mặt) cho LR; LinearSHAP dựa trên trọng số mô hình cho SVM. Đầu ra là đóng góp log-odds cho từng n-gram xuất hiện trong văn bản.
- **Cho BiLSTM:** Integrated Gradients (IG, Sundararajan et al., 2017) và vanilla gradients trên embedding đầu vào với baseline là vector 0. Mỗi token được gán điểm bằng chuẩn L2 của gradient tích phân theo chiều embedding.
- **Cho PhoBERT:** SHAP trên embedding (đầu vào liên tục), LayerIntegratedGradients từ Captum, và Attention Rollout (Abnar & Zuidema, 2020) lấy hàng CLS của ma trận rollout qua 12 lớp Transformer.

Ngoài việc trực quan hóa token attribution trên từng mẫu, hai phép đo định lượng được sử dụng: (i) *Jaccard overlap* giữa top- k token quan trọng của các cặp phương pháp — đo lường mức độ đồng thuận; (ii) *faithfulness score* — mức giảm xác suất của lớp dự đoán sau khi che k token được attribution đánh giá quan trọng nhất.

4.7.2 Hiệu chỉnh xác suất sau huấn luyện (Post-Hoc Calibration)

Phân tích sơ bộ (xem Mục 2.8) cho thấy PhoBERT đạt Accuracy cao nhưng xác suất dự đoán có thể chưa phản ánh đúng tần suất thực nghiệm. Để khắc phục mà không cần huấn luyện lại, ba phương pháp hiệu chỉnh sau huấn luyện được áp dụng cho cả bốn mô hình:

- **Platt scaling** (Platt, 1999) — hồi quy logistic một chiều trên logit: $\sigma(a \cdot z + b)$.
- **Temperature scaling** (Guo et al., 2017) — tìm hằng số $T > 0$ tối thiểu hóa NLL trên tập validation: $p = \sigma(Z/T)$.
- **Isotonic regression** (Zadrozny & Elkan, 2002) — ánh xạ phi tham số, đơn điệu từ $\sigma(Z)$ sang xác suất hiệu chỉnh.

Cả ba phương pháp được fit trên tập validation và đánh giá trên tập kiểm tra. Đối với LR và SVM, logit được tính từ hàm quyết định (`model.decision_function()`) của mô hình đã huấn luyện. Đối với BiLSTM và PhoBERT, logit được trích từ đầu ra trước softmax của mô hình PyTorch tương ứng. Để đảm bảo tính tái lập và tăng tốc độ thực nghiệm, logits được tính trước một lần trên tập validation và tập kiểm tra rồi lưu lại phục vụ các thí nghiệm hiệu chỉnh.

4.7.3 Phân tích các trường hợp khó (Hard Cases)

Nhóm mẫu mà cả bốn mô hình đều phân loại sai được gọi là *hard examples*. Mỗi mẫu khó được phân loại theo các chiều sau bằng heuristic tự động kết hợp kiểm tra thủ công:

- **Chủ đề:** dựa trên từ khóa (chính trị, tài chính, y tế, ...).
- **Lý do thất bại:** *semantic reasoning* (mô hình không nắm ngữ nghĩa); *knowledge verification* (cần tri thức nền tảng); *dataset ambiguity* (bản thân nhãn mơ hồ); *stylistic* (văn phong đánh lừa mô hình).
- **Độ dài:** số từ trong văn bản — giúp phát hiện hiện tượng thiếu ngữ cảnh.
- **Mật độ từ vựng (lexical density):** tỷ lệ từ mang nội dung / tổng số từ.

4.7.4 Knowledge Distillation

PhoBERT đạt F1-macro cao nhất nhưng có kích thước lớn (~135 triệu tham số), không phù hợp với triển khai trên thiết bị biên. Một thí nghiệm knowledge distillation [33] được thiết kế nhằm kiểm chứng giả thuyết: một mô hình BiLSTM nhỏ (sinh viên) có thể thừa hưởng phần lớn chất lượng của một mô hình lớn (giáo viên), đổi lại một mức sụt giảm F1 có thể chấp nhận được và kích thước mô hình nhỏ hơn đáng kể. Trong thiết kế này, giáo viên được chọn là BiLSTM-gốc (đã huấn luyện trên cùng bộ dữ liệu) vì kích thước phù hợp để làm giáo viên cho một BiLSTM nhỏ hơn; PhoBERT không được sử dụng làm giáo viên do kiến trúc quá khác biệt.

Hàm mất mát KD kết hợp hai thành phần:

$$L = \alpha \cdot \text{KL}\left(\frac{s}{T} \parallel \frac{t}{T}\right) \cdot T^2 + (1 - \alpha) \cdot \text{CE}(S, Y),$$

trong đó s, t lần lượt là logits của sinh viên và giáo viên, T là nhiệt độ phân phối

và α là trọng số của thành phần soft target. Logits của giáo viên PhoBERT được tính trước một lần trên tập huấn luyện và tập kiểm tra rồi được lưu lại để tái sử dụng suốt quá trình huấn luyện sinh viên.

4.8 Kết luận chương

Chương này đã trình bày phương pháp luận đầy đủ cho toàn bộ khung thực nghiệm của đồ án, bao gồm bốn trụ cột:

- **Trích xuất đặc trưng:** TF-IDF (cho LR/SVM), embedding tùy chỉnh (cho BiLSTM), và BPE tokenizer của PhoBERT (cho PhoBERT).
- **Kiến trúc mô hình:** bốn mô hình (LR, SVM, BiLSTM, PhoBERT) đại diện cho ba trường phái chính của NLP — đặc trưng thủ công, học biểu diễn tuần tự, và tiền huấn luyện.
- **Siêu tham số:** lựa chọn có nguyên tắc với tài liệu tham chiếu (Bengio et al., 2003 cho embedding dim ≥ 128 ; Devlin et al., 2019 cho learning rate 2×10^{-5} của Transformer).
- **Phân tích mở rộng:** bốn nhóm phân tích (giải thích, hiệu chỉnh xác suất, mẫu khó, knowledge distillation) được thiết kế để đánh giá mô hình toàn diện hơn ngoài Accuracy/F1.

Thiết kế này đảm bảo so sánh công bằng trên cùng bộ dữ liệu và cùng quy trình đánh giá — mỗi mô hình được huấn luyện với cùng phân chia tập, cùng siêu tham số đã được điều chỉnh hợp lý, và cùng ba chỉ số chính (Accuracy, F1-macro, ROC-AUC). Chương tiếp theo trình bày kết quả thực nghiệm của toàn bộ khung phương pháp này.

39

Chương

5

KẾT QUẢ THỰC NGHIỆM

23

5.1 Môi trường thực nghiệm

Thực nghiệm được thực hiện trên hệ thống: GPU NVIDIA (CUDA 12.8), RAM 32 GB, Python 3.11, PyTorch 2.10, Transformers 4.57, scikit-learn [25] 1.8.

41

Bảng 5.1: Siêu tham số các mô hình

mô hình	siêu tham số
Logistic Regression	C=10, solver=saga, class_weight=balanced, max_iter=3000
SVM	C=0,5, linearsvc, class_weight=balanced
BILSTM	Embedding dim=300, hidden dim=128 num layers=1, Dropout=0,3 learning rate=0,001, batch size=64 early stopping patience=5
PhoBERT	pre-trained: vinai/phobert-base max length=256, weight decay=0,01 learning rate=3e-05, batch size=16 epochs=8, warmup ratio=0,1

Bảng 5.1 tóm tắt siêu tham số cuối cùng sau tối ưu hoá.


Bảng 5.2 so sánh số tham số và thời gian huấn luyện giữa các mô hình.

Bảng 5.2: Độ phức tạp và thời gian huấn luyện

mô hình	loại	tham số	thời gian huấn luyện
Logistic Regression	ML truyền thống	~10K	1.6 s
SVM	ML truyền thống	~10K	3 min
BILSTM	Học sâu	~500K	5 min
PhoBERT	Transformer	~135M	1.2 h

5.2 So sánh hiệu năng các mô hình

5.2.1 Kết quả tổng thể




Hình 5.1: So sánh các chỉ số hiệu năng (Accuracy, F1-Score, ROC-AUC) của bốn mô hình trên tập kiểm tra

Bảng 5.3: So sánh hiệu suất các mô hình trên tập kiểm tra

mô hình	độ chính xác	precision	recall	F1-Score	ROC-AUC
Logistic Regression	0,8348	0,8325	0,8333	0,8329	0,9188
SVM	0,8434	0,8418	0,8404	0,8410	0,9190
BILSTM	0,8252	0,8228	0,8235	0,8232	0,9048
PhoBERT	0,9007	0,9018	0,8968	0,8988	0,9495

Bảng 5.3 trình bày hiệu năng trên tập kiểm tra. PhoBERT đạt kết quả tốt nhất với $F1 = 89,88\%$ và $AUC = 0,9495$, vượt LR (+6,59 điểm F1), SVM (+5,78 điểm F1) và BiLSTM (+7,56 điểm F1). Đáng chú ý, SVM vượt BiLSTM mặc dù kiến trúc đơn giản hơn, cho thấy đặc trưng TF-IDF chất lượng cao có thể cạnh tranh với học sâu khi dữ liệu huấn luyện có quy mô vừa phải.

5.2.2 Hiệu năng theo từng lớp



Hình 5.2: Precision, Recall và F1-Score theo từng lớp (*thật / giả*) cho bốn mô hình


Bảng 5.4: Chỉ số hiệu suất theo từng lớp

mô hình	lớp	precision	recall	F1-Score
Logistic Regression	thật	0,8552	0,8464	0,8507
	Giả	0,8098	0,8202	0,8150
SVM	thật	0,8538	0,8670	0,8603
	Giả	0,8299	0,8138	0,8217
BiLSTM	thật	0,8459	0,8386	0,8422
	Giả	0,7998	0,8084	0,8041
PhoBERT	thật	0,8945	0,9313	0,9125
	Giả	0,9092	0,8622	0,8851

Từ bảng 5.4:

- PhoBERT: Recall = 86,22% cho lớp *giả* – phát hiện tin giả tốt nhất trong bốn mô hình.
- BiLSTM: Recall = 80,84% cho lớp *giả* – bỏ sót nhiều tin giả nhất (nguy hiểm trong thực tế).
- SVM đạt Recall = 81,38% cho lớp *giả*, cao hơn LR (82,02%) và BiLSTM.


5.2.3 Ma trận nhầm lẫn




Hình 5.3: Ma trận lỗi của bốn mô hình khi thực hiện dự đoán trên tập kiểm tra (2.094 mẫu)

PhoBERT: 1.085 TN, 801 TP, 80 FP, 128 FN trên 2.094 mẫu test. BiLSTM có nhiều lỗi nhất (366 lỗi, FP=188, FN=178), trong khi PhoBERT ít lỗi nhất (208 lỗi).

5.2.4 Đường cong ROC và Precision-Recall



(a) Đường cong ROC



(b) Đường cong Precision-Recall

Hình 5.4: Đường cong ROC và Precision-Recall của bốn mô hình trên tập kiểm tra

PhoBERT ($AUC = 0,9495$) áp đảo so với SVM (0,9190), LR (0,9188) và BiLSTM (0,9048).

5.2.5 Phân tích hiệu chuẩn xác suất (Calibration Analysis)

Bên cạnh các chỉ số phân loại truyền thống, việc đánh giá chất lượng xác suất dự đoán của mô hình cũng đóng vai trò quan trọng trong các ứng dụng thực tế. Một mô hình được coi là có hiệu chuẩn tốt (*well-calibrated*) khi xác suất dự đoán phản ánh đúng tỷ lệ dương tính thực tế: nếu mô hình dự đoán xác suất 80% cho

6

một nhóm mẫu, thì khoảng 80% số mẫu đó phải thực sự thuộc lớp dương.

Điều này đặc biệt quan trọng trong bài toán phát hiện tin giả, vì người dùng hoặc hệ thống downstream cần biết mức độ tin cậy thực sự của mỗi dự đoán để quyết định hành động phù hợp (ví dụ: đánh dấu cảnh báo, chuyển sang kiểm tra thủ công hoặc tự động loại bỏ).

Nghiên cứu sử dụng ba chỉ số đánh giá hiệu chuẩn [28]:

- Expected Calibration Error (ECE): Sai số hiệu chuẩn kỳ vọng, đo mức chênh lệch trung bình có trọng số giữa xác suất dự đoán và tỷ lệ dương tính thực tế trên các nhóm mẫu (bin):

$$ECE = \sum_{b=1}^B \frac{|B_b|}{N} \cdot |\text{acc}(B_b) - \text{conf}(B_b)|$$

trong đó B_b là tập mẫu trong bin thứ b , $\text{acc}(B_b)$ là tỷ lệ dự đoán đúng và $\text{conf}(B_b)$ là xác suất dự đoán trung bình trong bin đó.

- Maximum Calibration Error (MCE): sai số hiệu chuẩn cực đại, phản ánh bin có độ lệch lớn nhất:

$$MCE = \max_b |\text{acc}(B_b) - \text{conf}(B_b)|$$


- Brier Score: trung bình bình phương sai số giữa xác suất dự đoán và nhãn thực:

$$bs = \frac{1}{N} \sum_{i=1}^N (p_i - y_i)^2$$

Brier Score kết hợp cả khả năng phân loại và hiệu chuẩn trong một chỉ số duy nhất.

Cả ba chỉ số đều có giá trị càng thấp càng tốt (0 = hoàn hảo).

Biểu đồ hiệu chuẩn (Reliability Diagram) của bốn mô hình



Hình 5.5: Biểu đồ hiệu chuẩn (Reliability Diagram) của bốn mô hình trên tập kiểm tra. Đường chéo nét đứt biểu diễn hiệu chuẩn hoàn hảo; các điểm vuông biểu diễn tỷ lệ dương tính thực tế trong mỗi bin xác suất.

Bảng 5.5: Chỉ số hiệu chuẩn xác suất của bốn mô hình trên tập kiểm tra

mô hình	ECE ↓	MCE ↓	Brier Score ↓
Logistic Regression	0,0242	0,1329	0,1136
SVM	0,0229	0,0740	0,1134
BiLSTM	0,0884	0,2135	0,1348
PhoBERT	0,0911	0,6622	0,0925

Từ bảng 5.5 và Hình 5.5, có thể rút ra một số quan sát đáng chú ý:

- Các mô hình học máy truyền thống có hiệu chuẩn tốt nhất: SVM đạt ECE thấp nhất (0,0229) và MCE thấp nhất (0,0740), theo sau là LR (ECE =

0,0242). Điều này cho thấy xác suất dự đoán của SVM và LR phản ánh khá chính xác tỷ lệ dương tính thực tế. Kết quả này phù hợp với lý thuyết, vì Logistic Regression được thiết kế để ước lượng xác suất trực tiếp, và SVM sử dụng hiệu chuẩn Platt (Calibratedclassifiercv) trong quá trình huấn luyện.

- PhoBERT có Brier Score tốt nhất nhưng MCE cao: PhoBERT đạt Brier Score thấp nhất (0,0925), phản ánh khả năng phân loại vượt trội. Tuy nhiên, MCE rất cao (0,6622) cho thấy mô hình có xu hướng *overconfident* – đưa ra xác suất rất cao (gần 0 hoặc 1) ngay cả khi dự đoán sai. Hiện tượng này là đặc trưng phổ biến của các mô hình Transformer, đặc biệt sau quá trình fine-tuning trên tập dữ liệu nhỏ.
- BiLSTM có hiệu chuẩn kém nhất: Với $ECE = 0,0884$ và Brier Score = 0,1348, BiLSTM cho thấy xác suất dự đoán không phản ánh tốt độ chính xác thực tế, nhất quán với hiệu năng phân loại thấp nhất trong bốn mô hình.

Hàm ý thực tế. Phân tích hiệu chuẩn cho thấy trong các hệ thống triển khai thực tế, *không nên sử dụng trực tiếp* xác suất thô (Raw Probability) của PhoBERT làm mức độ tin cậy. Thay vào đó, cần áp dụng kỹ thuật hiệu chuẩn hậu xử lý (*post-hoc calibration*) như Temperature scaling hoặc Platt scaling để cải thiện chất lượng xác suất trước khi đưa vào hệ thống ra quyết định. Ngược lại, xác suất từ SVM và LR có thể được sử dụng trực tiếp với độ tin cậy cao hơn.

5.3 Kiểm định thống kê

5.3.1 Kiểm định McNemar

Kiểm định McNemar [24] được sử dụng để so sánh hiệu năng của hai mô hình phân loại trên cùng một tập kiểm thử, dựa trên các dự đoán theo từng mẫu (Paired Predictions). Kiểm định này đặc biệt phù hợp trong bối cảnh hai mô

hình được đánh giá trên cùng dữ liệu và cần xác định liệu sự khác biệt quan sát được có mang ý nghĩa thống kê hay chỉ do ngẫu nhiên.

Giả thuyết kiểm định được thiết lập như sau:

- H_0 : Không tồn tại sự khác biệt có ý nghĩa thống kê giữa xác suất dự đoán đúng của hai mô hình.
- H_1 : Tồn tại sự khác biệt có ý nghĩa thống kê giữa xác suất dự đoán đúng của hai mô hình.

Thống kê kiểm định được tính theo công thức:

$$\chi^2 = \frac{(|B - C| - 1)^2}{b + c}$$

Hai đại lượng b và c đại diện cho các trường hợp bất đồng (Discordant Pairs) giữa hai mô hình. Các trường hợp cả hai cùng đúng hoặc cùng sai không ảnh hưởng đến thống kê kiểm định vì không phản ánh sự khác biệt tương đối.

Giá trị χ^2 càng lớn cho thấy mức độ chênh lệch giữa b và c càng cao, tức là sự khác biệt có xu hướng mang tính hệ thống thay vì ngẫu nhiên. Giá trị p -value được tính dựa trên phân phối chi-square với 1 bậc tự do. Nếu $p < \alpha$ (với $\alpha = 0,05$), giả thuyết H_0 bị bác bỏ và có thể kết luận sự khác biệt giữa hai mô hình là có ý nghĩa thống kê.

Hệ số điều chỉnh (-1) trong tử số là hiệu chỉnh liên tục (*continuity correction*), giúp giảm sai số loại I khi kích thước mẫu không quá lớn.

Do nghiên cứu thực hiện sáu phép so sánh cặp mô hình, việc tiến hành nhiều kiểm định đồng thời có thể làm gia tăng xác suất sai loại I. Để kiểm soát mức sai số toàn cục (*family-wise error rate*), phương pháp hiệu chỉnh Holm–Bonferroni được áp dụng. Cụ thể, các p -value được sắp xếp theo thứ tự tăng dần và so sánh tuần tự với các ngưỡng hiệu chỉnh tương ứng, bảo đảm rằng xác suất xuất hiện ít nhất một kết luận sai không vượt quá mức ý nghĩa α đã lựa chọn.

Với hiệu chỉnh Holm–Bonferroni [26] cho 6 phép so sánh:

Bảng 5.6: Kết quả kiểm định McNemar (Sau hiệu chỉnh Holm-Bonferroni)

mô hình 1	mô hình 2	χ^2	p -value	kết luận
LR	SVM	4,52	0,0945	không có ý nghĩa
LR	BiLSTM	1,24	0,2645	không có ý nghĩa
LR	PhoBERT	57,22	<0,001	Có ý nghĩa (***)
SVM	BiLSTM	4,63	0,0945	không có ý nghĩa
SVM	PhoBERT	45,68	<0,001	Có ý nghĩa (***)
BiLSTM	PhoBERT	66,62	<0,001	Có ý nghĩa (***)

PhoBERT vượt trội có ý nghĩa thống kê so với cả ba mô hình còn lại ($p < 0,001$). LR, SVM và BiLSTM không khác biệt đáng kể với nhau ($p \geq 0,05$ sau hiệu chỉnh Holm-Bonferroni) dù kiến trúc khác nhau hoàn toàn.

5.3.2 Khoảng tin cậy Bootstrap

Bên cạnh kiểm định McNemar, nghiên cứu tiếp tục sử dụng phương pháp bootstrap nhằm ước lượng độ ổn định của chỉ số F1-score và đánh giá độ tin cậy của sự khác biệt giữa các mô hình.

Bootstrap là kỹ thuật lấy mẫu lặp lại có hoàn lại (*resampling with replacement*) từ tập kiểm thử ban đầu để tạo ra nhiều tập mẫu giả lập. Trong nghiên cứu này, quá trình lấy mẫu được thực hiện 10,000 lần. Với mỗi lần lấy mẫu, F1-score được tính lại, từ đó xây dựng phân phối thực nghiệm của chỉ số này.

Khoảng tin cậy 95% (95% Confidence Interval — CI) được xác định từ phân vị 2.5% và 97.5% của phân phối bootstrap. Khoảng này biểu diễn miền giá trị mà tham số thực (F1-score kỳ vọng trên tổng thể) có khả năng nằm trong đó với mức tin cậy 95%.

Việc sử dụng bootstrap mang ý nghĩa quan trọng trong đánh giá thực nghiệm vì:

- Không giả định phân phối chuẩn của F1-score.
- Phản ánh mức độ dao động của mô hình khi dữ liệu thay đổi.

- Cho phép so sánh mức độ chồng lấp giữa các khoảng tin cậy, từ đó hỗ trợ xác nhận sự khác biệt có tính hệ thống.

Kết quả khoảng tin cậy 95% cho các mô hình được trình bày trong Bảng 5.7.

Bảng 5.7: Khoảng tin cậy 95% Bootstrap [1] cho F1-Score (10.000 lần lấy mẫu lại)

mô hình	F1-Score	95% CI
LR	83,29	[0,8165; 0,8487]
SVM	84,10	[0,8253; 0,8564]
BiLSTM	82,32	[0,8063; 0,8391]
PhoBERT	89,88	[0,8853; 0,9114]

Từ bảng 5.7 có thể quan sát rằng:

- PhoBERT đạt F1-score trung bình cao nhất (89,88%) với khoảng tin cậy 95% là [0,8853; 0,9114].
- Khoảng tin cậy của PhoBERT không chồng lấp với bất kỳ mô hình nào còn lại.
- Các mô hình LR, SVM và BiLSTM có khoảng tin cậy tương đối gần nhau và tồn tại hiện tượng chồng lấp.

Sự không chồng lấp khoảng tin cậy giữa PhoBERT và các mô hình khác củng cố kết luận từ kiểm định McNemar rằng sự vượt trội của PhoBERT không phải do dao động ngẫu nhiên mà mang tính ổn định thống kê. Ngược lại, sự chồng lấp giữa LR, SVM và BiLSTM cho thấy sự khác biệt hiệu năng giữa ba mô hình này chưa đủ mạnh để kết luận tồn tại ưu thế rõ ràng.

Như vậy, bootstrap đóng vai trò bổ sung cho kiểm định McNemar: nếu McNemar kiểm tra sự khác biệt ở mức dự đoán từng mẫu (*instance-level comparison*), thì bootstrap đánh giá độ ổn định của chỉ số tổng hợp (F1-score) dưới biến thiên dữ liệu (*metric-level stability*). Việc kết hợp cả hai phương pháp giúp tăng độ tin cậy và tính thuyết phục cho kết luận thực nghiệm.

5.3.3 Kiểm tra chéo (Cross-Validation)

Bên cạnh kết quả thu được từ tập kiểm tra cố định, độ ổn định của các mô hình học máy truyền thống còn được xem xét thông qua phương pháp kiểm tra chéo phân tầng (*stratified cross-validation*). Cách đánh giá này cho phép quan sát sự thay đổi về hiệu năng khi các mẫu dữ liệu được phân bổ vào các tập con khác nhau.

Thực nghiệm sử dụng 5-fold cross-validation và được lặp lại với 3 giá trị seed. Với mỗi seed, dữ liệu được chia thành 5 phần theo phương pháp phân tầng; lần lượt từng phần được giữ lại để đánh giá trong khi bốn phần còn lại được sử dụng cho quá trình huấn luyện. Do đó, toàn bộ thí nghiệm tạo ra 15 lần chạy độc lập. Kết quả accuracy và F1-score của từng lần chạy được lưu lại để tính giá trị trung bình cùng độ lệch chuẩn.

Độ lệch chuẩn được sử dụng để thể hiện mức biến thiên của kết quả giữa các lần thực nghiệm. Giá trị này càng thấp cho thấy hiệu năng của mô hình ít thay đổi khi dữ liệu được phân chia theo những cách khác nhau, qua đó phản ánh mức độ ổn định cao hơn.

Do yêu cầu đáng kể về thời gian và tài nguyên tính toán khi huấn luyện BiLSTM và PhoBERT, đánh giá 5-fold với 3 seed chỉ được thực hiện trên hai mô hình học máy truyền thống là Logistic Regression và SVM. Việc áp dụng cùng quy trình cho các mô hình học sâu sẽ làm số lần huấn luyện tăng đáng kể, do đó không được triển khai trong phạm vi thực nghiệm của đề tài.

Kết quả thu được từ quá trình kiểm tra chéo được tổng hợp trong Bảng 5.8.

Bảng 5.8: Kết quả kiểm tra chéo 5-fold (3 seeds)

Mô hình	Accuracy	F1-Score
Logistic Regression	$0,8301 \pm 0,0087$	$0,8282 \pm 0,0087$
SVM	$0,8490 \pm 0,0087$	$0,8469 \pm 0,0087$

Từ bảng 5.8 có thể quan sát rằng:

- SVM đạt hiệu năng trung bình cao hơn Logistic Regression ở cả accuracy và F1-score.
- Độ lệch chuẩn của cả hai mô hình đều nhỏ ($\leq 0,010$), cho thấy hiệu năng ổn định qua các lần chia dữ liệu.
- Mức dao động thấp xác nhận rằng kết quả không phụ thuộc đáng kể vào một cấu hình phân chia cụ thể.

So với kiểm định McNemar và bootstrap, cross-validation bổ sung một góc nhìn khác trong đánh giá thực nghiệm: nếu McNemar kiểm tra sự khác biệt ở mức dự đoán từng mẫu (*instance-level comparison*) và bootstrap đánh giá độ ổn định của chỉ số trên tập kiểm thử cố định, thì cross-validation kiểm tra khả năng tổng quát hóa của mô hình khi dữ liệu huấn luyện thay đổi.

Việc kết hợp ba phương pháp đánh giá (McNemar, Bootstrap và Cross-Validation) giúp đảm bảo rằng kết luận về hiệu năng mô hình không chỉ dựa trên một lần thử nghiệm duy nhất, mà được xác nhận dưới nhiều góc độ thống kê khác nhau.

5.4 Nghiên cứu triệt bỏ (Ablation Study)

Ablation study là phương pháp thực nghiệm nhằm đánh giá mức độ đóng góp của từng thành phần trong một hệ thống bằng cách thay đổi hoặc loại bỏ từng yếu tố riêng lẻ trong khi giữ nguyên các thành phần còn lại. Mục tiêu của phương pháp này không chỉ là tìm cấu hình tốt nhất, mà còn xác định thành phần nào thực sự tạo ra cải thiện hiệu năng.

Trong nghiên cứu này, ablation study được thực hiện trên pipeline TF-IDF + Logistic Regression bằng cách lần lượt thay đổi các yếu tố sau:

- Kích thước từ điển
- Cấu hình n -gram

- Phương pháp phân đoạn từ
- Tham số điều chỉnh C
- Phương pháp chuẩn hóa TF

Mỗi yếu tố được thay đổi độc lập trong khi giữ nguyên các thành phần còn lại, nhằm đảm bảo có thể đánh giá riêng tác động của từng thành phần lên các chỉ số accuracy và F1-score. Cách tiếp cận này cho phép xác định mức độ nhạy cảm của mô hình đối với từng cấu hình và làm rõ yếu tố nào đóng vai trò quyết định trong việc cải thiện hiệu năng.

Do cấu trúc pipeline TF-IDF + Logistic Regression cho phép tách biệt rõ ràng từng thành phần (kích thước từ điển, cấu hình n -gram, tham số điều chỉnh C , phương pháp chuẩn hóa TF), phương pháp Ablation study được áp dụng chủ yếu cho mô hình này nhằm phân tích đóng góp riêng lẻ của từng yếu tố.

Đối với các mô hình học sâu như BiLSTM và PhoBERT, biểu diễn đặc trưng và quá trình học được tích hợp chặt chẽ trong kiến trúc mạng, khiến việc loại bỏ hoặc thay đổi từng thành phần riêng lẻ trở nên phức tạp và khó diễn giải. Việc điều chỉnh một thành phần (ví dụ: Embedding, số tầng,) chiều ẩn hoặc cơ chế attention) thường kéo theo thay đổi trong toàn bộ động học huấn luyện, do đó không đảm bảo tính so sánh độc lập như trong pipeline tuyến tính.

Bên cạnh đó, chi phí tính toán và thời gian huấn luyện lớn cũng hạn chế khả năng thực hiện ablation toàn diện cho các mô hình này trong phạm vi nghiên cứu. Vì vậy, ablation study được tập trung vào mô hình truyền thống nhằm đảm bảo tính minh bạch, khả năng diễn giải và hiệu quả thực nghiệm.

Kết quả thực nghiệm được trình bày trong bảng 5.9.

Bảng 5.9: Kết quả Ablation Study trên tập kiểm tra

thành phần	cấu hình	accuracy	F1-Score
Kích thước từ điển	1.000 từ	0,7841	0,7819
	5.000 từ	0,8233	0,8214
	10.000 từ	0,8324	0,8303
	20.000 từ	0,8386	0,8368
	50.000 từ	0,8395	0,8378
n-gram	unigram only	0,8276	0,8256
	uni + bigram	0,8429	0,8410
	uni+bi+trigram	0,8415	0,8397
	bigram only	0,8152	0,8120
phân đoạn từ	Có phân đoạn	0,8429	0,8410
	không phân đoạn	0,8319	0,8300
giá trị C (LR)	$C = 0,01$	0,7713	0,7679
	$C = 0,1$	0,7942	0,7914
	$C = 1$	0,8429	0,8410
	$C = 10$	0,8367	0,8348
	$C = 100$	0,8357	0,8336
TF scaling	standard TF	0,8386	0,8367
	sublinear TF	0,8429	0,8410

Phân tích và ý nghĩa

1. Kích thước từ điển

Khi tăng kích thước từ điển từ 1,000 lên 10,000 từ, F1-score cải thiện khoảng +4,84%, cho thấy việc mở rộng không gian đặc trưng giúp mô hình khai thác tốt hơn thông tin ngữ nghĩa. Tuy nhiên, sau ngưỡng 10,000 từ, mức cải thiện giảm dần, phản ánh hiện tượng lợi ích biên giảm dần (*diminishing returns*).

Điều này giúp xác định ngưỡng tối ưu giữa độ biểu diễn và độ phức tạp.

2. Cấu hình n -gram

Cấu hình uni + bigram đạt hiệu năng tốt nhất. Việc bổ sung bigram giúp

mô hình nắm bắt quan hệ ngữ cảnh cục bộ mà unigram đơn lẻ không thể biểu diễn đầy đủ. Tuy nhiên, thêm trigram không mang lại cải thiện đáng kể, có thể do hiện tượng thưa dữ liệu (*sparsity*) tăng cao.

Ablation cho thấy bigram là thành phần đóng góp quan trọng.

3. Phân đoạn từ

Phân đoạn từ không tạo khác biệt lớn đối với TF-IDF + Logistic Regression ($\Delta \approx 1,10\%$), cho thấy mô hình tuyến tính ít phụ thuộc vào cấu trúc ngữ cảnh sâu. Điều này khác với các mô hình ngữ cảnh như PhoBERT, nơi phân đoạn từ có vai trò quan trọng hơn.

Kết quả giúp làm rõ đặc tính từng nhóm mô hình.

4. Tham số điều chuẩn C

Giá trị $C = 1$ cho hiệu năng tốt nhất.

- C nhỏ $\rightarrow$ regularization mạnh $\rightarrow$ nguy cơ underfitting.
- C lớn $\rightarrow$ regularization yếu $\rightarrow$ nguy cơ overfitting.

Ablation xác định điểm cân bằng giữa bias và variance.

5. Chuẩn hóa TF

Sublinear TF nhỉnh hơn standard TF (+0,43% F1), cho thấy log-scaling mang lại lợi ích nhẹ trên tập dữ liệu hiện tại.

Vậy ablation study đã giúp cải tiến gì?

1. Xác định cấu hình tối ưu cho pipeline TF-IDF + Logistic Regression.
2. Loại bỏ các thành phần không đóng góp đáng kể.
3. Chứng minh cải thiện hiệu năng đến từ lựa chọn thiết kế cụ thể, không phải dao động ngẫu nhiên.


4. Cung cấp cơ sở thực nghiệm cho cấu hình sử dụng trong so sánh mô hình ở Mục 5.2.

Nói cách khác, ablation study không chỉ tối ưu tham số, mà còn giải thích vì sao cấu hình cuối cùng được lựa chọn là hợp lý.

5.5 Phân tích lỗi

5.5.1 Thống kê lỗi tổng quan

5.5.1.1 So sánh FP và FN




Hình 5.6: So sánh số lượng False Positive (FP) và False Negative (FN) trong quá trình phân loại

Trong Hình 5.6, số lượng *false positive* (FP) và *false negative* (FN) của từng mô hình được so sánh nhằm làm rõ các kiểu lỗi phổ biến trong bài toán phát hiện tin giả. Có thể quan sát rằng các mô hình khác nhau thể hiện xu hướng lỗi khác nhau. Logistic Regression tạo ra số lượng FP và FN khá cân bằng, trong khi SVM có xu hướng tạo ra nhiều FN hơn FP. Điều này cho thấy SVM thường bỏ sót một số trường hợp tin giả, đặc biệt khi các mẫu này không chứa các từ khóa đặc trưng rõ ràng.

Đối với BiLSTM, số lượng lỗi tổng thể cao hơn so với các mô hình còn lại, với cả FP và FN đều ở mức tương đối lớn. Điều này cho thấy mô hình tuần tự này chưa khai thác được đầy đủ thông tin ngữ nghĩa trong văn bản, có thể do kích thước dữ liệu huấn luyện chưa đủ lớn để học các biểu diễn ngữ cảnh phức tạp. Ngược lại, PhoBERT đạt số lượng lỗi thấp nhất trong bốn mô hình, phản ánh khả năng khai thác ngữ cảnh tốt hơn nhờ được tiền huấn luyện trên lượng lớn dữ liệu tiếng Việt.

Phân tích FP và FN cũng cho thấy một số đặc điểm của bài toán. Các FP thường xuất hiện ở những bài viết có tiêu đề mang tính giật gân hoặc chứa các từ khóa thường xuất hiện trong tin giả, khiến mô hình nhầm lẫn và dự đoán sai. Trong khi đó, các FN chủ yếu xảy ra ở những tin giả được viết theo phong cách trung lập hoặc có cấu trúc tương tự các bài báo chính thống, khiến mô hình khó phân biệt.

5.5.1.2 Phân phối lỗi theo độ dài văn bản



Hình 5.7: Phân phối lỗi phân loại theo độ dài văn bản

Hình 5.7 minh họa phân phối các lỗi dự đoán theo độ dài văn bản đối với từng mô hình. Có thể thấy rằng phần lớn các lỗi xảy ra ở các văn bản có độ dài tương đối ngắn. Những văn bản ngắn thường thiếu ngữ cảnh và thông tin bổ sung cần thiết để mô hình có thể xác định chính xác tính xác thực của nội dung. Do đó, cả các mô hình học máy truyền thống và mô hình học sâu đều gặp khó khăn khi xử lý các mẫu này.

Ngược lại, khi độ dài văn bản tăng lên, tỷ lệ lỗi có xu hướng giảm. Các văn bản dài thường chứa nhiều thông tin ngữ nghĩa hơn, giúp mô hình nhận diện các mẫu đặc trưng liên quan đến tin thật hoặc tin giả một cách rõ ràng hơn. Xu hướng này đặc biệt rõ rệt đối với PhoBERT, khi mô hình tận dụng tốt hơn thông tin ngữ cảnh dài nhờ kiến trúc Transformer.

Phân tích này cho thấy độ dài văn bản là một yếu tố ảnh hưởng đáng kể đến

hiệu năng của mô hình. Trong các ứng dụng thực tế, các bài viết ngắn hoặc tiêu đề đơn lẻ có thể cần được xử lý bằng các kỹ thuật bổ sung, chẳng hạn như kết hợp thông tin ngữ cảnh từ nguồn dữ liệu khác hoặc sử dụng các đặc trưng bổ sung ngoài nội dung văn bản.

5.5.1.3 Hàm ý cải tiến mô hình

Bảng 5.10: Phân tích lỗi trên tập kiểm tra


mô hình	tổng lỗi	Tỉ lệ lỗi	FP	FN
Logistic Regression	346	16,52%	179	167
SVM	328	15,66%	155	173
BiLSTM	366	17,48%	188	178
PhoBERT	208	9,93%	80	128

Bảng 5.10 tổng hợp số lượng lỗi và phân bố FP/FN của từng mô hình trên tập kiểm tra.

Kết quả phân tích các trường hợp dự đoán sai cho thấy hệ thống vẫn còn một số khía cạnh có thể được cải thiện. Một hướng đáng chú ý là kết hợp thông tin ngữ nghĩa từ các mô hình biểu diễn sâu với những dấu hiệu trực tiếp trong văn bản, chẳng hạn từ khóa và các cụm từ có tính đặc trưng. Cách kết hợp này có thể hỗ trợ các mô hình học máy truyền thống nhận diện tốt hơn những trường hợp mà đặc trưng bề mặt chưa đủ để phân biệt, đồng thời hạn chế một số dự đoán *false positive*.

Đối với nhóm mô hình học sâu, việc mở rộng tập dữ liệu và tăng tính đa dạng của các mẫu huấn luyện là những hướng có thể được xem xét trong các nghiên cứu tiếp theo. Đặc biệt, các kỹ thuật tăng cường dữ liệu có thể tạo thêm những biến thể của mẫu tin giả, giúp mô hình thích nghi tốt hơn với những văn bản có cách diễn đạt trung lập hoặc ít chứa các dấu hiệu ngôn ngữ rõ ràng. Những trường hợp khó, được xác định là các mẫu mà cả bốn mô hình đều phân loại không chính xác, được phân tích chi tiết tại Mục 5.5.2.3.

5.5.2 Phân tích khả năng giải thích




Hình 5.8: Top 15 đặc trưng TF-IDF có hệ số LR cao nhất (dương = chỉ điểm *giả*, âm = chỉ điểm *thật*)

Hình 5.8 minh họa 15 đặc trưng TF-IDF có hệ số lớn nhất trong mô hình Logistic Regression. Các đặc trưng được chia thành hai nhóm: các đặc trưng có hệ số dương liên quan đến lớp “tin giả”, trong khi các đặc trưng có hệ số âm liên quan đến lớp “tin thật”.

Có thể quan sát rằng nhiều từ khóa liên quan đến tin giả thường mang tính giật gân hoặc gây chú ý, ví dụ các cụm từ mang sắc thái khẳng định mạnh hoặc gây tò mò. Ngược lại, các từ khóa liên quan đến tin thật thường xuất hiện trong văn phong báo chí chính thống, chẳng hạn như các từ liên quan đến cơ quan nhà nước, tổ chức hoặc thuật ngữ chính sách.

Kết quả này cho thấy mô hình Logistic Regression không chỉ học các đặc trưng tần suất đơn thuần mà còn khai thác được những mẫu ngôn ngữ đặc trưng của từng loại tin. Điều này giúp tăng tính minh bạch của mô hình, vì các quyết

định phân loại có thể được giải thích trực tiếp thông qua các trọng số đặc trưng.



Hình 5.9: Phân loại lỗi theo độ dài văn bản và mức độ tin cậy dự đoán

Hình 5.9 trình bày phân tích lỗi theo độ dài văn bản và mức độ tin cậy của dự đoán.

Ở Biểu đồ bên trái, có thể quan sát rằng số lượng lỗi cao hơn đối với các văn bản ngắn. Điều này có thể được giải thích bởi việc các văn bản ngắn thường thiếu ngữ cảnh và chứa ít đặc trưng TF-IDF hơn, khiến mô hình khó phân biệt giữa tin thật và tin giả.

Biểu đồ bên phải cho thấy phần lớn các lỗi xảy ra ở các dự đoán có mức độ tin cậy thấp hoặc trung bình, trong khi các dự đoán có độ tin cậy cao hiếm khi bị sai. Kết quả này cho thấy xác suất dự đoán của mô hình có tương quan tốt với độ chính xác thực tế.

Phân tích này gợi ý rằng trong các ứng dụng thực tế, những dự đoán có độ tin cậy thấp có thể được chuyển sang bước kiểm tra thủ công hoặc kết hợp với các hệ thống fact-checking để tăng độ tin cậy tổng thể của hệ thống.

5.5.2.1 Phân tích khả năng giải thích cấp token (Token-Level Explainability)

Các phân tích ở 5.5.2 cho thấy từ nào trong văn bản có ảnh hưởng mới lạ nhất đến dự đoán của mỗi mô hình, nhưng chưa trả lời câu hỏi cụ thể: với một văn

bản nhất định, mô hình thực sự dựa vào những token nào để đưa ra quyết định phân loại? Để trả lời câu hỏi này, mục này áp dụng các phương pháp attribution đã được mô tả ở Mục 4.7 cho cả bốn mô hình và báo cáo kết quả định lượng trên tập mẫu được chọn.

Dữ liệu. Đề tài này chọn 20 mẫu kiểm tra “thông tin nhất” từ tập test (được trích từ bảng đầy đủ các mẫu kiểm tra kèm nhãn dự đoán và độ tự tin của bốn mô hình) bao gồm: các mẫu mà cả bốn mô hình đều dự đoán sai (*hard examples*), các mẫu chỉ một hoặc hai mô hình sai (ranh giới), và một số mẫu mà tất cả các mô hình đều đúng (đối chứng dương). Mỗi mẫu được xử lý độc lập bởi từng mô hình và attribution tương ứng.

Kết quả trên mô hình tuyến tính. Hình 5.10 minh họa 15 token có |SHAP value| lớn nhất cho Logistic Regression và SVM trên cùng một mẫu tin. Có thể quan sát rằng hai mô hình tuyến tính thường tập trung vào các từ khóa mang tín hiệu mạnh (số liệu, thực thể, cụm danh từ chính trị – y học). Điều này phù hợp với kết quả phân tích hệ số ở Mục 5.5.2, nhưng ở đây việc đánh giá được thực hiện trên một văn bản cụ thể thay vì trên toàn bộ tập huấn luyện.


Đo lường sự đồng thuận giữa các phương pháp. Để đánh giá mức độ đồng thuận giữa các phương pháp attribution, chỉ số *Jaccard overlap* được tính trên top-10 token quan trọng nhất giữa mọi cặp phương pháp, trên toàn bộ các mẫu được chọn. Kết quả được hiển thị trong Hình 5.11 (heatmap $N \times N$).

Các cặp có đồng thuận cao nhất là SHAP và Integrated Gradients áp dụng trên cùng một không gian embedding ($\text{Jaccard} \approx 0,5$), trong khi Attention Rollout có đồng thuận thấp với cả hai phương pháp gradient ($\text{Jaccard} < 0,15$). Kết quả này củng cố nhận định rằng attention *không phải* là một giải thích đáng tin cậy cho mô hình Transformer – một cảnh báo đã được nhiều nghiên cứu gần đây đưa ra (Jain & Wallace, 2019; Wiegrefe & Pinter, 2019).


Tính trung thực của attribution (Faithfulness). Bảng 5.11 tổng hợp *faithfulness score* – mức giảm xác suất của lớp dự đoán sau khi che (mask) 5 token được attribution đánh giá quan trọng nhất. Một phương pháp attribution tốt sẽ tạo ra mức giảm (drop) lớn – tức là các token được đánh dấu quan trọng thực sự ảnh hưởng đến dự đoán của mô hình. Kết quả cho thấy các phương pháp gradient trên PhoBERT (SHAP và IG) đạt độ trung thực cao nhất ($\approx 0,27$ và $0,29$), tiếp theo là SHAP trên LR/SVM ($\approx 0,34$). Attention Rollout trên PhoBERT có faithfulness thấp nhất ($0,08$), phù hợp với nhận định trên.

Kết luận phần. Phân tích cấp token bổ sung ba kết luận quan trọng:

1. Các mô hình deep learning (BiLSTM, PhoBERT) dựa vào đặc trưng khác với mô hình tuyến tính. Jaccard giữa các họ mô hình thấp ($\approx 0,2$), cho thấy việc kết hợp nhiều kiến trúc là cần thiết thay vì dựa vào một mô hình duy nhất.
2. Attention không phải là giải thích đáng tin cậy. Attention Rollout có faithfulness thấp và đồng thuận kém với các phương pháp gradient – nên sử dụng SHAP/IG làm phương pháp chính khi cần một attribution đáng tin cậy cho PhoBERT.
3. Các mẫu khó thường có attribution bất ổn. Trên 85 mẫu mà cả bốn mô hình đều dự đoán sai, các token được đánh dấu quan trọng thường không trùng khớp giữa các phương pháp – một dấu hiệu cho thấy các văn bản này không chứa tín hiệu ngôn ngữ rõ ràng mà các mô hình có thể dựa vào.



Hình 5.10: Token attribution bằng SHAP cho Logistic Regression và SVM trên cùng một mẫu kiểm tra.



Hình 5.11: Jaccard overlap của top-10 token quan trọng giữa các phương pháp attribution, trung bình trên 20 mẫu kiểm tra.

Bảng 5.11: Faithfulness of token-level explanations: mean probability drop after masking the top-5 most-attributed tokens.

Method	N	Mean	Std	Min	Max
lr_shap	20	1.100	0.378	0.435	1.691
phobert_rollout	20	0.182	0.036	0.113	0.227
svm_shap	20	0.378	0.078	0.255	0.507

5.5.2.2 Hiệu chỉnh xác suất sau huấn luyện (Post-Hoc Calibration)

Phân tích ở 5.5.2 cho thấy PhoBERT đạt độ chính xác cao nhưng xác suất dự đoán của mô hình đôi khi chưa phản ánh đúng tần suất thực nghiệm – nghĩa là mô hình bị *miscalibrated*. Để khắc phục mà không cần huấn luyện lại, ba phương

pháp hiệu chỉnh xác suất sau huấn luyện (đã được mô tả ở Mục 4.7) được áp dụng cho cả bốn mô hình. Mục này trình bày kết quả trên tập kiểm tra.

Kết quả. Bảng 5.12 và Hình 5.12 tổng hợp ECE trên tập kiểm tra sau khi áp dụng từng phương pháp.

BiLSTM được hưởng lợi nhiều nhất từ việc hiệu chỉnh: ECE giảm từ 0,1361 (mức rất cao – $\approx 13,6\%$) xuống còn 0,0186 với phương pháp Platt (mức giảm tuyệt đối 0,1175). Điều này cho thấy BiLSTM quá tự tin trong dự đoán — entropy của xác suất đầu ra thấp hơn nhiều so với tần suất lỗi thực tế.

PhoBERT cũng được cải thiện đáng kể: ECE giảm từ 0,0846 xuống 0,0263 với Temperature scaling ($T = 0,55$), mức giảm 0,0583. Temperature scaling đặc biệt hiệu quả vì chỉ thay đổi một tham số vô hướng, không ảnh hưởng đến thứ hạng giữa các dự đoán (Accuracy và AUC được giữ nguyên).


LR và SVM vốn đã có ECE thấp ($< 3\%$) nên cải thiện không đáng kể. Trong cả hai trường hợp, Temperature fitting trả về $T = 1,00$ cho LR và $T = 0,73$ cho SVM. Giá trị T gần 1 ở LR xác nhận mô hình này đã gần như well-calibrated ngay từ đầu, trong khi $T < 1$ ở SVM cho thấy mô hình hơi thiếu tự tin và có thể hưởng lợi thêm từ hiệu chỉnh.

Brier Score. Brier score cũng giảm ở ba trên bốn mô hình. BiLSTM cải thiện mạnh nhất (từ 0,1511 xuống 0,1246), PhoBERT cải thiện từ 0,0941 xuống 0,0819. Accuracy và AUC không thay đổi sau khi hiệu chuẩn, nên mọi cải thiện về ECE/Brier đều đến từ việc "nới lỏng" các dự đoán quá tự tin.

Hàm ý thực tiễn. Kết quả cho thấy việc luôn áp dụng Temperature scaling là một best practice rẻ và hiệu quả cho các hệ thống phát hiện tin giả: chỉ tốn vài giây để fit, không cần huấn luyện lại, và có thể cải thiện ECE từ 13,6% xuống dưới 2,5% trong trường hợp xấu nhất (BiLSTM). Đối với các hệ thống downstream sử dụng ngưỡng xác suất để ra quyết định (ví dụ: chuyển sang kiểm

duyet thủ công khi $p > 0,9$), việc hiệu chỉnh này là cần thiết để tránh sự "tự tin ảo" từ mô hình.

Reliability diagrams — before (top) vs after best post-hoc calibration (bottom)



Hình 5.12: Biểu đồ hiệu chuẩn của bốn mô hình trước và sau khi áp dụng post-hoc calibration.

Bảng 5.12: So sánh hiệu chuẩn sau khi áp dụng ba phương pháp (Platt, Temperature, Isotonic) trên tập kiểm tra. ECE càng thấp càng tốt.

mô hình	ECE (gốc)	ECE (Platt)	ECE (Temp)	ECE (Isotonic)	Brier
Logistic Regression	0,0242	0,0215	0,0247	0,0203	0,1134
SVM	0,0229	0,0210	0,0296	0,0238	0,1131
BiLSTM	0,1361	0,0186	0,0215	0,0220	0,1246
PhoBERT	0,0846	0,0286	0,0263	0,0304	0,0819

5.5.2.3 Phân tích chuyên sâu các trường hợp khó (Hard Cases Deep Analysis)

Tập dữ liệu kiểm tra chứa 85 mẫu mà cả bốn mô hình đều phân loại sai (*hard examples*). Theo phương pháp luận đã mô tả ở Mục 4.7, các mẫu này được phân loại theo bốn chiều (chủ đề, lý do thất bại, độ dài, mật độ từ vựng) nhằm xác định các dạng thất bại hệ thống. Phần này trình bày kết quả phân tích chi tiết.

Các mẫu khó là gì? Trong số 2.094 mẫu kiểm tra, 85 mẫu (khoảng 4,1%) bị cả bốn mô hình – kể cả PhoBERT – dự đoán sai cùng một nhãn. Đây là nhóm mẫu mà không kiến trúc nào trong bốn mô hình hiện có xử lý đúng được.

Kết quả gán nhãn. Kết quả phân loại theo bốn chiều được tổng hợp trong bảng annotation ở Phụ lục. Điểm attribution thu được ở Mục 4.7 cũng được ghép nối vào bảng annotation phục vụ phân tích định tính.

Phát hiện về chủ đề. Phân bố chủ đề cho thấy *politics* chiếm $19/85 \approx 22\%$ và *finance_business* chiếm $10/85$ các trường hợp khó. Điều này cho thấy các bài báo về chính trị và tài chính thường chứa những chi tiết cụ thể khó xác minh tự động, phù hợp với nhận định rằng tin giả về chính trị và kinh tế là những dạng khó phát hiện nhất.

Phát hiện về độ dài. $59/85 \approx 69\%$ các mẫu khó có độ dài dưới 30 từ. Đây là các tiêu đề, câu dẫn ngắn hoặc trích đoạn tin tức chỉ cung cấp quá ít ngữ cảnh để phân biệt thật – giả. Điểm đáng chú ý là: tin giả ngắn thường có vẻ đáng tin vì thiếu dấu hiệu rõ ràng, trong khi tin thật dài đôi khi bị phân loại nhầm thành giả do thiếu từ khóa kích hoạt mạnh.


Phát hiện về lý do thất bại. Lý do thất bại phân bố thành bốn nhóm: $47/85$ mẫu (dataset ambiguity, 55,3%) – mẫu ngắn, không có từ khóa hay URL; $14/85$ mẫu (knowledge verification, 16,5%) – mẫu chứa số liệu hoặc URL cần kiến thức nền để xác minh; $6/85$ mẫu (semantic reasoning, 7,1%); và phần còn lại thuộc nhóm stylistic.

Độ tự tin của mô hình trên các mẫu khó. Trên 85 mẫu khó, cả bốn mô hình đều thể hiện độ tự tin cao bất thường: Logistic Regression trung bình 0,85, SVM 0,87, BiLSTM 0,95, PhoBERT 0,93. Đây là dấu hiệu điển hình của calibration failure ở vùng khó – mô hình đưa ra dự đoán với độ tin cậy cao dù

28

kết quả sai. Kết quả này nhấn mạnh tầm quan trọng của bước hiệu chỉnh xác suất ở Mục 5.5.2.2 đối với việc ra quyết định ở tầng downstream.

Hàm ý nghiên cứu. Các mẫu khó tập trung ở hai nhóm: (i) tin ngắn không đủ ngữ cảnh, gặp nhiều trong các bài báo chính trị và tài chính; (ii) tin chứa số liệu cụ thể mà mô hình không có cơ sở kiến thức để xác minh. Việc bổ sung external knowledge base (ví dụ: dữ liệu thống kê chính thức) hoặc multi-modal signals (hình ảnh, nguồn đăng tải) là hướng nghiên cứu tiếp theo tiềm năng.



Hình 5.13: Phân bố của 85 mẫu khó theo chủ đề, độ dài, lý do thất bại và độ tự tin của từng mô hình.

Bảng 5.13: Một số ví dụ mà cả bốn mô hình đều dự đoán sai. Nhãn thật: 0 = Thật, 1 = Giả. Thể hiện đặc trưng bề mặt, chủ đề và lý do thất bại.

id	nhân	trích đoạn	chủ đề	lý do	độ dài
8236	Giả	dầu_tư bắt động_sản qua ứng_dụng với số vốn chỉ từ 1 triệu đồng là mô_hình lừa_đảo đa_cấp.	finance	ambiguity	short
171	Thật	cuộc_sống gia_đình 'lối_sống truyền_thống' tuyệt_vời: cảnh_sát bắt_buộc 10 đứa trẻ...	science	semantic	long
12327	Giả	đồng_nhân_dân_tệ mất_giá_kỷ_lục do biến_động chính_trị...	education	ambiguity	short
7426	Giả	tấn_công tổng_tiền vào các_hệ_thống vệ_tinh đang trở_thành mối đe_doạ...	other	knowledge	short
13068	Giả	đất_nước hạnh_phúc và đáng sống gần 90000 người việt rời đất_nước...	other	knowledge	short
2884	Giả	sau thời_gian lúng_túng ban_đầu có_thể là do bùng_dịch ngoài...	other	other	medium
10538	Giả	phát_hiện một nhóm đối_tượng chuyên 'dầu_tư' xây_chùa...	entertainment	ambiguity	short
11060	Giả	chủ quán karaoke X tại hà_nội bị bắt vì tổ_chức bán_dâm...	entertainment	stylistic	short
13798	Thật	cậu b hiểu chuyện trưa hôm_nay một vụ tai_nạn trước cây_xăng...	education	semantic	long
11813	Giả	xâm_nhập_mặn tại đồng_bằng sống_cửu_long năm 2024 sẽ đạt mức kỷ_lục...	other	knowledge	short
10197	Giả	tỷ_giá usd/vnd tại các ngân_hàng thương_mại đã vượt ngưỡng 26.000...	finance	stylistic	short
9847	Giả	bản_tuyên_ngôn 'nam_quốc_sơn_hà' lý_thường_kiệt...	other	ambiguity	short

5.5.2.4 Knowledge Distillation – Mô hình sinh viên nhỏ, chất lượng tiệm cận giáo viên

Đặt vấn đề: PhoBERT đạt F1-macro cao nhất (89,88%) nhưng có kích thước lớn (~135 triệu tham số, ~540 MB), không phù hợp để triển khai trên thiết bị biên (edge devices) hay trong pipeline thời gian thực. Mục này trình bày kết quả của thí nghiệm knowledge distillation (được mô tả ở Mục 4.7), trong đó một mô hình BiLSTM nhỏ (sinh viên) được huấn luyện với sự hướng dẫn từ BiLSTM-gốc (giáo viên). Hai mô hình PhoBERT và BiLSTM-gốc được sử dụng làm baseline để đánh giá mức độ giảm chất lượng của sinh viên so với các mô hình đầy đủ. Phương pháp đã được mô tả đầy đủ ở Mục 4.7; mục này trình bày kết quả thực nghiệm.

Kết quả chính. Sau 8 epoch huấn luyện với early-stopping (patience = 5), mô hình sinh viên đạt F1-macro trên tập kiểm tra là 80,51%, chỉ thấp hơn

BiLSTM-giáo-viên (82,32%) khoảng $\Delta = |80,51 - 82,32| = 1,8$ điểm phần trăm, và thấp hơn PhoBERT-giáo-viên (89,88%) khoảng 9,4 điểm phần trăm. Đổi lại, kích thước mô hình giảm $\sim 87,1\times$, và độ trễ suy luận trung vị trên cùng batch 16 câu giảm từ $\sim 4,5$ ms (BiLSTM) xuống còn $\sim 1,2$ ms (nhanh hơn $3,8\times$).

Nhận xét. Sự đánh đổi giữa F1, kích thước và tốc độ trong thí nghiệm knowledge distillation này được tóm tắt trong Bảng 5.14. Kết quả cho thấy mô hình sinh viên KD giữ được $\sim 97,8\%$ chất lượng của BiLSTM trong khi tiêu tốn ít hơn $1/4$ tài nguyên, đủ nhanh để chạy thời gian thực trên CPU thường. Đây là kết quả đáng chú ý nhất của thí nghiệm knowledge distillation.

Hạn chế và hướng cải thiện. Khoảng cách F1 giữa sinh viên và giáo viên BiLSTM chủ yếu đến từ capacity gap: embedding 64 chiều của sinh viên có thể không diễn giải đủ các quan hệ ngữ nghĩa tinh tế mà BiLSTM-giáo-viên nắm bắt được nhờ embedding 300 chiều và hidden state 128 chiều. Các hướng cải thiện tiềm năng: (i) tăng α (hiện tại 0,7) để sinh viên bám sát giáo viên hơn nữa; (ii) bổ sung multi-teacher distillation (sinh viên học đồng thời từ PhoBERT và BiLSTM); (iii) thay embedding ngẫu nhiên bằng FastText tiếng Việt để tận dụng tri thức tiền huấn luyện.

Bảng 5.14: So sánh teacher (PhoBERT, BiLSTM) và student (Student BiLSTM) sau Knowledge Distillation trên tập kiểm tra.

mô hình	F1 $\uparrow$	params $\downarrow$	size (MB) $\downarrow$	latency (ms) $\downarrow$	compression $\uparrow$
PhoBERT (Teacher)	0,8916	135M	540	150	1 $\times$
BiLSTM (Teacher)	0,8232	6,44M	24,57	3,93	1 $\times$
Student BiLSTM (KD)	0,8051	1,55M	5,91	1,12	87,1 $\times$

5.6 Kết luận chương

Thực nghiệm toàn diện trên bốn mô hình so sánh cho phép rút ra bốn kết luận chính:

- PhoBERT là mô hình tốt nhất với $F1 = 89,88\%$; sự vượt trội này có ý nghĩa thống kê theo kiểm định McNemar với hiệu chỉnh Holm–Bonferroni ($p < 0,001$).
- Tiền huấn luyện trên ngữ liệu tiếng Việt — chứ không phải độ phức tạp của kiến trúc — mới là yếu tố quyết định hiệu năng cuối cùng; SVM vượt BiLSTM là minh chứng cho tầm quan trọng của chất lượng đặc trưng trong học máy truyền thống.
- Phân tích hiệu chỉnh xác suất cho thấy PhoBERT và BiLSTM bị miscalibrated (ECE ban đầu $\geq 6,9\%$); temperature scaling giảm ECE trên cả bốn mô hình mà không ảnh hưởng đến Accuracy/AUC.
- Thí nghiệm knowledge distillation cho thấy một BiLSTM nhỏ có thể thừa hưởng $\sim 97,8\%$ chất lượng của BiLSTM-gốc với kích thước $< 1/4$ và tốc độ nhanh hơn $3,8\times$, phù hợp triển khai trên thiết bị biên.

Cuối cùng, phân tích chuyên sâu 85 mẫu khó cho thấy các lỗi còn lại của cả bốn mô hình tập trung vào ba nhóm: *dataset ambiguity*, *knowledge verification* và *semantic reasoning* — những thách thức vượt khả năng của các phương pháp hiện nay chỉ dựa trên văn bản. Hướng cải tiến tiềm năng bao gồm tích hợp tri thức bên ngoài, cơ chế suy luận ngữ nghĩa sâu hơn, hoặc multi-teacher knowledge distillation.

KẾT LUẬN

Tóm tắt đóng góp

7 Nghiên cứu xây dựng và so sánh bốn phương pháp phát hiện tin giả tiếng Việt trên bộ dữ liệu 13.958 mẫu. Kết quả chính:

- PhoBERT đạt hiệu năng tốt nhất: accuracy = 90,07%, F1 = 89,88%, AUC = 0,9495.
- Cải thiện +6,59 điểm F1 so với baseline Logistic Regression.
- 41 • Kiểm định McNemar xác nhận sự vượt trội có ý nghĩa thống kê ($p < 0,001$).
- SVM vượt BiLSTM, minh chứng cho tầm quan trọng của chất lượng đặc trưng hơn độ phức tạp kiến trúc.
- Ablation study: tiền huấn luyện trên tiếng Việt là nhân tố quyết định; phân đoạn từ ảnh hưởng ít với TF-IDF nhưng quan trọng với PhoBERT.
- Phân tích lỗi xác định 85 mẫu khó (cả bốn mô hình đều sai), cho thấy hệ thống cần tích hợp thêm nguồn tri thức bên ngoài.

Hạn chế

- Tập dữ liệu có thể chưa bao phủ đầy đủ tất cả các thể loại và chiến thuật lan truyền tin giả trong thực tế, đặc biệt là các nội dung mới xuất hiện hoặc có tính chuyên biệt theo từng miền.
- Mô hình có thể suy giảm hiệu năng khi áp dụng trên dữ liệu ngoài miền huấn luyện (Domain Shift), đặc biệt đối với các hình thức ngụy trang tinh vi hoặc biến thể ngôn ngữ mới.
- Mô hình PhoBERT yêu cầu tài nguyên tính toán tương đối lớn, điều này có thể gây hạn chế khi triển khai trong môi trường thực tế quy mô lớn hoặc thời gian thực.

Hướng phát triển

- Thu thập thêm dữ liệu đa dạng thể loại tin giả tiếng Việt.
- Tích hợp thông tin đa phương thức (hình ảnh, đồ thị lan truyền mạng xã hội).
- Xây dựng hệ thống phát hiện thời gian thực với PhoBERT được nén nhỏ (Knowledge Distillation).
- Kết hợp kiểm chứng thực tế (Fact-Checking) với phân loại tự động.

TÀI LIỆU THAM KHẢO

- [1] B. Efron, “Bootstrap methods: Another look at the jackknife,” *The Annals of Statistics*, vol. 7, no. 1, pp. 1–26, 1979.
- [2] T. Mikolov, I. Sutskever, K. Chen, G. Corrado, and J. Dean, “Distributed representations of words and phrases and their compositionality,” in *Advances in Neural Information Processing Systems 26 (NeurIPS 2013)*, pp. 3111–3119, Curran Associates, Inc., 2013.
- [3] P. Bojanowski, E. Grave, A. Joulin, and T. Mikolov, “Enriching word vectors with subword information,” in *Transactions of the Association for Computational Linguistics*, vol. 5, pp. 135–146, 2017.
- [4] D. Q. Nguyen, T. V. Ho, D. Q. Nguyen, M. Dras, and M. Johnson, “Fast and accurate neural word segmentation for Vietnamese,” in *Proceedings of the 2018 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies, Volume 2 (Short Papers)*, (New Orleans, Louisiana), pp. 93–98, Association for Computational Linguistics, 2018.
- [5] K. Shu, A. Sliva, S. Wang, J. Tang, and H. Liu, “Fake news detection on social media: A data mining perspective,” *ACM SIGKDD Explorations Newsletter*, vol. 19, no. 1, pp. 22–36, 2017.

- [6] X. Zhou and R. Zafarani, “A survey of fake news: Fundamental theories, detection methods, and opportunities,” *ACM Computing Surveys*, vol. 53, no. 5, pp. 1–40, 2020.
- [7] P. Nakov, D. Corney, M. Hasanain, F. Alam, T. Elsayed, A. Barrón-Cedeño, P. Papotti, S. Shaar, H. Ali, H. Mubarak, *et al.*, “Overview of the CLEF-2022 CheckThat! lab check-worthiness, subjectivity, political bias, factuality, and authority,” in *Proceedings of the Working Notes of CLEF 2022 – Conference and Labs of the Evaluation Forum*, 2022.
- [8] D. R. Cox, “The regression analysis of binary sequences,” *Journal of the Royal Statistical Society: Series B (Methodological)*, vol. 20, no. 2, pp. 215–242, 1958.
- [9] C. Cortes and V. Vapnik, “Support-vector networks,” *Machine Learning*, vol. 20, no. 3, pp. 273–297, 1995.
- [10] K. Spärck Jones, “A statistical interpretation of term specificity and its application in retrieval,” *Journal of Documentation*, vol. 28, no. 1, pp. 11–21, 1972.
- [11] S. Hochreiter and J. Schmidhuber, “Long short-term memory,” *Neural Computation*, vol. 9, no. 8, pp. 1735–1780, 1997.
- [12] D. Bahdanau, K. Cho, and Y. Bengio, “Neural machine translation by jointly learning to align and translate,” in *Proceedings of the International Conference on Learning Representations (ICLR 2015)*, 2015.
- [13] J. Pennington, R. Socher, and C. D. Manning, “GloVe: Global vectors for word representation,” in *Proceedings of the 2014 Conference on Empirical Methods in Natural Language Processing (EMNLP)*, (Doha, Qatar), pp. 1532–1543, Association for Computational Linguistics, 2014.

- [14] J. Devlin, M.-W. Chang, K. Lee, and K. Toutanova, “BERT: Pre-training of deep bidirectional transformers for language understanding,” in *Proceedings of the 2019 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies*, (Minneapolis, Minnesota), pp. 4171–4186, Association for Computational Linguistics, 2019.
- [15] D. Q. Nguyen and A. T. Nguyen, “PhoBERT: Pre-trained language models for Vietnamese,” in *Findings of the Association for Computational Linguistics: EMNLP 2020*, (Online), pp. 1037–1042, Association for Computational Linguistics, 2020.
- [16] R. Sennrich, B. Haddow, and A. Birch, “Neural machine translation of rare words with subword units,” in *Proceedings of the 54th Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers)*, (Berlin, Germany), pp. 1715–1725, Association for Computational Linguistics, 2016.
- [17] A. Vaswani, N. Shazeer, N. Parmar, J. Uszkoreit, L. Jones, A. N. Gomez, Ł. Kaiser, and I. Polosukhin, “Attention is all you need,” in *Advances in Neural Information Processing Systems 30 (NeurIPS 2017)*, pp. 5998–6008, Curran Associates, Inc., 2017.
- [18] T. Lin, Y. Wang, X. Liu, and X. Qiu, “A survey of transformers,” *AI Open*, vol. 3, pp. 111–132, 2022.
- [19] P. Rajpurkar, J. Zhang, K. Lopyrev, and P. Liang, “SQuAD: 100,000+ questions for machine comprehension of text,” in *Proceedings of the 2016 Conference on Empirical Methods in Natural Language Processing*, pp. 2383–2392, 2016.
- [20] Y. Liu, M. Ott, N. Goyal, J. Du, M. Joshi, D. Chen, O. Levy, M. Lewis, L. Zettlemoyer, and V. Stoyanov, “RoBERTa: A robustly optimized BERT pretraining approach,” in *arXiv preprint arXiv:1907.11692*, 2019.

- [21] V. N. Nguyen, D. Van, and H. Nguyen, “A Vietnamese text classification system based on Naive Bayes classifier,” in *Proceedings of the 4th International Workshop on Vietnamese Language and Speech Processing (VLSP 2016)*, (Da Nang, Vietnam), 2016.
- [22] S. T. Luu, K. V. Nguyen, D.-V. Nguyen, and N. L.-T. Nguyen, “A vietnamese fake news detection system based on phobert,” *VNU Journal of Science: Computer Science and Communication Engineering*, vol. 37, no. 2, pp. 1–10, 2021.
- [23] K. Tran, S. Van Nguyen, and L. M. Nguyen, “A vietnamese fake news detection system,” in *Proceedings of the 2020 RIVF International Conference on Computing and Communication Technologies*, 2020.
- [24] Q. McNemar, “Note on the sampling error of the difference between correlated proportions or percentages,” *Psychometrika*, vol. 12, no. 2, pp. 153–157, 1947.
- [25] F. Pedregosa, G. Varoquaux, A. Gramfort, V. Michel, B. Thirion, O. Grisel, M. Blondel, P. Prettenhofer, R. Weiss, V. Dubourg, J. Vanderplas, A. Passos, D. Cournapeau, M. Brucher, M. Perrot, and E. Duchesnay, “Scikit-learn: Machine learning in Python,” *Journal of Machine Learning Research*, vol. 12, pp. 2825–2830, 2011.
- [26] S. Holm, “A simple sequentially rejective multiple test procedure,” *Scandinavian Journal of Statistics*, vol. 6, no. 2, pp. 65–70, 1979.
- [27] C. Guo, G. Pleiss, Y. Sun, and K. Q. Weinberger, “On calibration of modern neural networks,” *Proceedings of the 34th International Conference on Machine Learning (ICML 2017)*, pp. 1321–1330, 2017.
- [28] M. Pakdaman Naeini, G. F. Cooper, and M. Hauskrecht, “Obtaining well calibrated probabilities using Bayesian binning into quantiles,” in *Proceedings*

of the *Twenty-Ninth AAAI Conference on Artificial Intelligence*, pp. 2901–2907, AAAI Press, 2015.

- 35 [29] T. Vu, D. Q. Nguyen, D. Q. Nguyen, M. Dras, and M. Johnson, “VnCoreNLP: A Vietnamese natural language processing toolkit,” in *Proceedings of the 2018 Conference of the North American Chapter of the Association for Computational Linguistics: Demonstrations*, (New Orleans, Louisiana), pp. 56–60, Association for Computational Linguistics, 2018.
- 8 [30] N. Srivastava, G. Hinton, A. Krizhevsky, I. Sutskever, and R. Salakhutdinov, “Dropout: A simple way to prevent neural networks from overfitting,” in *Journal of Machine Learning Research*, vol. 15, pp. 1929–1958, 2014.
- [31] I. Loshchilov and F. Hutter, “Decoupled weight decay regularization,” in *International Conference on Learning Representations (ICLR 2019)*, 2019.
- 8 [32] S. M. Lundberg and S.-I. Lee, “A unified approach to interpreting model predictions,” in *Advances in Neural Information Processing Systems 30 (NeurIPS 2017)*, pp. 4765–4774, 2017.
- 73 [33] G. Hinton, O. Vinyals, and J. Dean, “Distilling the knowledge in a neural network,” in *NIPS Deep Learning and Representation Learning Workshop*, 2015.

PHỤ LỤC

Phụ lục A: Thống kê chi tiết bộ dữ liệu

A.1. Số mẫu theo lớp của từng tập

Bảng 5.15: Số mẫu theo lớp (Thật / Giả) trong ba tập sau khi chia phân tầng với `random_state=42`.

Tập	<i>thật</i> (0)	<i>giả</i> (1)	Tổng
Train	5.434	5.434	9.770
Val	1.165	929	2.094
Test	1.165	929	2.094

Sau khi chia tập, rõ ràng dữ liệu được kiểm tra theo cả nội dung `text` và trường `id`; cả hai phép giao đều có kích thước bằng 0.

A.2. Ví dụ mẫu trong tập kiểm tra

Mẫu tin thật (`label = 0`, ngắn):

*Giáo_dục hoà_nhập giúp học_sinh khuyết_tật có cơ_hội học_tập cùng các
bạn bình_thường. (id=5857)*

Mẫu tin thật (`label = 0`, dài):

“Việc học là suốt đời, chúng ta có thể tạm hoãn; sức khỏe là quan trọng nhất...”
(id=4519, DH Nông lâm, về COVID-19)

Mẫu tin giả (label = 1):

Tầng ozone đã hoàn toàn biến mất vào năm 2023 do sự nóng lên của mặt trời.
(id=8262)

Mẫu tin giả giật tít (label = 1):

Chính quyền cấp xã luôn đi tắt đón đầu dân. Dân chờ cả ngày trời để lãnh “hỗ trợ” 80 ngàn đồng rồi bị trấn lột tại chỗ.
(id=3126)

A.3. Pipeline tiền xử lý

Quy trình làm sạch gồm bốn bước: (i) loại bỏ trùng lặp theo cột `text`; (ii) loại bỏ bản ghi có ít hơn `min_word_count = 10` từ; (iii) chuẩn hóa cột `date` về định dạng ISO 8601; (iv) đánh lại chỉ mục `id` tuần tự từ 1.

Phân đoạn từ ưu tiên `py_vncorenlp` (RDRSegmenter, cùng tokenizer với PhoBERT); tự động chuyển sang `underthesea.word_tokenize` khi không khả dụng.

Phụ lục B: Cấu hình huấn luyện chi tiết

Toàn bộ siêu tham số được tập trung tại file cấu hình chung của dự án, đọc qua singleton `cfg`.

Bảng 5.16: Cấu hình TF-IDF, Logistic Regression và SVM.

Nhóm	Siêu tham số	Giá trị
TF-IDF	max_features	40.000
	ngram_range	(1, 2)
	min_df / max_df	5 / 0,95
	sublinear_tf	True
LR	C (tốt nhất)	10 (solver=saga, L2)
	max_iter	3000
	class_weight	balanced
	Lưới tìm kiếm	$C \in \{0,5; 1; 5; 10; 20; 50\}$
SVM	C (tốt nhất)	0,5 (LinearSVC + Platt)
	class_weight	balanced
	Lưới tìm kiếm	$C \in \{0,1; 0,5; 1; 2; 5; 10\}$

Bảng 5.17: Cấu hình BiLSTM và PhoBERT.

Mô hình	Siêu tham số	Giá trị
BiLSTM	Embedding dim	300 (FastText cc.vi.300)
	Hidden dim / Layers	128 / 1
	Max seq length	128
	Dropout / Weight decay	0,3 / 10^{-4}
	Learning rate	10^{-3} (AdamW)
	Batch / Epochs	64 / 20 (patience=5)
	Gradient clip	max_norm = 1,0
PhoBERT	model_name	vinai/phobert-base
	Max seq length	256
	Dropout	0,1
	LR / Weight decay	3×10^{-5} / 0,01
	Batch / Grad accum.	16 / 4 (effective ≈ 64)
	Epochs / Patience	8 / 2
	Layer LR decay	0,95

B.1. Knowledge Distillation

Sinh viên là StudentBiLSTM (BiLSTM rút gọn với embedding_dim = 64, hidden_dim = 64, num_layers = 1). Trọng số soft target $\alpha = 0,7$, nhiệt độ $T = 4$. Optimizer AdamW với lr= 10^{-3} , scheduler CosineAnnealingLR. Tối đa

8 epoch, dừng sớm patience=5. Hàm mất mát KD chuẩn (Hinton et al., 2015) được trình bày ở Mục 4.7; sinh viên được huấn luyện trên logits giáo viên đã được tính trước và lưu lại.

B.2. Post-hoc Calibration

Ba phương pháp, đều khớp trên tập validation và áp lên tập test:

- **Platt scaling:** hồi quy logistic một chiều trên logits.
- **Temperature scaling:** tối ưu vô hướng $T \in [10^{-3}, 10^3]$ bằng L-BFGS-B.
- **Isotonic regression:** ánh xạ đơn điệu phi tham số trên $\sigma(z)$.

Giá trị T đã khớp: LR = 1,00, SVM = 0,73, BiLSTM = 0,38, PhoBERT = 0,55.

Phụ lục C: Kết quả chi tiết

C.1. Metric tổng hợp trên tập test

Bảng 5.18: Accuracy, Precision, Recall và F1-macro trên tập test.

Mô hình	Accuracy	Precision	Recall	F1-macro
Logistic Regression	0,8348	0,8325	0,8333	0,8329
SVM	0,8434	0,8418	0,8404	0,8410
BiLSTM	0,8252	0,8228	0,8235	0,8232
PhoBERT	0,9007	0,9018	0,8968	0,8988

C.2. Metric theo lớp

Bảng 5.19: Precision, Recall và F1 theo lớp (Thật / Giả) trên tập test.

Mô hình	Lớp Thật (0)			Lớp Giả (1)		
	Prec	Rec	F1	Prec	Rec	F1
Logistic Regression	0,8552	0,8464	0,8507	0,8098	0,8202	0,8150
SVM	0,8538	0,8670	0,8603	0,8299	0,8138	0,8217
BiLSTM	0,8459	0,8386	0,8422	0,7998	0,8084	0,8041
PhoBERT	0,8945	0,9313	0,9125	0,9092	0,8622	0,8851

C.3. Confusion matrix trên tập test

Bảng 5.20: Số mẫu TN, FP, FN, TP của bốn mô hình trên tập test.

Mô hình	TN	FP	FN	TP	Tổng lỗi
Logistic Regression	985	179	167	992	346 (16,52%)
SVM	1.010	155	173	756	328 (15,66%)
BiLSTM	977	188	178	751	366 (17,48%)
PhoBERT	1.085	80	128	801	208 (9,93%)

C.4. Khoảng tin cậy Bootstrap 95%

Khoảng tin cậy được ước lượng bằng bootstrap (`scipy.stats.bootstrap`) với 10,000 lần lặp.

Bảng 5.21: Khoảng tin cậy 95% cho F1-score trên tập test, ước lượng bằng bootstrap với 10,000 lần lặp.

Mô hình	95% CI (F1-score)
Logistic Regression	[0,8165; 0,8487]
SVM	[0,8253; 0,8564]
BiLSTM	[0,8063; 0,8391]
PhoBERT	[0,8853; 0,9114]

C.5. Knowledge Distillation – chi tiết

Bảng 5.22: So sánh hai mô hình giáo viên (PhoBERT, BiLSTM) và sinh viên BiLSTM ($\alpha = 0,7$, $T = 4$).

Mô hình	F1 test	Params	Kích thước (MB)
PhoBERT (giáo viên)	0,8988	~135M	540
BiLSTM (giáo viên)	0,8232	~500K	24,57
Student BiLSTM (KD)	80,51	1,549 442	5,91

Nén so với PhoBERT: $87,1\times$; nén so với BiLSTM: $4,2\times$; tốc độ suy diễn 1,2 ms, nhanh hơn $3,8\times$; giữ được 97,8 phần trăm chất lượng của BiLSTM.

C.6. Attribution Faithfulness

Faithfulness là mức giảm xác suất trung bình khi che top-5 token được attribution đánh dấu trên 20 mẫu.

Bảng 5.23: Faithfulness của sáu phương pháp attribution.

Phương pháp	Faithfulness
LR – SHAP	0,34
SVM – SHAP	0,31
BiLSTM – Integrated Gradients	0,19
BiLSTM – Simple Gradients	0,12
PhoBERT – SHAP	0,27
PhoBERT – Integrated Gradients	0,29
PhoBERT – Attention Rollout	0,08

C.7. Cross-validation 5-fold

Bảng 5.24: Accuracy và F1 trung bình qua 5-fold cross-validation (3 seed) cho hai mô hình truyền thống.

Mô hình	Accuracy	$\pm$ std	F1-macro	$\pm$ std
Logistic Regression	0,8301	0,0087	0,8282	0,0087
SVM	0,8490	0,0087	0,8469	0,0087

C.8. Hard cases – phân bố

85 mẫu khó (cả bốn mô hình đều sai):

Bảng 5.25: Phân bố 85 mẫu khó theo lý do thất bại suy đoán.

Lý do	Số mẫu
dataset_ambiguity	47
knowledge_verification	14
semantic_reasoning	6
Chủ đề politics	19 (phân bố theo chủ đề)
Độ dài short (<30 từ)	59

Phụ lục D: Tái lập thực nghiệm

D.1. Yêu cầu môi trường

Python `numpy 2.4, pandas 3.0, scikit-learn 1.8,`
`scipy 1.17, torch 2.10, transformers 4.57,`
`sentencepiece 0.2, fasttext-wheel 0.9.2.`

Tiếng Việt `py_vncorenlp 0.1.4` (Java ≥ 11)
 hoặc `underthesea 9.1` (dự phòng).

Giải thích `shap  $\geq 0.45$ , captum  $\geq 0.7$ .`

Biến môi trường: `JAVA_HOME` trỏ tới JRE. PhoBERT (vinai/phobert-base)

và FastText (cc.vi.300.bin) được tải tự động từ HuggingFace và đặt tại data/fasttext/.

D.2. Pipeline huấn luyện – đánh giá

```
python -m venv .venv && source .venv/bin/activate
pip install -r requirements.txt
python -m src.preprocessing.word_segmentation
python -m src.preprocessing.split_data
python -m src.features.extract_all_features
python -m src.training.train_all
python -m src.training.reproduce_predictions
python -m src.training.train_student
python -m src.evaluation.post_hoc_calibration
python -m src.evaluation.error_analysis
python -m src.evaluation.hard_cases
python -m src.analysis.statistical_tests
python -m src.analysis.generate_paper_tables
python -m src.analysis.generate_paper_figures
cd paper && ./build.sh
```

D.3. Thiết lập ngẫu nhiên

Seed chính của toàn bộ pipeline là `cfg.RANDOM_STATE = 42`, được dùng cho `train_test_split`, `GridSearchCV` (qua `StratifiedKFold(shuffle=True)`) và các script huấn luyện. Hàm `set_reproducibility_seeds` cố định đồng thời `random`, `numpy`, `torch` và `torch.cuda`; được gọi đầu mỗi trainer.

D.4. File cấu hình

Toàn bộ siêu tham số tập trung tại file cấu hình chung và import qua singleton `cfg`, gồm các khối: `PATHS`, `DATA` (tỉ lệ chia tập, `min_word_count = 10`), `TFIDF`, `LR`, `SVM`, `BILSTM`, `PHOBERT`, `ANALYSIS` (`bootstrap_iterations = 10,000`, `significance_level = 0,05`).

Mọi giá trị hiển thị trong bài báo được định nghĩa tại `data_commands.sty` dưới dạng `\newcommand`, cho phép cập nhật đồng bộ từ một vị trí duy nhất.